

Capítulo 6

Distribuciones continuas especiales

(Revisión 01/2012)

1. Introducción	1
2. Distribución uniforme	1
2.1. Características de la distribución uniforme	2
2.2. Aplicaciones de la distribución uniforme	3
2.3. Simulación de Montecarlo	3
2.4. Aplicación práctica de la simulación de Montecarlo	4
3. Distribuciones Erlang y gamma.....	5
4. Distribución exponencial	8
4.1. Características	9
4.2. Pérdida de memoria de la distribución exponencial	10
4.3. Aplicaciones.....	11
5. Distribución de Weibull	12
6. Distribución normal.....	13
6.1. Características de la distribución normal.....	16
6.2. Tipificación	16
6.3. Aproximación de la Normal a las distribuciones binomial y de Poisson.....	17
7. Gráficos de probabilidad	17
8. Problemas	20

Después de un estudio en profundidad de este capítulo, el estudiante deberá ser capaz de:

- Entender los supuestos de las distribuciones de probabilidad continuas más frecuentes.
- Seleccionar la distribución continua apropiada para el problema considerado para calcular probabilidades.
- Calcular probabilidades, medias y varianzas de las distribuciones de probabilidad continuas más comunes.
- Utilizar la tabla de la función de distribución de la distribución normal.
- Aproximar probabilidades para determinadas distribuciones binomiales y de Poisson.

1. Introducción

Generalmente, las distribuciones continuas son susceptibles de un tratamiento matemático más elegante que las distribuciones discretas. En este sentido las distribuciones continuas se usan en la mayor parte de las aplicaciones, tanto en construcción de modelos como en la aplicación de técnicas estadísticas. Las distribuciones continuas se usan para aproximar distribuciones discretas. De hecho, la mayor parte de los usos de las distribuciones continuas en la construcción de modelos son como aproximación de distribuciones discretas. En general es más razonable representar un valor dado por una variable aleatoria continua que por una variable aleatoria discreta ya que de esta forma se simplifica el análisis matemático y estadístico.

Vamos a ver algunos modelos teóricos de distribuciones de tipo continuo que sirvan para ajustarlos a las frecuencias de las observaciones de una población.

2. Distribución uniforme

Definimos la distribución uniforme como una distribución continua con función de densidad constante en un intervalo $[a, b]$ y densidad nula fuera del mismo.

$$f(x) = k \quad a \leq x \leq b$$

El valor de la constante queda determinado en función del intervalo, ya que:

$$\int_a^b f(x)dx = \int_a^b kdx = 1 \quad \Rightarrow \quad k(b - a) = 1 \quad \Rightarrow \quad k = \frac{1}{b - a}$$

Por tanto, la distribución uniforme en $[a, b]$ queda especificada por la función de densidad:

$$f(x) = \frac{1}{b-a} \quad a \leq x \leq b$$

A esta función de densidad le corresponde una representación gráfica de la forma indicada en la Figura 1. Por esta razón a este tipo de distribución se le suele denominar también *rectangular*.

La *función de distribución* es:

$$F(x) = \frac{x-a}{b-a} \quad a \leq x \leq b$$




Figura 1. Distribución uniforme

La probabilidad correspondiente a un intervalo $[c, d]$ es:

$$P(c \leq X \leq d) = \int_c^d \frac{1}{b-a} dx = \frac{d-c}{b-a}$$

Por tanto, el cociente entre la longitud del intervalo $[c, d]$ y la longitud total del intervalo en el que está definida la distribución. Este resultado se modifica fácilmente si todo el intervalo $[c, d]$ no está contenido en $[a, b]$.

2.1. Características de la distribución uniforme

La función característica es:

$$\varphi(t) = E(e^{itx}) = \frac{1}{b-a} \int_a^b e^{itx} dx = \frac{1}{b-a} \left[\frac{e^{itx}}{it} \right]_a^b = \frac{e^{itb} - e^{ita}}{it(b-a)}$$

Veamos el valor medio y la varianza:

$$E(X) = \alpha_1 = \frac{1}{b-a} \int_a^b x dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}$$

$$\alpha_2 = \frac{1}{b-a} \int_a^b x^2 dx = \frac{1}{b-a} \left[\frac{x^3}{3} \right]_a^b = \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3}$$

$$\sigma^2 = \alpha_2 - \alpha_1^2 = \frac{(b-a)^2}{12}$$

Interesa en particular la distribución uniforme en el intervalo $[0, 1]$. Para esta distribución resulta:

$$f(x) = 1 \quad 0 \leq x \leq 1$$

$$F(x) = x \quad 0 \leq x \leq 1$$

$$E(X) = \frac{1}{2} \quad \sigma^2 = \frac{1}{12}$$

$$\varphi(t) = \frac{e^{it} - 1}{it}$$

2.2. Aplicaciones de la distribución uniforme

Esta distribución es la más sencilla entre las de tipo continuo. Tiene aplicaciones importantes.

- a) Es la distribución apropiada para representar el fenómeno aleatorio que consiste en considerar un punto al azar en el intervalo $[a, b]$. Si hacemos esta proposición supondremos que el número real correspondiente X , es una variable aleatoria con distribución uniforme en el intervalo $[a, b]$.
- b) Veremos más adelante que una transformación de la variable aleatoria X a otra Y dada por $Y = F_x(X)$ siendo $F_x(X)$ la función de distribución de la variable aleatoria X , da lugar a que Y tenga una distribución uniforme. Este tipo de transformación es de aplicación fundamental en los *métodos de simulación* conocidos como *métodos de Montecarlo*.

2.3. Simulación de Montecarlo

Supongamos una variable aleatoria continua X . Sea $F(x)$ su función de distribución: $F(x) = P(X \leq x)$. $F(x)$ es una función de la variable real X cuyas propiedades hemos estudiado. En particular nos interesa fijarnos ahora en la propiedad de monotonía: es no decreciente, y en la de acotación: $0 \leq F(x) \leq 1$. Tal y como la hemos definido, los valores de $F(x)$ son las probabilidades de que la variable aleatoria X pertenezca a intervalos de la forma $I_x = (-\infty, x]$.

Vamos a emplear la función $F(x)$ para definir una variable aleatoria transformada de X en la forma $Y = F(X)$. Teniendo en cuenta el recorrido de valores de X , conocemos que el recorrido de valores de Y es $0 \leq y \leq 1$. Por tanto, la variable aleatoria Y tendrá densidad de probabilidad nula fuera de este intervalo. Vamos a determinar la función de distribución de Y . Si denominamos $G(y) = P(Y \leq y)$ es (véase Figura 2):




Figura 2

$$G(y) = P(Y \leq y) = P[F(X) \leq y] = P[X \leq F^{-1}(y)] = P(X \leq x) = F(x) = y$$

Por consiguiente la variable aleatoria Y tiene siempre la misma distribución: una distribución uniforme en el intervalo $[0, 1]$.

Recíprocamente: si Y es una variable aleatoria uniforme en $[0, 1]$ y sea F una función de distribución. Si definimos a partir de Y la variable aleatoria X por la transformación $X = F^{-1}(Y)$, la variable aleatoria X tiene como función de distribución precisamente a $F(X)$. En efecto, denominemos $F_1(x)$ a la función de distribución de X . Teniendo en cuenta su definición es (ver Figura 3):

$$\begin{aligned} F_1(x) &= P(X \leq x) = P[F^{-1}(Y) \leq x] = P[Y \leq F(x)] \\ &= P(Y \leq y) = G(y) = y \end{aligned}$$

Obtenemos así $\forall x$ $F_1(x) = y$, pero es $y = F(x)$ por tanto es $F_1(x) = F(x)$ y $F(x)$ es precisamente la distribución de la variable aleatoria X .

En este segundo sentido es en el que la transformación por la curva integral tiene su mayor aplicación. Hemos visto que si Y tiene distribución uniforme en $[0, 1]$ y es $X = F^{-1}(y)$, X tiene por función de distribución a $F(x)$.

Por tanto, si observamos un conjunto de valores $(y_1, y_2, \dots, y_m)$ y denominamos $(x_1, x_2, \dots, x_m)$ a sus correspondientes transformados, estos valores se comportan como si se hubieran observado de la variable aleatoria X .




Figura 3

2.4. Aplicación práctica de la simulación de Montecarlo

Teniendo en cuenta el apartado anterior, es fácil generar números con cualquier distribución siempre y cuando dispongamos de un generador de números aleatorios (con distribución

uniforme en $[0, 1]$) y conozcamos o dispongamos de un programa que tenga la función de distribución inversa de la distribución con la que deseamos generar números aleatorios.

La mayoría de las calculadoras de mano tienen una tecla llamada “Random” que genera un número cada vez que se aprieta. Los números generados con esta tecla tienen una distribución $U(0, 1)$. Excel tiene una función “ALEATORIO()” que genera números distribuidos uniformemente en $[0, 1]$.

En la Tabla siguiente los números de la primera fila se han generado en Excel con la función *ALEATORIO()*. Cada número de la fila 2 se ha obtenido a partir del número de la misma columna de la fila 1 aplicando la fórmula “= INV. NORM(celda; 3; 2)”, siendo celda el correspondiente número de la fila 1. En consecuencia, los números de la fila 2 tienen una distribución normal con media 3 y desviación típica 2.

0,0002	0,6741	0,5593	0,276	0,8312	0,1333	0,594	0,0981	0,1423	0,3446
-4,0802	3,9025	3,2984	1,8105	4,9178	0,7781	3,4757	0,4151	0,8599	2,2001

3. Distribuciones Erlang y gamma

Vamos a ver la distribución de la variable aleatoria correspondiente al tiempo transcurrido hasta la ocurrencia de r sucesos en un proceso de Poisson.

Sea X la variable que representa el número de sucesos ocurridos en un intervalo de tiempo de longitud x . Sea λ (dimensiones eventos/unidad de tiempo) la media del proceso de Poisson. Entonces la probabilidad de que el evento r ocurra a partir del instante x es la probabilidad de Poisson de que en el intervalo $(0, x)$ hayan ocurrido $r - 1$ eventos, es decir:

$$P(X > x) = P(Y = r - 1) = \sum_{k=0}^{r-1} \frac{(\lambda x)^k}{k!} e^{-\lambda x}$$

Al ser $P(X > x) = 1 - F(x)$, la función de densidad de X es igual a la derivada cambiada de signo del anterior sumatorio. Tras un laborioso proceso de cálculo se obtiene que:

$$f(x) = \frac{\lambda^r}{(r-1)!} x^{r-1} e^{-\lambda x} \quad x > 0 \quad r = 1, 2, \dots$$

Esta distribución se conoce con el nombre de Erlang.

Interesa generalizar la distribución de Erlang para valores de r que sean positivos pero también no enteros. Para ello recordamos de cálculo la función gamma $\Gamma(r)$:

$$\Gamma(r) = \int_0^{+\infty} x^{r-1} e^{-x} dx \quad r > 0$$

Para los valores indicados $r > 0$, la integral que define a $\Gamma(p)$ es convergente.

Se obtiene inmediatamente:

$$\Gamma(1) = \int_0^{+\infty} e^{-x} dx = 1$$

Se demuestra que $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$.

La fórmula recurrente de cálculo de la función gamma se obtiene integrando por partes:

$$\Gamma(r) = [-x^{r-1}e^{-x}]_0^{+\infty} + (r-1) \int_0^{+\infty} x^{r-2}e^{-x} dx$$

De donde:

$$\Gamma(r) = (r-1)\Gamma(r-1)$$

Si r es entero y positivo podemos aplicar reiteradamente este proceso obteniendo:

$$\Gamma(r) = (r-1)!$$

Si r no es entero, se llega por recurrencia hasta un valor de $\Gamma(r)$ con r comprendido entre 0 y 1 que viene en algunas tablas de libros de texto o se puede calcular mediante Excel. La función $\Gamma(r)$ permite generalizar el concepto de factorial a números no enteros.

Ahora podemos generalizar la distribución Erlang introduciendo la distribución gamma.

La variable aleatoria X con función de densidad:

$$f(x) = \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x} \quad x > 0$$

diremos que tiene una distribución gamma con parámetros $\lambda > 0$ y $r > 0$. Los parámetros λ y r son los parámetros de **escala y forma** respectivamente. Si r es entero, X tiene una distribución Erlang. A esta distribución la denotaremos por $\gamma(r, \lambda)$. Excel tiene una función para esta distribución: `DIST.GAMMA(x;α;β;acumulado)` donde `acumulado` es 0 para calcular la probabilidad individual y 1 para calcular la suma de probabilidades de todos los valores menores o iguales que x . α se corresponde con r y $\beta = 1/\lambda$

La forma de esta función puede verse en la Figura 5.




Figura 4. Distribuciones gamma

De la definición de la distribución gamma se deduce que:

$$\int_0^{\infty} x^{r-1} e^{-\lambda x} dx = \frac{\Gamma(r)}{\lambda^r}$$

Calculemos el momento de orden k de la variable X con distribución gamma:

$$\begin{aligned} \alpha_k = E(X^k) &= \frac{\lambda^r}{\Gamma(r)} \int_0^{\infty} x^k x^{r-1} e^{-\lambda x} dx = \frac{\lambda^r}{\Gamma(r)} \int_0^{\infty} x^{r+k-1} e^{-\lambda x} dx = \frac{\lambda^r}{\Gamma(r)} \frac{\Gamma(r+k)}{\lambda^{r+k}} \\ &= \frac{1}{\lambda^k} \frac{\Gamma(r+k)}{\Gamma(r)} = \frac{r(r+1)(r+2) \cdots (r+k-1)}{\lambda^k} = \frac{r^{(k)}}{\lambda^k} \end{aligned}$$

Donde $r^{(k)}$ representa el producto de k factores crecientes de unidad en unidad a partir de r.

En consecuencia:

$$\alpha_1 = \frac{r}{\lambda} \quad \alpha_2 = \frac{r(r+1)}{\lambda^2}$$

De aquí que el valor medio y la varianza valgan:

$$\mu = \frac{r}{\lambda} \quad \sigma^2 = \alpha_2 - \alpha_1^2 = \frac{r}{\lambda^2}$$

Puede deducirse que la moda es:

$$m = \frac{r - 1}{\lambda}$$

4. Distribución exponencial

Cuando se estudió la distribución de Poisson, se vio un ejemplo de una variable que representaba el número de defectos en una bobina de papel de longitud L . La distancia entre defectos es también otra variable aleatoria. Sea X la variable aleatoria que representa la distancia desde cualquier punto de partida de la bobina hasta el punto donde se detecta el primer error. Como se puede intuir, la distribución de X puede obtenerse a partir de la distribución del número de defectos. Así, la distancia al primer defecto excede 2 metros sí y sólo sí no hay defectos en una longitud de 2 metros. Esto es simple, pero suficiente para encontrar la distribución de X .

En general, sea Y la variable que representa el número de defectos en x metros de la bobina. Si la media del número de defectos es λ por metro, Y tiene una distribución de Poisson con media λx . Suponemos que la bobina tiene una longitud superior a x . Se tendrá:

$$P(X > x) = P(Y = 0) = \frac{(\lambda x)^0}{0!} e^{-\lambda x} = e^{-\lambda x}$$

Por tanto:

$$F(x) = P(X \leq x) = 1 - P(X > x) = 1 - e^{-\lambda x} \quad x \geq 0$$

Derivando $F(x)$ obtenemos la función de densidad:

$$f(x) = \lambda e^{-\lambda x} \quad x \geq 0$$

La distribución de X depende sólo del supuesto de que los defectos en la bobina siguen un proceso de Poisson. Asimismo, el punto de partida para medir X no importa porque la probabilidad del número de fallos en un intervalo de un proceso de Poisson depende sólo de la longitud del intervalo, no de la localización. Para cualquier proceso de Poisson se aplica siempre el siguiente principio general:

La variable aleatoria X que mide la distancia entre eventos sucesivos de un proceso de Poisson con valor medio λ eventos por unidad de intervalo tiene una **distribución exponencial** de parámetro λ . La función de densidad es:

$$f(x) = \lambda e^{-\lambda x} \quad x \geq 0$$

A esta distribución la denominamos $EXP(\lambda)$. Excel tiene una función para esta distribución: $DIST.EXP.N(x; \lambda; acumulado)$ donde acumulado es 0 para calcular la probabilidad individual y 1 para calcular la suma de probabilidades de todos los valores menores o iguales que x .

La Figura 4 muestra la forma de la distribución exponencial para algunos valores de λ .




Figura 5. Función de densidad de la distribución exponencial

Es importante emplear unidades consistentes en los cálculos que se hagan con la distribución exponencial. El siguiente ejemplo muestra la manera de realizar adecuadamente la conversión de unidades.

Ejemplo 1. En la centralita de una gran empresa, las llamadas que se reciben pueden modelarse mediante un proceso de Poisson de media 25 llamadas por hora. ¿Cuál es la probabilidad de que no haya llamadas en un intervalo de 6 minutos?

Sea X el tiempo en horas desde el comienzo del intervalo hasta la primera llamada. Entonces X tiene una distribución exponencial con λ igual a 25 llamadas por hora. Estamos interesados en la probabilidad de que X exceda 6 minutos. Como λ tiene unidades de llamadas por hora, expresamos el tiempo en horas. Como 6 minutos son 0.1 horas, la probabilidad buscada es:

$$P(X > 0.1) = \int_{0.1}^{\infty} 25e^{-25x} dx = e^{-25(0.1)} = 0.082$$

La misma respuesta se obtiene transformando la media de llamadas por hora en llamadas por minuto: 0.41667 llamadas por minuto y calcular la probabilidad de que el tiempo hasta la próxima llamada exceda 6 minutos. Pruebe a hacerlo.

4.1. Características

Como esta distribución es una distribución $\gamma(r, \lambda)$ con $r = 1$. Particularizando, se tiene:

Función de distribución: $F(x) = 1 - e^{-\lambda x}$

Función característica: $\varphi(t) = \frac{\lambda}{\lambda - it}$

Valor medio: $\mu = \frac{1}{\lambda}$

Varianza: $\sigma^2 = \frac{1}{\lambda^2}$

4.2. Pérdida de memoria de la distribución exponencial

De manera general, se puede formular la pérdida de memoria de la distribución exponencial mediante la siguiente expresión:

$$P(X < t_1 + t_2 | X > t_1) = P(X < t_2)$$

Su demostración es fácil:

$$\begin{aligned} P(X < t_1 + t_2 | X > t_1) &= \frac{P(t_1 < X < t_1 + t_2)}{P(X > t_1)} = \frac{F(t_1 + t_2) - F(t_1)}{1 - F(t_1)} = \frac{e^{-\lambda t_1} - e^{-\lambda(t_1 + t_2)}}{e^{-\lambda t_1}} \\ &= 1 - e^{-\lambda t_2} = F(t_2) = P(X < t_2) \end{aligned}$$

Interpretación de esta propiedad: La probabilidad de que ocurra un evento en un intervalo de duración $(t_1 + t_2)$ supuesto que ha transcurrido t_1 unidades de tiempo es igual a la probabilidad de ocurra un evento en un intervalo de duración t_2 (el tiempo que falta por transcurrir del intervalo de partida $(t_1 + t_2)$). Es decir, el hecho de que en las primeras t_1 unidades de tiempo no haya ocurrido ningún evento no influye en la probabilidad de que en las restantes t_2 unidades de tiempo ocurra algún evento.

Ejemplo 2. Se está empleando un contador Geiger para medir la radioactividad en el edificio de una central atómica. Se conoce que el tiempo que transcurre entre la detección de dos partículas radiactivas se ajusta a una variable aleatoria X con distribución exponencial de media 1.4 minutos. Por tanto, la probabilidad de detectar una partícula en los primeros 30 segundos de puesta a punto del contador es:

$$P(X < 0.5 \text{ minutos}) = F(0.5) = 1 - e^{-\frac{0.5}{1.4}} = 0.3003$$

Supongamos ahora que volvemos a encender el contador y en los primeros 2 minutos no se detecta ninguna partícula. ¿Cuál es la probabilidad de detectar una partícula en *los siguientes* 30 segundos?

Podríamos pensar que puesto que hemos esperado 2 minutos sin detectar ninguna partícula, la probabilidad de detectar una partícula en los siguientes 30 segundos sea algo mayor de 0.3003. La respuesta es que no cuando se trata de una distribución exponencial. Calculemos esta probabilidad:

$$P(X < 2.5 | X > 2) = \frac{P(2 < X < 2.5)}{P(X > 2)} = \frac{F(2.5) - F(2)}{1 - F(2)} = \frac{e^{-\frac{2}{1.4}} - e^{-\frac{2.5}{1.4}}}{e^{-\frac{2}{1.4}}} = 0.3003$$

La interpretación es que el hecho de haber esperado 2 minutos sin detectar ninguna partícula no cambia la probabilidad de detección en los siguientes 30 segundos.

4.3. Aplicaciones

El tiempo de vida de válvulas, lámparas y otras piezas de equipos eléctricos o electrónicos son variables aleatorias. Vamos a ver que la distribución exponencial es la apropiada para representar el *tiempo de fallo* de una componente cuando se puedan establecer las siguientes premisas:

- a) en un tiempo muy corto, Δx , la probabilidad de fallo es proporcional a Δx . La ponemos en la forma $\lambda \Delta x$.
- b) la probabilidad de fallo es independiente de x (es decir, se trata de elementos que no sufren un desgaste apreciable con el tiempo, pues de otra forma esta probabilidad cambia con el tiempo)

Vamos a considerar la probabilidad de que la componente no falle en un intervalo $(0, x)$. Para ello dividimos el intervalo en n partes iguales: $\Delta x = x/n$. Para n grande Δx es pequeño y podemos considerar que la probabilidad de que falle es $\lambda \Delta x$ y la de que no falle será: $1 - \lambda \Delta x$. Teniendo en cuenta la hipótesis de que la probabilidad de que falle en un intervalo pequeño no depende de la posición de éste, podemos considerar que la probabilidad de que la pieza no falle en el intervalo $(0, x)$ será:

$$p = P(X \geq x) = (1 - \lambda \Delta x)^n$$

Como

$$\Delta x = \frac{x}{n} \quad \Rightarrow \quad n = \frac{x}{\Delta x}$$

Luego:

$$p = (1 - \lambda \Delta x)^{\frac{x}{\Delta x}} = \left[\left(1 + \frac{1}{\frac{1}{\lambda \Delta x}} \right)^{-\frac{1}{\lambda \Delta x}} \right]^{-\lambda x} \xrightarrow{\Delta x \rightarrow 0} e^{-\lambda x}$$

Como:

$$P(X \geq x) = \int_x^{+\infty} \lambda e^{-\lambda t} dt = \lambda \left[-\frac{e^{-\lambda t}}{\lambda} \right]_x^{+\infty} = e^{-\lambda x}$$

De acuerdo con esto, la distribución exponencial se emplea en estudios de fiabilidad de sistemas para representar el tiempo hasta el fallo de un dispositivo. La pérdida de memoria de la distribución exponencial implica que el dispositivo no se desgasta. Esto es, independientemente de cuánto tiempo ha estado funcionando el dispositivo, la probabilidad de fallo en las siguientes 1000 horas es igual que la probabilidad de fallo en las primeras 1000 horas de funcionamiento. Por consiguiente, el tiempo de vida de un dispositivo con fallos causados por perturbaciones aleatorias puede ser representado por una distribución exponencial. Sin embargo, el tiempo de vida T de un dispositivo que sufre desgaste se modeliza mejor por una distribución tal que la probabilidad $P(T < t + \Delta t | T > t)$ aumenta con el tiempo. En situaciones como esta, se emplea la distribución de Weibull que se verá más adelante.

5. Distribución de Weibull

Como se dijo anteriormente, la distribución de Weibull se usa para modelizar el tiempo hasta el fallo de diferentes tipos de sistemas. Los parámetros de la distribución proporcionan una gran flexibilidad para modelizar sistemas en que el número de fallos aumenta con el tiempo (sistemas que sufren desgaste), disminuye con el tiempo (algunos semiconductores) o permanece constante con el tiempo (fallos causados por perturbaciones externas al sistema).

Decimos que la variable X tiene una distribución de Weibull con parámetro de forma $\alpha > 0$ y parámetro de escala $\beta > 0$ cuando su función de densidad es:

$$f(x) = \frac{\alpha}{\beta^\alpha} x^{\alpha-1} e^{-\left(\frac{x}{\beta}\right)^\alpha} \quad x > 0$$

A esta distribución la denominamos $W(\alpha, \beta)$. Excel tiene una función para esta distribución: *DIST.WEIBULL*($x; \alpha; \beta; \text{acumulado}$) donde *acumulado* es 0 para calcular la probabilidad individual y 1 para calcular la suma de probabilidades de todos los valores menores o iguales que x .

La flexibilidad de esta distribución se observa en los gráficos de la Figura 6. La función de distribución es fácil de obtener:

$$F(x) = 1 - e^{-\left(\frac{x}{\beta}\right)^\alpha}$$

El valor medio y la varianza de la distribución de Weibull son:

$$\mu = \beta \Gamma\left(1 + \frac{1}{\alpha}\right) \quad \sigma^2 = \beta^2 \Gamma\left(1 + \frac{2}{\alpha}\right) - \beta^2 \left[\Gamma\left(1 + \frac{1}{\alpha}\right)\right]^2$$




Figura 6. Distribuciones Weibull para diferentes valores de α y β

6. Distribución normal

La distribución normal es la más importante de las que se estudian en estadística. La razón de este hecho está en el Teorema Central del Límite, que veremos más adelante.

De acuerdo con este teorema una variable aleatoria:

$$Z = \sum_{i=1}^n X_i$$

donde las X_i son independientes, tiene una distribución que tiende a ser normal cuando $n \rightarrow \infty$. Este teorema se verifica en condiciones muy amplias, o sea, con pocas restricciones para las distribuciones de las X_i .

Como son muchas las variables aleatorias que se presentan en el mundo real que podemos suponer que tienen una composición del tipo indicado, esta es la razón de que sean muchas las variables aleatorias de las que podemos suponer que se adapta bien una distribución de este tipo.

La distribución normal se estudió por primera vez en el siglo XVIII en relación con los errores de medida. Esta distribución podía ser aproximada por una curva en forma de **campana** a la que se denominó **curva normal de errores**. Fue estudiada sistemáticamente por:

- Pierre Laplace (1749-1827)
- Abraham de Moivre (1667-1745)
- Karl Gauss (1777-1855)

En honor de este último la distribución normal suele denominarse distribución **de Gauss**.

Bajo la influencia de estos matemáticos, que fue enorme, durante mucho tiempo se consideró que *todas* las distribuciones estadísticas se aproximaban a la normal, y que si no era así se debía a falta de información, a no tener datos suficientes. Es de Lippman la frase: *“todos creen en la ley normal de errores; los experimentadores porque piensan que es un teorema matemático; los matemáticos porque creen que es un hecho experimental”*.

Hemos indicado ya la razón fundamental de la *presencia* de la distribución normal, que aclararemos después. La introduciremos de la forma siguiente. Diremos que X tiene una distribución normal $N(\mu, \sigma)$ cuando tenga una función de densidad de la forma:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad -\infty < x < +\infty$$

Su forma es:




Figura 7. Forma de la distribución normal para algunos valores de μ y σ

Veremos que μ y σ son el valor medio y la desviación típica de la distribución. Cuando $\mu = 0$ y $\sigma = 1$ tenemos el caso de la distribución normal estándar $N(0, 1)$, cuya función de densidad es:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad -\infty < x < +\infty$$

Los dos siguientes teoremas, serán de utilidad en ciertos cálculos y demostraciones.

Teorema 1. Si X es una variable aleatoria $N(0, 1)$ la variable aleatoria $Y = X^2$ es $\gamma\left(\frac{1}{2}, \frac{1}{2}\right)$.

Demostración:

Cuando la distribución de X es continua, ya hemos deducido en forma general que a la variable aleatoria $Y = X^2$ le corresponde una función de densidad:

$$f_y(y) = \frac{1}{2\sqrt{y}} [f_x(\sqrt{y}) + f_x(-\sqrt{y})]$$

En nuestro caso:

$$f_y(y) = \frac{1}{2\sqrt{y}} \left[\frac{1}{\sqrt{2\pi}} e^{-\frac{y}{2}} + \frac{1}{\sqrt{2\pi}} e^{-\frac{y}{2}} \right] = \frac{1}{\sqrt{2\pi}} e^{-\frac{y}{2}} y^{-\frac{1}{2}}$$

Que como puede comprobarse, se trata de una distribución $\gamma(r, \lambda)$ con $r = \frac{1}{2}$ y $\lambda = \frac{1}{2}$

Veamos a continuación las características de la distribución $N(0, 1)$.

Para calcular los momentos de una distribución $N(0, 1)$ conviene recordar en primer lugar el siguiente teorema.

Teorema 2. Si X es una variable aleatoria con una distribución simétrica respecto de $x = 0$, y $g(x)$ es una función impar, entonces $E[g(X)] = 0$

Demostración:

Supongamos X continua. Entonces es $f(-x) = f(x)$ y, por ser $g(X)$ impar, es $g(-x) = -g(x)$. Entonces:

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x)f(x)dx = \int_{-\infty}^0 g(x)f(x)dx + \int_0^{+\infty} g(x)f(x)dx$$

Hacemos en la primera el cambio $x = -y$:

$$\int_{-\infty}^0 g(x)f(x)dx = \int_{-\infty}^0 g(-y)f(-y)(-dy) = \int_{-\infty}^0 g(y)f(y)dy = - \int_0^{+\infty} g(y)f(y)dy$$

Sustituyendo este resultado en la expresión anterior se reduce con la segunda integral tal como se quería demostrar.

6.1. Características de la distribución normal.

Sea Z una variable aleatoria $N(0, 1)$ y X una variable $N(\mu, \sigma)$. La relación entre ambas es:

$$Z = \frac{X - \mu}{\sigma}$$

Los momentos centrales para X se calculan fácilmente teniendo en cuenta que $X - \mu = \sigma Z$. Además, debido a la simetría de la distribución respecto de μ , sabemos que $\mu_{2r+1} = 0$.

Calculemos los momentos centrales de orden par de X . Para ello tendremos en cuenta que por el Teorema 1, $Y = X^2$ tiene una distribución $\gamma(r, \lambda)$ con $r = \frac{1}{2}$ y $\lambda = \frac{1}{2}$:

$$\mu_{2r} = E(X - \mu)^{2r} = E(\sigma Z)^{2r} = \sigma^{2r} E(X^2)^r = \sigma^{2r} E(Y)^r = \sigma^{2r} 2^r \left(\frac{1}{2}\right)^r$$

Que se puede poner de forma más simplificada:

$$\mu_{2r} = \sigma^{2r} \cdot 1 \cdot 3 \cdot 5 \cdot \dots \cdot (2r - 1)$$

De aquí se deduce que:

$$\mu_2 = \sigma^2 \cdot 1 = \sigma^2$$

Se demuestra que la función característica de una distribución $N(\mu, \sigma)$ es

$$\varphi(t) = e^{it\mu} \cdot e^{-\frac{t^2\sigma^2}{2}}$$

6.2. Tipificación

Tabulada la función $F_z(z)$ para una variable aleatoria Z que es $N(0, 1)$ podemos emplearla para determinar valores de la distribución normal general X que sea $N(\mu, \sigma)$. En efecto,

$$P(X \leq x) = P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) = P\left(Z \leq \frac{x - \mu}{\sigma}\right) = F_z\left(\frac{x - \mu}{\sigma}\right)$$

Teniendo esto en cuenta podemos calcular fácilmente probabilidades de la forma:

$$P(a \leq X \leq b) = P\left(\frac{a - \mu}{\sigma} \leq \frac{X - \mu}{\sigma} \leq \frac{b - \mu}{\sigma}\right) = F_z\left(\frac{b - \mu}{\sigma}\right) - F_z\left(\frac{a - \mu}{\sigma}\right)$$

Por esta razón, basta disponer de una tabla con la función de distribución de la $N(0, 1)$.

6.3. Aproximación de la Normal a las distribuciones binomial y de Poisson

En este apartado estableceremos unas que permiten simplificar los cálculos de probabilidades binomiales y de Poisson. Su justificación se verá en el capítulo donde se exponga el teorema central del límite.

APROXIMACIÓN DE LA DISTRIBUCIÓN BINOMIAL POR LA NORMAL. Si X es una variable con distribución binomial $B(n, p)$ entonces la variable Z :

$$Z = \frac{X - np}{\sqrt{np(1-p)}}$$

tiene una distribución que es aproximadamente normal $N(0, 1)$.

Para que la aproximación sea mejor, se debe aplicar la llamada **corrección por continuidad**:

$$P(X \leq x) = P(X \leq x + 0.5) \cong P\left(Z \leq \frac{x + 0.5 - np}{\sqrt{np(1-p)}}\right)$$

$$P(x \leq X) = P(x - 0.5 \leq X) \cong P\left(\frac{x - 0.5 - np}{\sqrt{np(1-p)}} \leq Z\right)$$

Para que la aproximación sea buena se ha de cumplir que $np > 5$ y $n(1-p) > 5$.

APROXIMACIÓN DE LA DISTRIBUCIÓN DE POISSON POR LA NORMAL. Si X es una variable con distribución de Poisson de parámetro λ entonces la variable Z :

$$Z = \frac{X - \lambda}{\sqrt{\lambda}}$$

tiene una distribución que es aproximadamente normal $N(0, 1)$.

Se debe emplear también la corrección por continuidad, al igual que con la distribución binomial. Esta aproximación es buena cuando $\lambda > 5$

7. Gráficos de probabilidad

A veces no conocemos si una distribución concreta de probabilidad es un modelo razonable para los datos de la muestra obtenida. Esta cuestión es importante, pues muchas de las técnicas de cálculo estadístico dependen de la distribución real de la población de los datos.

Algunos de los gráficos ya vistos tales como el histograma pueden proporcionar ayuda sobre la distribución de la población. Sin embargo, los histogramas no son indicadores muy fiables de la forma de la distribución salvo que el tamaño de la muestra sea muy grande.

Un gráfico de probabilidad es un método gráfico para determinar si los datos de una muestra se ajustan o no a una determinada distribución de probabilidad, basándose en un examen visual de los datos. El procedimiento general es muy simple y puede llevarse a cabo rápidamente. También es más fiable que un histograma para muestras de tamaño pequeño o moderado.

Los pasos para construir un gráfico de probabilidad son los siguientes:

- Ordenar los datos de menor a mayor
- Asignar un rango a los valores, $i = 1, 2, \dots, n$
- Calcular: $(i - 0.5)/n$ para $i = 1, 2, \dots, n$
- Utilizar la tabla de la distribución hipotética para obtener los valores z_i tales que $z_i = F^{-1}[(i - 0.5)/n]$ para $i = 1, 2, \dots, n$ y siendo F la función de distribución de la población
- Dibujar los pares de valores (*valor observado* _{i} , z_i)
- Interpretar el gráfico: si la distribución hipotética describe adecuadamente los datos, la gráfica de puntos tendrá la forma de una línea recta; en caso contrario, si la gráfica de puntos no tiene forma de recta, la distribución hipotética no es apropiada.

Ejemplo 3. Se ha obtenido una muestra de la duración en minutos de diez baterías de ordenadores portátiles recién recargadas. Los datos son:

204.56 188.16 213.69 171.26 210.78 186.26 194.77 219.39 221.76 168.05

Se piensa que estas duraciones pueden modelarse mediante una distribución normal. Obténgase un gráfico de probabilidad e interprétese el resultado.

Mediante Excel es fácil obtener la siguiente tabla (con los datos observados ordenados):

Tabla 1. Cálculo para construir un gráfico de probabilidad

Datos observados	i	$(i - 0.5)/n$	z_i
168,05	1	0,05	-1,645
171,26	2	0,15	-1,036
186,26	3	0,25	-0,674
188,16	4	0,35	-0,385
194,77	5	0,45	-0,126
204,56	6	0,55	0,126
210,78	7	0,65	0,385
213,69	8	0,75	0,674
219,39	9	0,85	1,036
221,76	10	0,95	1,645

Y gráficamente:




Figura 8. Gráfico de probabilidad del Ejemplo 3

El gráfico de probabilidad puede ser útil para identificar distribuciones simétricas pero que tienen colas más “pesadas” o más “ligeras” que la normal, tal como se indica en la Figura 9.




Figura 9. Gráficos de probabilidad indicando: (a) Sesgo a la derecha (b) Sesgo a la izquierda (c) Colas cortas (menos varianza que la esperada) y (d) Colas largas (más varianza que la esperada)

Cuando se está haciendo un gráfico de probabilidad para distribución normal, los datos de la muestra no constituirán una gráfica en línea recta. Se requiere cierta experiencia y raciocinio para evaluar el gráfico. Generalmente, si el tamaño de muestra es $n < 30$, el gráfico puede desviarse mucho de la linealidad, por lo que en estos casos sólo una gran desviación puede interpretarse como indicación de no normalidad. Conforme n aumenta, el patrón lineal tiende a ser más fuerte y el gráfico de probabilidad normal será más fácil de interpretar y más fiable como indicador de la forma de distribución.

8. Problemas

6-1. Una bombilla halógena para lámparas de despacho tiene una vida (en años) que puede representarse por una variable aleatoria con la siguiente función de densidad:

$$f(x) = \begin{cases} \frac{x}{2} & 0 \leq x \leq 1 \\ \frac{1}{2} & 1 \leq x \leq 2 \\ \frac{1}{2}e^{-2(x-2)} & x \geq 2 \end{cases}$$

Se instalan tres bombillas idénticas el mismo día.

- a) Hallar la probabilidad de que las tres hallan fallado al cabo de tres años.
- b) Hallar la probabilidad de que una y sólo una falle al cabo de tres años.
- c) Determinar el número de años al cabo de los cuáles la probabilidad de que no existan ninguna en funcionamiento sea de 0.99.

Solución: a) 0.9019, b) 0.0033, c) 4.1571 años.

6-2. Sea X una variable aleatoria $N(0, 1)$. Calcular las siguientes probabilidades:

- a) $P(0 \leq X \leq 1.42)$
- b) $P(-0.73 \leq X \leq 0)$
- c) $P(-1.37 \leq X \leq 2.01)$
- d) $P(0.65 \leq X \leq 1.26)$
- e) $P(-1.79 \leq X \leq -0.54)$
- f) $P(X \geq 1.13)$
- g) $P(|X| \leq -0.5)$

Solución: a) 0.4222, b) 0.2673, c) 0.8925, d) 0.1540, e) 0.2579, f) 0.1292, g) 0.2830.

6-3. Sea X una variable aleatoria $N(0, 1)$. Determinar el valor de k si:

- a) $P(0 \leq X \leq k) = 0.4236$
- b) $P(X \leq k) = 0.7967$
- c) $P(k \leq X \leq 2) = 0.1$

Solución: a) 1.43, b) 0.83, c) 1.161.

6-4. La temperatura de Ferrol durante el mes de Julio está normalmente distribuida con media 20°C y desviación típica 3°C. Encontrar la probabilidad de que la temperatura esté entre 21°C y 26°C.

Solución: 0.3467.

6-5. En una cadena de montaje se emplea una pieza cilíndrica que debe tener un determinado diámetro d con límites de tolerancia t_i y t_s conocidos y especificados por el departamento de ingeniería. Estas piezas se procesan automáticamente en una máquina herramienta que, ajustada para producir piezas de un determinado diámetro d , produce en realidad piezas que se ajustan a una distribución $N(d, \sigma)$, siendo σ también conocido. Las piezas con diámetro superior a t_s pueden ajustarse con un coste adicional de C_1 €/pieza. Las piezas con diámetro inferior a t_i suponen una pérdida de C_2 €/pieza. Determinar la medida a la que debe ajustarse la máquina para que el coste total esperado sea mínimo. Estudiar el caso particular en que: $t_i = 44 \text{ mm}$, $t_s = 48 \text{ mm}$, $C_1 = 2 \text{ €/pieza}$, $C_2 = 5 \text{ €/pieza}$, $\sigma = 3 \text{ mm}$.

Solución: $d^* = \frac{t_s + t_i}{2} + \frac{\sigma^2}{t_s - t_i} \ln\left(\frac{C_2}{C_1}\right)$. Caso particular: $d^* = 48.06 \text{ mm}$.

6-6. Un componente eléctrico consta de un montaje de dos resistencias en serie. Cada una de ellas tiene un valor nominal de a ohmios y b ohmios respectivamente. Se conoce que el verdadero valor de las resistencias de este tipo se comporta como una variable aleatoria con distribución normal de valor medio el que figura como valor nominal y desviación típica el 2% de dicho valor. Expresar en función de a , b y c

- La probabilidad de que un montaje de este tipo tenga una resistencia superior a " $a + b + c$ ".
- ¿A qué porcentaje del valor medio debe ser igual la desviación típica de cada resistencia para que dicha probabilidad sea 0.01?
- Estudiar el caso particular en que $a = 3$, $b = 4$, $c = 0.1$.

Solución: a) $1 - F_z\left(\frac{50c}{\sqrt{a^2 + b^2}}\right)$, b) $p = \frac{42.987c}{\sqrt{a^2 + b^2}}$, c) $P(Y \geq 7.1) = 0.1587$, $p = 0.8597$.

6-7. Una factoría produce paquetes de margarina. El peso nominal del contenido de cada paquete es 450 gramos. Sin embargo, debido a fluctuaciones aleatorias en la báscula automática, el peso del contenido de los paquetes varía y se observa que un 10% de los paquetes está por debajo del peso nominal, mientras que un 5% pesa no menos de 457 gramos.

- Calcular la media y la desviación típica de la distribución de los pesos, supuesto que esta distribución es normal.

La producción diaria de la factoría es de 375.000 paquetes y el coste de producción, en céntimos de euro, de un paquete conteniendo x gramos de margarina es: $335 + 6.8515x - 0.01402x^2$. Debido a un aumento de la demanda mundial de aceites comestibles, el coste de producción de la margarina aumenta. Para compensar una parte de este aumento, el fabricante hace ciertas reducciones en sus gastos básicos y establece controles para disminuir

desperdicios. Como resultado de estas medidas, la función de costes pasa a ser: $334.68 + 6.8705x - 0.01398x^2$. Determinar antes y después de la subida del precio de los aceites:

- b) El coste medio por paquete.
- c) El coste medio de la producción diaria.

Solución: a) $\mu=453.0654$, $\sigma=2.391854$, b) Antes: 5.6124 €/paquete. Después: 5.7774 €/paquete, c) Antes: 2104636.58 € Después: 2166508.58 €

6-8. El contenido nominal Y de los tarros de mermelada envasados en una fábrica es w gramos, pero debido a las fluctuaciones del proceso de envasado puede considerarse que tiene una distribución normal con media x gramos y desviación típica σ , siendo x un valor ajustable.

Todos los tarros se pesan y los que tienen un contenido inferior a w gramos se desechan, teniendo un valor para la empresa de C/2 euros por tarro. De los tarros restantes el 90% se venden al precio de C euros por tarro y el 10% se devuelve a la fábrica donde tienen un valor de recuperación de C/2 euros por tarro. El coste de producción por tarro en euros es $0.01Y - k$ siendo k una constante.

- a) Calcular el valor x que hace máximo el beneficio medio.
- b) Para el caso de w = 500 gramos, $\sigma = 3$, C = 5 euros por tarro y k = 4 euros por tarro, calcular x y el beneficio medio por tarro.
- c) Refiriéndonos al caso concreto del apartado b) se realizó una inspección de la producción de la fábrica, resultado que el 20% de los tarros tenían un contenido inferior a 501 gramos. ¿A qué valor x está ajustada la media? ¿Cuál es el beneficio medio en este caso? ¿En qué cantidad hay que aumentar o disminuir el valor de x para optimizar el beneficio medio?

Solución: a) $x = w + \sigma \sqrt{2 \ln \frac{45C}{\sigma \sqrt{2\pi}}}$, b) $x = 507.82137$, $B = 3.66$ euros por tarro, c1) $x = 503.52486$, $B = 3.44$ euros/tarro, hay que aumentar x en 4.29651 gramos.

6-9. En un proceso de fabricación se obtienen planchas de acero que han de tener un determinado grosor. Debido a las propiedades del material, el comportamiento de las máquinas así como de las herramientas utilizadas el grosor sufre ligeras perturbaciones aleatorias imposibles de predecir. Por ello, el grosor X en milímetros de las placas puede considerarse como una variable aleatoria que, para un determinado ajuste de la línea de producción, puede considerarse que tiene una distribución normal con media 10 mm y desviación típica 0.02 mm Determinar el porcentaje de placas defectuosas que se esperan obtener suponiendo que las placas defectuosas son:

- a) placas más delgadas que 9.97 mm
- b) placas más gruesas que 10.05 mm
- c) placas cuyo grosor difiere en más de 0.03 mm de 10 mm

Suponiendo que las placas defectuosas son aquellas cuyo espesor es inferior a $10-k$ y superior a $10+k$:

- d) determinar la constante k de forma que el porcentaje esperado de placas defectuosas no supere el 5%.
- e) ¿Cómo cambiará el porcentaje de placas defectuosas en el apartado d) si el valor medio pasa de 10 mm a 10.01 mm?

6-10. Se ha comprobado que el tiempo X , en minutos, necesario para completar la reparación de una estación de trabajo es una variable aleatoria con distribución gamma de dos parámetros $\gamma(r, \lambda)$. El tiempo medio de reparación es de 100 minutos y el tiempo más probable es 50 minutos.

- a) Calcular los parámetros p y a .
- b) Determinar en función de la constante k , el valor $P(X \geq k)$.
- c) Calcular $P(X \leq \mu_x)$
- d) Calcular la probabilidad de que X tome un valor mayor de 2 veces su desviación típica con respecto a su media, es decir, $P(X \geq \mu_x + 2\sigma_x)$.
- e) Calcular la probabilidad de que X tome un valor menor que su moda.

6-11. Sea una variable aleatoria normal X , con valor medio m y desviación típica $m/2$.

- a) Determinar la probabilidad de un valor experimental de X sea negativo.
- b) Determinar la probabilidad de que la suma de cuatro valores experimentales independientes de X sea negativa.
- c) Calcular la probabilidad de que el producto de cuatro valores experimentales independientes de X sea negativo.
- d) Obtener la función de densidad de la variable aleatoria $|X_1 - X_2|$

6-12. Se sabe que un determinado tipo de transistor tiene un tiempo medio de fallo de diez mil horas. Se ha comprobado que los tiempos de vida de estos transistores tienen una distribución exponencial.

- a) ¿Cuál es la probabilidad de que el tiempo de vida de un transistor exceda el tiempo medio de vida?
- b) ¿Cuál es la probabilidad de que el transistor falle en las primeras mil horas de uso?
- c) ¿Cuál es la probabilidad de que el tiempo de vida de un transistor esté entre 10000 y 11000 horas?
- d) La tasa de fallo durante un periodo de tiempo es la probabilidad de fallo durante ese periodo dado que el transistor ha sobrevivido hasta el comienzo de dicho periodo. En otras palabras, la tasa de fallo durante un periodo de tiempo es el número de transistores que fallarán durante ese periodo dividido por el número de transistores que todavía están operativos al comienzo de dicho periodo. Determinar la tasa de fallo del periodo (10000, 11000).
- e) Compare el resultado d) con el b). Interprete el resultado.

6-13. Una variable aleatoria tiene una distribución $\gamma(r, \lambda)$ cuya media es 18 y su varianza 36. Determinar su función de densidad y la moda.

6-14 Un fabricante de lámparas fluorescentes sabe que la cantidad de pintura luminiscente depositada en uno de sus productos está normalmente distribuida con media de 1.2 gramos y una desviación típica de 0.03 gramos. Cualquier lámpara con menos de 1.14 gramos de pintura luminiscente no cumplirá las especificaciones de los clientes. Se toma una muestra al azar de 25 lámparas y se mide en cada una la cantidad de pintura fluorescente.

- a) ¿Cuál es la probabilidad de que al menos una lámpara no cumpla las especificaciones?
- b) ¿Cuál es la probabilidad de que 5 lámparas o menos no cumplan las especificaciones?
- c) ¿Cuál es la probabilidad de que todas las máquinas cumplan las especificaciones?

6-15. El peso de los habitantes de una población está distribuido normalmente con una media de 65 Kg y una desviación típica de 15 Kg.

- a) Calcular el porcentaje de personas con un peso superior a 80 Kg.
- b) Determinar la probabilidad de que en una muestra de 7 personas exactamente 4 tengan un peso comprendido entre 60 y 75 Kg.
- c) Calcular el número medio de personas de la muestra del apartado anterior que no tienen un peso comprendido entre 60 y 75 Kg.
- d) Se han examinado las 7 personas del apartado b), resultando que 5 tienen un peso comprendido entre 60 y 75 Kg. Si seleccionamos 3 personas, ¿cuál será la probabilidad de que exactamente 2 personas tengan un peso comprendido entre 60 y 75 Kg?
- e) Calcular la probabilidad de que haya que seleccionar al menos 3 personas de la población antes de encontrar la primera persona con un peso comprendido entre 60 y 75 Kg.

6-16. El diámetro en cm de cierto tipo de cable eléctrico posee una distribución normal de la que se sabe que el 99'38% de los cables tiene un diámetro inferior a 0'85 cm y el 84'13% tiene un diámetro superior a 0'78 cm.

Un cable se considera defectuoso si el diámetro se diferencia de la media de la población en más de 0'025.

- a) Determinar el valor medio y la desviación típica del diámetro de los cables.
- b) Calcular la probabilidad de que un cable elegido al azar sea defectuoso.
- c) Los cables se embalan en cajas de 50 unidades. Hallar el número esperado de cajas con, a lo más, un 20% de cables defectuosos en un lote de 500 cajas.