

Capítulo 8

Inferencia estadística

(Revisión 01/2012)

1. Inferencia estadística	1
2. Muestreo estadístico	2
3. Distribuciones asociadas a un proceso de muestreo	3
4. Distribución de la media muestral	4
5. El estadístico varianza muestral.....	5
6. Distribución Chi cuadrado de Pearson	6
7. Muestreo aleatorio simple de una distribución normal.....	8
8. Distribución t de Student	8
9. Razón de Student.....	10
10. Distribución F de Snedecor	11
11. Estadísticos de orden	12
11.1. Distribución del mínimo muestral.....	12
11.2. Distribución del máximo muestral	13
11.3. Distribución conjunta del mínimo y del máximo muestral	13
12. Problemas.....	14

Después de un estudio en profundidad de este capítulo, el estudiante deberá ser capaz de:

- Entender y diferenciar los conceptos de media muestral, varianza muestral, media poblacional y varianza poblacional.
- Entender el concepto de muestreo aleatorio y su utilidad.
- Aplicar el muestreo aleatorio a una población con distribución normal.
- Conocer las distribuciones empleadas en el muestreo: chi cuadrado, t de Student y F Snedecor.
- Aplicar y conocer estadísticos de orden.

1. Inferencia estadística

Los métodos estadísticos se emplean para tomar decisiones y sacar conclusiones sobre poblaciones. Este aspecto de la estadística se conoce con el nombre de **inferencia estadística**. Para ello se utiliza la información de una muestra para sacar conclusiones.

La inferencia estadística se divide en dos grandes áreas: **estimación de parámetros** y **contraste de hipótesis**. Como ejemplo de estimación de parámetros, supongamos que un ingeniero está analizando la resistencia a la tracción de un componente empleado en el chasis de un vehículo. La variabilidad está presente en los componentes debido a diferencias en los materiales empleados, el proceso de fabricación y los procedimientos de medida (por citar algunos casos), de manera que el ingeniero desea estimar la resistencia media de la población de componentes. En la práctica, el ingeniero utilizará una muestra de datos para calcular un valor que sea razonable (una buena tentativa) de la verdadera media de la población. Este número se llama una **estimación por punto**. Veremos en el capítulo 9 que hay procedimientos para desarrollar estimadores de parámetros con buenas propiedades estadísticas. Además podremos establecer la precisión de la estimación por punto (capítulo 10, intervalos de confianza).

Consideremos ahora otra situación. Supongamos que se utilizan dos temperaturas de reacción diferentes t_1 y t_2 en un proceso químico. Un ingeniero puede preguntarse si t_1 origina un mayor rendimiento que t_2 . El contraste de hipótesis es el marco para resolver problemas de este tipo. En este ejemplo, el ingeniero estaría interesado en formular una hipótesis que le permita demostrar que el rendimiento medio utilizando t_1 es mayor que utilizando t_2 . Nótese que no se hace énfasis en estimar rendimientos; en su lugar, se está interesado en la conclusión acerca de una hipótesis que es relevante para tomar una decisión. El capítulo 11 tratará sobre contraste de hipótesis.

2. Muestreo estadístico

Estamos interesados en el estudio de los fenómenos aleatorios representados por una variable aleatoria. Sabemos que esta queda completamente determinada cuando conocemos su distribución de probabilidad.

A un conjunto de datos obtenidos en un experimento aleatorio se les denomina **muestra**. El problema fundamental, en conjunto, es pues *inducir* de las características de una muestra las de la *población* de la que proceden. La Estadística se ocupa pues del estudio de los *problemas* a partir de *muestras*. Conviene precisar estos conceptos.

Entre los fenómenos reales de carácter indeterminado hemos considerado los aleatorios. Hemos visto que podemos describirlos por una distribución de probabilidad, por una variable aleatoria X de una o varias dimensiones. Esta variable aleatoria tendrá un *recorrido* finito o infinito. Este recorrido es el conjunto de valores *distintos* que puede tomar X , que podemos *observar* de X .

- 1) Lanzamiento de un dado: los valores posibles son 1, 2, 3, 4, 5, 6.
- 2) Diámetro de ejes: $a \leq x \leq b$; a y b se establecen de una determinada forma.
- 3) Número de llamadas en una central durante una hora: 0, 1, 2, ...
- 5) Valor de la resistencia de un elemento tomado de un determinado lote.

Ahora bien, en relación con un fenómeno aleatorio cualquiera podemos considerar no el conjunto de valores que puede tomar X sino todo el conjunto de observaciones *posibles* que podemos hacer de X . En el ejemplo 5 este conjunto de observaciones *posibles* es un conjunto *actual*, que tiene existencia, y lo vemos perfectamente claro. En los otros casos los conjuntos de *todas las observaciones posibles* son potenciales y claramente infinitos. A este conjunto de todas las observaciones posibles de un fenómeno aleatorio es el que vamos a denominar **población** (de observaciones posibles correspondientes al fenómeno aleatorio).

Por tanto, una **muestra** de tamaño n es un conjunto de observaciones $(x_1, x_2, \dots, x_n)$

Proceso de muestreo es el conjunto de reglas de acuerdo con las cuales se extraen las muestras.

Está claro que cada valor x_i es una observación que podemos considerarla de una variable aleatoria X_i . X_i será la variable aleatoria correspondiente al fenómeno aleatorio: primera observación. El conjunto de *valores muestrales* $(x_1, x_2, \dots, x_n)$ serán observaciones de otras variables aleatorias $X_1, X_2, \dots, X_n$ que podrán tener o no la misma distribución de X_1 según que el *proceso de muestreo* no modifique o *sí* modifique la *composición* de la población.

En principio podemos apreciar que:

- Un muestreo de población infinita no modifica (sensiblemente) la composición de la población (cuando ésta es potencial)
- Un muestreo de población finita *con reemplazamiento* claramente no modifica la composición de la población.

- El mismo sin reemplazamiento sí la modifica.

En general cuando el proceso de muestreo es tal que a cada muestra $(x_1, x_2, \dots, x_n)$ podemos considerarla como una observación de una variable aleatoria $(X_1, X_2, \dots, X_n)$ con una determinada distribución de probabilidad, al muestreo se le denomina *probabilístico*.

En particular cuando todas las X_i tienen la *misma distribución* y son independientes el proceso de muestreo se le denomina **aleatorio simple**. Este es el tipo de muestreo más importante y el único que consideraremos en este curso.

A la variable aleatoria $(X_1, X_2, \dots, X_n)$ asociada a un proceso de muestreo probabilístico para muestras de tamaño n la llamaremos en general **muestra genérica**. A una observación particular de la muestra genérica: $(x_1, x_2, \dots, x_n)$ le llamaremos **muestra**. Denominaremos **estadístico** a una variable aleatoria $Y = g(X_1, X_2, \dots, X_n)$ función de la muestra genérica. A cada estadístico le corresponderá una determinada distribución de probabilidad (del estadístico en el proceso de muestreo). Ejemplos de estadísticos son:

- La media muestral: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- La varianza muestral: $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

3. Distribuciones asociadas a un proceso de muestreo

Podemos considerar las siguientes distribuciones en relación con un proceso de muestreo.

- 1) Distribución correspondiente a la *población base*. O sea, distribución correspondiente al fenómeno aleatorio o variable aleatoria que se está estudiando. Suponemos una variable aleatoria X con función de distribución $F_x(x)$, o función de densidad $f_x(x)$.
- 2) Distribución *empírica* de una muestra determinada. Es la distribución de frecuencias correspondiente a un conjunto de observaciones. En ella estará contenida toda la *información* que pueda proporcionar la muestra sobre la distribución de X .
- 3) Distribución de la *muestra genérica* de tamaño n . Si el muestreo es probabilístico sabemos que podemos considerar $(X_1, X_2, \dots, X_n)$ como una variable aleatoria con una determinada distribución dada por una función de distribución $F(X_1, X_2, \dots, X_n)$ o por una función de densidad $f(X_1, X_2, \dots, X_n)$. Si el muestreo es aleatorio simple es:

$$F(x_1, x_2, \dots, x_n) = F_x(x_1)F_x(x_2) \dots F_x(x_n) = \prod_{i=1}^n F_x(x_i)$$

$$f(x_1, x_2, \dots, x_n) = f_x(x_1)f_x(x_2) \dots f_x(x_n) = \prod_{i=1}^n f_x(x_i)$$

Siendo $F_x(x)$ y $f_x(x)$ las funciones de distribución y de densidad de la variable aleatoria X que representa la población de donde se extraen las muestras. Si el muestreo no es aleatorio simple se determinarán estas distribuciones teniendo en cuenta determinadas distribuciones condicionadas.

- 4) Distribución correspondiente a un estadístico. Hemos definido un estadístico como una variable aleatoria función de la muestra genérica. Su distribución de probabilidad dependerá pues de la distribución de la muestra genérica. Es pues también una distribución de probabilidad asociada al proceso de muestreo.

Entre las distribuciones asociadas a un proceso de muestreo nos van a interesar especialmente las distribuciones de determinados estadísticos. Vamos a determinar algunas de estas distribuciones. En todo lo siguiente supondremos muestreo aleatorio simple. En la mayoría de los casos, según indicaremos, la población base la supondremos $N(\mu, \sigma)$.

4. Distribución de la media muestral

Cualquiera que sea la distribución de X , si el muestreo es aleatorio y es $E(X) = \mu$ y $D(X) = \sigma$, entonces, por la definición del estadístico media muestral será:

$$E(\bar{X}) = \frac{n\mu}{n} = \mu$$

$$D^2(\bar{X}) = \frac{n\sigma^2}{n^2} \Rightarrow D(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

Resumiendo:

$\mu_{\bar{X}} = \mu \quad \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$
--

Las propiedades anteriores son generales para un muestreo aleatorio simple y nos dicen que el valor medio de la media muestral es la media poblacional mientras que su desviación típica es la de la población dividida por la raíz cuadrada de n .

Otras propiedades generales de $\bar{X}$ en el muestreo aleatorio simple son las siguientes:

- Se deduce inmediatamente por aplicación de la desigualdad de Tchebycheff que la media muestral converge en probabilidad a la media poblacional:

$$\bar{X} \xrightarrow{P} \mu$$

En efecto, sabemos que se verifica:

$$P(|\bar{X} - \mu| > k) < \frac{D^2(\bar{X})}{k^2} = \frac{\sigma^2}{nk^2} \xrightarrow{n \rightarrow \infty} 0$$

- Por aplicación del teorema central del límite se deduce inmediatamente que:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{n \rightarrow \infty} N(0, 1)$$

5. El estadístico varianza muestral

La varianza de una muestra es:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

En general no es fácil determinar la distribución de S^2 en el caso de un muestreo aleatorio simple. Lo haremos cuando X es $N(\mu, \sigma)$. Pero podemos estudiar algunas características de S^2 .

Interesa calcular $E(S^2)$. Para ello ponemos S^2 en la forma siguiente:

$$\begin{aligned} S^2 &= \frac{1}{n-1} \sum_{i=1}^n [(X_i - \mu) - (\bar{X} - \mu)]^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n [(X_i - \mu)^2 + (\bar{X} - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu)] \\ &= \frac{1}{n-1} \left[\sum_{i=1}^n (X_i - \mu)^2 + n(\bar{X} - \mu)^2 - 2n(\bar{X} - \mu)^2 \right] \\ &= \frac{1}{n-1} \left[\sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \right] \end{aligned}$$

Tomando esperanzas:

$$E(S^2) = \frac{1}{n-1} \left[\sum_{i=1}^n E(X_i - \mu)^2 - nE(\bar{X} - \mu)^2 \right] = \frac{1}{n-1} \left[n\sigma^2 - n\frac{\sigma^2}{n} \right] = \sigma^2$$

Por tanto:

$$E(S^2) = \sigma^2$$

Esta expresión nos dice que el estadístico S^2 como *estimador* de σ^2 es *centrado*. Conviene resaltar la generalidad de esta expresión. Únicamente hemos tenido en cuenta que el muestreo es aleatorio simple cualquiera que sea la distribución de la variable aleatoria X .

6. Distribución Chi cuadrado de Pearson

Supongamos $X_1, X_2, \dots, X_n$ independientes y todas ellas con distribución $N(0, 1)$.

En relación con un muestreo aleatorio simple se presenta con frecuencia el tener que considerar la distribución de una variable aleatoria de la forma:

$$\chi_n^2 = \sum_{i=1}^n X_i^2$$

La distribución de χ_n^2 la determinamos inmediatamente teniendo en cuenta lo siguiente. Sabemos que si X_i es $N(0,1)$ entonces X_i^2 es $\gamma(1/2, 1/2)$. Si las X_i son independientes lo mismo lo son sus cuadrados, por tanto χ_n^2 es, por los teoremas de adición, $\gamma(n/2, 1/2)$. Su función de densidad será:

$$k_n(x) = \frac{1}{2^{n/2} \Gamma(n/2)} e^{-\frac{x}{2}} x^{n/2-1} \quad x \geq 0$$

A n , número de sumandos, se le denomina número de *grados de libertad* de χ_n^2 . Veremos el sentido de esta denominación.

La forma de esta distribución se ve en la Figura 1. Nótese que se trata de una variable no negativa y que la distribución está sesgada a la derecha. Cuando n aumenta la distribución se va haciendo simétrica y cuando $n \rightarrow \infty$ la distribución tiende a ser normal.




Figura 1. Forma de la distribución χ_n^2

Determinamos inmediatamente las características de χ_n^2 teniendo en cuenta que es una distribución $\gamma(n/2, 1/2)$:

$$E(\chi_n^2) = n, \quad D^2(\chi_n^2) = 2n$$

La función de distribución de χ_n^2 viene tabulada en los libros. Excel 2010 da dos fórmulas para calcular probabilidades con esta distribución (siempre que acumulado valga 1):

$= \text{DISTR.CHICUAD}(x; n; \text{acumulado})$	Devuelve la probabilidad $P(\chi_n^2 \leq x)$
$= \text{DISTR.CHICUAD.CD}(x; n; \text{acumulado})$	Devuelve la probabilidad $P(\chi_n^2 \geq x)$

Siendo x el valor de la variable, n los grados de libertad y acumulado vale 0 para dar el valor de la función de densidad y 1 para calcular probabilidades. Las letras CD de la segunda función provienen de cola derecha.

Del teorema de adición de la distribución gamma se deduce inmediatamente que una variable aleatoria como:

$$\chi_{n_1}^2 + \chi_{n_2}^2 + \cdots \chi_{n_r}^2$$

tiene una distribución:

$$\gamma\left(\frac{n}{2}, \frac{1}{2}\right) \quad \text{con} \quad \frac{n}{2} = \frac{n_1}{2} + \frac{n_2}{2} + \cdots + \frac{n_r}{2}$$

Es decir, con $n = n_1 + n_2 + \cdots + n_r$, por tanto con un número de grados de libertad igual a la suma de los libertad igual de los sumandos.

El **teorema de COCHRAN** es un importante recíproco del teorema de adición anterior. Lo enunciamos sin demostración:

Si una variable aleatoria X es de la forma:

$$X = \sum_{i=1}^n X_i$$

y se verifica que cada X_i es una $\chi_{n_i}^2$ con n_i grados de libertad, X es una χ_n^2 con n grados de libertad y además: $n = n_1 + n_2 + \cdots + n_r$, entonces las X_i son independientes.

Teniendo en cuenta la definición de la distribución χ_n^2 resultará, por el teorema central del límite que:

$$\chi_n^2 \xrightarrow{n \rightarrow \infty} N(n, \sqrt{2n})$$

en el sentido de que:

$$\frac{\chi_n^2 - n}{\sqrt{2n}} \xrightarrow{n \rightarrow \infty} N(0, 1)$$

7. Muestreo aleatorio simple de una distribución normal

Anteriormente determinamos que S^2 se puede poner en la forma:

$$S^2 = \frac{1}{n-1} \left[\sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \right]$$

De aquí obtenemos:

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 - \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2$$

De aquí podemos establecer la igualdad:

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2 + \frac{(n-1)S^2}{\sigma^2}$$

Conocemos que:

$$\frac{X_i - \mu}{\sigma} \text{ es } N(0,1) \Rightarrow \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \text{ es } \chi_n^2$$

Asimismo

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \text{ es } N(0,1) \Rightarrow \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2 \text{ es } \chi_1^2$$

El **teorema de Fisher** demuestra que:

$$\frac{nS^2}{\sigma^2} \text{ es } \chi_{n-1}^2 \text{ y no depende de } \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

Este teorema es una especie de *teorema inverso* de adición de la distribución χ^2 .

8. Distribución t de Student

Sean X y $X_1, X_2, \dots, X_n$ $n+1$ variables aleatorias independientes y todas ellas con distribución $N(0, 1)$.

Sea

$$Y = \sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2}$$

Definimos la variable aleatoria

$$t = \frac{X}{Y}$$

Teniendo en cuenta los recorridos de X y de Y es claro que t tiene recorrido $-\infty < t < +\infty$. A esta variable aleatoria se le denomina **t de Student**. Su función de densidad se denomina $s_n(t)$ y su expresión, que no demostramos, es:

$$s_n(t) = \frac{1}{\sqrt{n\pi}} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} \left(\frac{t^2}{n} + 1\right)^{-\frac{n+1}{2}} \quad -\infty < t < +\infty$$

Esta es la denominada *distribución t de Student con n grados de libertad*.

En la Figura 2 se muestran diferentes distribuciones t. La forma de la distribución t es similar a la de la distribución normal estándar; ambas distribuciones son simétricas, unimodales y con el máximo corresponde a la media $\mu = 0$. La distribución t tiene colas con mayor probabilidad. Conforme el número de grados de libertad tiende a infinito, la distribución t tiende a la distribución normal estándar.




Figura 2. Distribución t para varios grados de libertad

$s_n(t)$ es simétrica respecto del origen, por tanto:

$$E(t) = 0$$

Se demuestra que:

$$D^2(t) = \frac{n}{n-2}$$

La distribución t es una de las distribuciones más importantes en las aplicaciones. Su distribución está tabulada en distintas formas. Puede comprobarse que $s_n(t)$ tiende hacia una distribución $N(0, 1)$ cuando n crece.

Excel 2010 tiene tres fórmulas para esta distribución:

$= \text{DISTR.T. } 2C(x; n)$	Devuelve la probabilidad $P(t \geq x)$
$= \text{DISTR.T. } CD(x; n)$	Devuelve la probabilidad $P(t \geq x)$
$= \text{DISTR.T. } N(x; n)$	Devuelve la probabilidad $P(t \leq x)$

Siendo x el valor de la variable y n los grados de libertad.

Hemos supuesto las variables aleatorias X y cada $X_i \sim N(0, 1)$. El mismo resultado se obtiene si se suponen $N(0, \sigma)$. En efecto, si es así basta tener en cuenta que podemos poner:

$$t = \frac{X}{\sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2}} = \frac{\frac{X}{\sigma}}{\sqrt{\frac{1}{n} \sum_{i=1}^n \frac{X_i^2}{\sigma^2}}} =$$

Y las variables aleatorias X/σ y X_i/σ son ahora $N(0, 1)$. La distribución obtenida es por consiguiente una t de Student y no depende de σ .

9. Razón de Student

Al estudiar la distribución de S^2 hemos obtenido la descomposición:

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2 + \frac{(n-1)S^2}{\sigma^2}$$

Conocemos que los dos sumandos del segundo miembro son **independientes** y hemos obtenido que:

$$\frac{(n-1)S^2}{\sigma^2} \quad \text{es} \quad \chi_{n-1}^2$$

Si consideremos ahora una población $N(\mu, \sigma)$ se demuestra que el estadístico:

$$t = \frac{\bar{X} - \mu}{S} \sqrt{n}$$

tiene una distribución de Student con $n - 1$ grados de libertad. Al estadístico t así definido se le denomina **razón de Student** y es fundamental en el estudio de la inferencia de una po-

blación $N(\mu, \sigma)$. Es importante fijarse en que está definido en función de la muestra genérica y de μ pero *no depende de σ* .

10. Distribución F de Snedecor

Supongamos $m + n$ variables aleatorias independientes $X_1, X_2, \dots, X_m$ e $Y_1, Y_2, \dots, Y_n$ todas ellas $N(0, 1)$. A partir de ellas consideramos las variables aleatorias (medias cuadráticas):

$$X = \frac{1}{m} \sum_{i=1}^m X_i^2 \quad Y = \frac{1}{n} \sum_{i=1}^n Y_i^2$$

Conocemos que mX es χ_m^2 . Análogamente nY será χ_n^2 . Definimos la variable aleatoria F de Snedecor en la forma:

$$F = \frac{X}{Y}$$

Conviene notar que F también se puede definir como el cociente de dos variables aleatorias independientes siendo el numerador una chi-cuadrado con m grados de libertad dividida por m y el denominador una chi-cuadrado con n grados de libertad dividida por n .

Se demuestra que la función de densidad de F es:

$$f(x) = \left(\frac{m}{n}\right)^{\frac{m}{2}} \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} x^{\frac{m}{2}-1} \left(\frac{m}{n}x + n\right)^{-\frac{m+n}{2}} \quad x \geq 0$$

Se dice que x tiene una distribución F de Snedecor con m *grados de libertad en el numerador* y n *en el denominador*.

Excel 2010 tiene dos funciones para calcular probabilidades con distribución F:

$= \text{DISTR.F.CD}(x; m; n)$	Devuelve la probabilidad $P(X \geq x)$
$= \text{DISTR.F.N}(x; m; n)$	Devuelve la probabilidad $P(X \leq x)$

Siendo x un valor, m el número de grados de libertad del numerador y n el número de grados de libertad del denominador.

La distribución F está tabulada en función de los parámetros m y n . Sus características son:

$$E(F) = \frac{n}{n-2} \quad D^2(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}$$

Estas fórmulas no suelen emplearse. El empleo de F es a partir de las tablas.

Veamos ahora la aplicación de F en el muestreo. Supongamos dos muestras de tamaño m y n , de dos poblaciones $N(\mu_x, \sigma)$ y $N(\mu_y, \sigma)$ respectivamente. O sea, dos poblaciones normales con la misma varianza aunque puedan tener medias diferentes. A partir de cada una de las muestras formamos los estadísticos S_x^2 y S_y^2 . Si formamos el cociente:

$$F = \frac{S_x^2}{S_y^2} = \frac{S_x^2/\sigma^2}{S_y^2/\sigma^2}$$

Se demuestra inmediatamente que F tiene una distribución F con $(m - 1)$ grados de libertad en el numerador y $(n - 1)$ en el denominador.

11. Estadísticos de orden

Supongamos una muestra de tamaño n : $(x_1, x_2, \dots, x_n)$. A partir de ella, ordenando sus valores de menor a mayor, podemos formar la correspondiente muestra ordenada que escribiremos en la forma: $(x_{(1)}, x_{(2)}, \dots, x_{(n)})$. Para esta muestra ordenada se verifica $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. A partir de este concepto podemos introducir el estadístico n -dimensional $[X_{(1)}, X_{(2)}, \dots, X_{(n)}]$ al que denominamos *nuestra ordenada genérica*. Para esta muestra definimos los siguientes conceptos:

- *Estadístico de orden K* es el estadístico que corresponde a la k -ésima componente de la muestra ordenada.
- *Mínimo muestral*: es el estadístico menor observación de la muestra: $X_{(1)}$. Lo denominaremos S .
- *Máximo muestral*: es el estadístico mayor observación de la muestra: $X_{(n)}$. Lo denominaremos T .
- *Recorrido*, rango o amplitud muestral: es la diferencia entre el máximo y el mínimo muestrales $R = X_{(n)} - X_{(1)} = T - S$.

Los tres últimos son los estadísticos más importantes de los que pueden definirse a partir de la muestra ordenada. Vamos a estudiar sus distribuciones.

A modo de ejemplo, la distribución de $X_{(n)}$ tiene aplicación en el estudio de la capacidad que debe tener una presa o el máximo de agua que puede llover en una región durante un período de tiempo determinado. Análogamente la distribución de $X_{(1)}$ en el estudio de períodos de sequía.

Seguidamente estudiamos la distribución del mínimo y del máximo muestral. La del recorrido suele ser compleja y se emplea menos en la práctica.

11.1. Distribución del mínimo muestral

Supongamos que la población X tiene distribución con función de distribución $F_x(x)$. Tratamos de determinar $F_s(s) = P(S \leq s)$. Es más fácil calcular la probabilidad del suceso

$\{S > s\}$ ya que este suceso sólo puede ocurrir de una forma: cuando todos los valores muestrales están a la derecha de X . Podemos determinar fácilmente:

$$P(S > s) = P(X_1 > s, X_2 > s, \dots, X_n > s) = \prod_{i=1}^n P(X_i > s) = [1 - F_x(s)]^n$$

$$F_s(s) = P(S \leq s) = 1 - [1 - F_x(s)]^n$$

Si la distribución de X es continua con función de densidad $f_x(x)$, podemos determinar:

$$f_s(s) = \frac{d}{ds} \{1 - [1 - F_x(s)]^n\} = n f_x(s) [1 - F_x(s)]^{n-1}$$

Evidentemente, el recorrido de valores de S es el mismo que el de la población X .

11.2. Distribución del máximo muestral

Tratemos de determinar ahora $F_t(t) = P(T \leq t)$. El suceso $\{T \leq t\}$ implica que todos los valores muestrales están a la izquierda de t . Por tanto:

$$F_t(t) = P(T \leq t) = P(X_1 \leq t, X_2 \leq t, \dots, X_n \leq t) = \prod_{i=1}^n P(X_i \leq t) = [F_x(t)]^n$$

Con lo cual la distribución de T queda determinada *directamente* con facilidad.

Si la distribución de X es de tipo continuo con función de densidad $f_t(t)$, a partir de lo anterior determinamos:

$$f_t(t) = \frac{d}{dt} [F_x(t)]^n = n f_x(t) [F_x(t)]^{n-1}$$

Al igual que en el caso del mínimo muestral, el recorrido de T es el mismo que el de la población X .

11.3. Distribución conjunta del mínimo y del máximo muestral

No tenemos garantía de que S y T sean variables aleatorias independientes sino todo lo contrario. Por ejemplo, si S toma un valor grande cabe esperar que T lo tome también grande.

Vamos a calcular la función de distribución:

$$F(s, t) = P(S \leq s, T \leq t)$$

Para determinar esta probabilidad tenemos en cuenta que podemos poner, en forma simplificada:

$$\{T \leq t\} = \{S > s, T \leq t\} + \{S \leq s, T \leq t\}$$

O sea, el suceso $\{T \leq t\}$ podemos considerarlo en dos formas mutuamente excluyentes (disjuntas). Tomando probabilidades deducimos:

$$F_t(t) = P(s < X_1, X_2, \dots, X_n \leq t) + F(s, t)$$

De aquí:

$$\begin{aligned} F(s, t) &= F_t(t) - P(s < X_1, X_2, \dots, X_n \leq t) = [F_x(t)]^n - \prod_{i=1}^n P(s < X_i \leq t) = \\ &= [F_x(t)]^n - [F_x(t) - F_x(s)]^n \end{aligned}$$

Si la distribución de X es *continua*, se tendrá:

$$f(s, t) = \frac{\partial^2 F(s, t)}{\partial s \partial t} = n(n-1)f_x(s)f_x(t)[F_x(t) - F_x(s)]^{n-2} \quad s \leq t$$

12. Problemas

8-1. Una empresa se dedica a la fabricación y comercialización de un solo artículo. Dispone para ello de una máquina que los fabrica en lotes de 3 unidades. De cada lote se manda la mejor unidad al almacén A, la siguiente al B y la peor al C.

Para saber cuál es la mejor el fabricante ha elaborado un índice de calidad que es función de varias características del producto, de manera que a cada unidad se le asigna un valor de este índice, el cual puede considerarse como una variable aleatoria con distribución uniforme en $[0, 1]$. Lógicamente, una pieza es mejor que otra si su índice de calidad es mejor. Se supone que los índices de calidad de las piezas de un mismo lote son independientes entre sí.

- ¿Cuál es la probabilidad de que una unidad del almacén A tenga un índice de calidad superior a 0.5? ¿Cuál es el índice de calidad medio de las unidades del almacén A?
- Contestar las mismas preguntas para el almacén C.
- ¿Cuál es la probabilidad de que una unidad, tomada al azar, del almacén A, sea de menor calidad que otra, también tomada al azar, del almacén C?
- ¿Cuál es el índice de calidad medio del almacén B?

Solución: a) Probabilidad: 0.875, Índice de calidad: 0.75, b) Probabilidad: 0.125, Índice de calidad: 0.25, c) 0.05, d) 0.5.

8-2. La función de densidad de la nota que saca un alumno, elegido al azar, en los exámenes de selectividad viene dada por:


$$f_x(x) = \frac{x}{50} \quad 0 \leq x \leq 10$$

Se forman grupos de 100 alumnos que son examinados por diferentes tribunales. Determinar:

- Función de densidad de la nota que saca el peor alumno de cada grupo.
- Función de densidad de la nota que saca el alumno mejor de cada grupo.
- ¿Cuál es la probabilidad de que apruebe el alumno peor de cada grupo?

Solución: $f_s(s) = 2 \cdot 100^{-99} s(1 - s^2)^{99}$ para $0 \leq s \leq 10$, b) $f_t(t) = 2 \cdot 100^{-99} t^{199}$ para $0 \leq t \leq 10$, c) $3.207 \cdot 10^{-13}$.

8-3. El sistema de componentes electrónicos de la figura funcionará en tanto que funcione el componente C_1 y al menos uno de los componentes C_2 y C_3 . Sea X_i el tiempo de vida del componente C_i ($i = 1, 2, 3$). Se sabe que estos tiempos de vida son variables aleatorias independientes con distribución exponencial de media 1.



Sea $Y = \max(X_2, X_3)$ y $Z = \min(X_1, Y)$. Entonces Z es el tiempo de vida del sistema de la figura.

- Encontrar la distribución de Z .
- Calcular el tiempo de vida media del sistema, $E(Z)$ así como la varianza $D^2(Z)$.

Solución: a) $f_z(z) = 4e^{-2z} - 3e^{-3z}$ $z \geq 0$, b) $E(Z) = \frac{2}{3}$, $D^2(Z) = \frac{1}{3}$

8-4. Se efectúa un proceso de muestreo aleatorio simple con muestras de tamaño n de una población X con función de densidad $f_x(x)$. Calcular el valor medio de la probabilidad de que $X \leq S$, siendo S el mínimo muestral.

Solución: $\frac{1}{1+n}$.

8-5. Sea X una variable aleatoria $N(\mu, \sigma)$. Encuéntrese el valor esperado de la mayor de las variables (máximo muestral) en una muestra aleatoria simple de tamaño 2.

Solución: $E(T) = \mu + \frac{\sigma}{\sqrt{\pi}}$

8-6. En un proceso de muestreo aleatorio simple de una población $N(0, 1)$ con muestras de tamaño 2, dedúzcase la distribución de la variable aleatoria “recorrido muestral”. Identificar el tipo de distribución que tiene.

Solución: $f_r(r) = \frac{1}{\sqrt{\pi}} e^{-\frac{r^2}{2}} \quad r \geq 0$. Se trata de una distribución $\gamma\left(\frac{1}{2}, \frac{1}{4}, 2\right)$

8-7. Se realiza un proceso de muestreo aleatorio simple con muestras de tamaño n de una población representada por una variable aleatoria X con función de densidad:

$$f_x(x) = e^{-x} \quad x \geq 0$$

Se considera la variable aleatoria (S, T) siendo S el mínimo y T el máximo muestral.

- Dedúzcase la distribución conjunta $f(s, t)$.
- Determinar a partir de $f(s, t)$ las distribuciones marginales de S y T .
- Comprobar los resultados obtenidos en el apartado b) deduciéndolos por otro método.
- ¿Qué tipo de distribución tiene el mínimo muestral? Calcular su valor medio y su varianza.

Solución: a) $f(s, t) = n(n-1)e^{-(s+t)}(e^{-s} - e^{-t}) \quad 0 \leq s \leq t$, b) $f_s(s) = ne^{-ns} \quad s \geq 0$, $f_t(t) = ne^{-t}(1 - e^{-t})^{n-1} \quad t \geq 0$ c) Aplicar las fórmulas directas de obtención de las distribuciones del mínimo y máximo muestrales, d) $E(S) = \frac{1}{n}, D^2(S) = \frac{1}{n^2}$