

Capítulo 9

Estimación de parámetros por puntos

(Revisión 01/2012)

1. Estimación por puntos	1
2. Estimadores centrados. Sesgo de un estimador	2
3. Estimadores consistentes	3
4. Varianza de un estimador.....	5
4.1. Eficiencia de un estimador	6
4.2. Acotación de la varianza de un estimador: desigualdad de Cramer-Rao	6
4.3. Determinación de la cantidad de información	8
4.4. Error estándar: información sobre la calidad de la estimación por puntos	12
5. Suficiencia. Criterio de Neyman-Fisher	12
6. Métodos de obtención de estimadores	13
6.1. Método de los momentos.....	13
6.2. Método de máxima verosimilitud	14
6.3. Complicaciones en el uso del método de máxima verosimilitud	17
6.4. Optimización computacional de la función de verosimilitud	18
7. Problemas.....	19

Después de un estudio en profundidad de este capítulo, el estudiante deberá ser capaz de:

- Entender lo que es un estimador de un parámetro poblacional.
- Explicar las propiedades de los estimadores: sesgo, varianza, etc.
- Construir estimadores usando el método de los momentos y el método de máxima verosimilitud.
- Calcular y explicar la precisión con que se estima un parámetro.

1. Estimación por puntos

La inferencia estadística trata, entre otros problemas, de sacar conclusiones sobre uno o más parámetros de la población. Una parte importante de este proceso consiste en obtener estimaciones de los parámetros. Supongamos que queremos obtener una **estimación por punto** (un valor razonable) de un parámetro de la población. Como sabemos, antes de recoger datos, las observaciones se consideran variables, a decir $X_1, X_2, \dots, X_n$. Por tanto, cualquier función de la observación, o cualquier **estadístico**, es también una variable aleatoria. Por ejemplo, la media muestral $\bar{X}$ y la varianza muestral S^2 son estadísticos y son también variables aleatorias.

Al ser una variable aleatoria, un estadístico tiene una distribución de probabilidad. A la distribución de probabilidad de un estadístico se denomina distribución de muestreo.

Para discutir problemas de inferencia, es conveniente tener un símbolo general que represente el parámetro de interés. Utilizaremos el símbolo θ para representar el parámetro: este símbolo puede representar la media μ , la varianza σ^2 o cualquier parámetro de interés para nosotros. El objetivo de la estimación por puntos es seleccionar un único número, basado en los datos de la muestra, que es el valor más plausible de θ .

En general, si X es una variable aleatoria con distribución de probabilidad $f(x)$ caracterizada por un parámetro desconocido θ , y si $X_1, X_2, \dots, X_n$ es una muestra aleatoria de tamaño n obtenida de la población representada por la variable aleatoria X , el estadístico:

$$\Theta = H(X_1, X_2, \dots, X_n)$$

se llama un estimador por punto de θ . Nótese que Θ es una variable aleatoria porque es función de variables aleatorias. Después de obtener una muestra, Θ toma un determinado valor numérico llamado **estimación por punto** de θ .

Una **estimación por punto** de un parámetro poblacional θ es un valor numérico $\hat{\theta}$ de un estadístico Θ . El estadístico Θ se llama **estimador por punto**.

Por poner un ejemplo, supongamos que la variable X tiene una distribución normal con media desconocida μ . La media muestral es un estimador por puntos de la media poblacional desconocida μ , esto es, $\hat{\mu} = \bar{X}$. En consecuencia, si extraemos la muestra $x_1 = 2.7, x_2 = 2.6, x_3 = 3.1, x_4 = 2.8$, la estimación por puntos de μ es:

$$\bar{x} = \frac{2.7 + 2.6 + 3.1 + 2.8}{4} = 2.8$$

De igual forma, si la varianza de la población σ^2 también es desconocida, un estimador por puntos de σ^2 es la varianza muestral S^2 . Para la muestra anterior resulta $S^2 = 0.035$ que será la estimación por puntos de σ^2 .

En ingeniería es frecuente encontrarse con problemas de estimación. Así, a menudo es necesario estimar:

- La media μ de una población.
- La varianza σ^2 de una población.
- La proporción de artículos p de una población que pertenece a una determinada clase
- La diferencia de medias $\mu_1 - \mu_2$ de dos poblaciones.
- La diferencia de proporciones $p_1 - p_2$ en dos poblaciones.

Estimaciones razonables de estos parámetros son:

- Para μ , la media muestral $\hat{\mu} = \bar{X}$.
- Para σ^2 , la varianza muestral $\hat{\sigma}^2 = S^2$
- Para p , la proporción de la muestra $\hat{p} = x/n$, donde x es el número de artículos en una muestra aleatoria de tamaño n que pertenecen a la clase de interés.
- Para $\mu_1 - \mu_2$, la diferencia entre las medias muestrales de dos muestras aleatorias independientes $\hat{\mu}_1 - \hat{\mu}_2 = \bar{x}_1 - \bar{x}_2$.
- Para $p_1 - p_2$, la diferencia entre proporciones de dos muestras aleatorias independientes.

En ocasiones dispondremos de varios estimadores de un mismo parámetro. Para poder elegir es necesario estudiar sus propiedades estadísticas y desarrollar algunos criterios de comparación de estimadores.

2. Estimadores centrados. Sesgo de un estimador

Diremos que un estimador $\hat{\theta}$ de un parámetro θ es un estimador centrado cuando:

$$E(\hat{\theta}) = \theta$$

Cuando el estimador no es centrado, a la diferencia:

$$E(\hat{\theta}) - \theta$$

Se le denomina **sesgo** del estimador $\hat{\theta}$.

Evidentemente siempre interesa que el estimador sea centrado: un estimador no centrado siempre comete un error “sistemático” en la estimación y este error es su sesgo. Se puede decir que un estimador no centrado es como una escopeta que cuando se apunta a un blanco, sus impactos tienden a estar siempre en una determinada dirección a una distancia del blanco.

Ejemplo. Supongamos que X es una variable aleatoria con media μ y varianza σ^2 desconocidas. Sea $(X_1, X_2, \dots, X_n)$ una muestra aleatoria de tamaño n de la población representada por X . Demostrar que la media muestral $\bar{X}$ y la varianza muestral S^2 son estimadores centrados de μ y σ^2 respectivamente.

Tendremos:

$$E(\bar{X}) = E\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \frac{1}{n}(\mu + \mu + \dots \mu) = \mu$$

Por otra parte:

$$\begin{aligned} E(S^2) &= E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n-1} E\left[\sum_{i=1}^n [(X_i - \mu) - (\bar{X} - \mu)]^2\right] \\ &= \frac{1}{n-1} E\left[\sum_{i=1}^n [(X_i - \mu)^2 + (\bar{X} - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu)]\right] \\ &= \frac{1}{n-1} E\left[\sum_{i=1}^n (X_i - \mu)^2 + n(\bar{X} - \mu)^2 - 2n(\bar{X} - \mu)^2\right] \\ &= \frac{1}{n-1} E\left[\sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2\right] = \frac{1}{n-1} \left(n\sigma^2 - n\frac{\sigma^2}{n}\right) = \sigma^2 \end{aligned}$$

Si un estimador no es centrado, se puede obtener a partir de él uno que sí lo sea, haciendo la transformación correspondiente.

3. Estimadores consistentes

Un estimador es una función de la muestra genérica. Por tanto, dependerá del tamaño, n , de la muestra. Explícitamente podemos escribir un estimador como θ_n . Por tanto, dado un estimador de cualquier tipo, podemos considerar la *sucesión* correspondiente de estimadores en función de n .

La propiedad de consistencia (Fisher, 1922) se refiere a una propiedad de esta sucesión. θ_n se dice consistente cuando θ_n *converge en probabilidad* a θ , o sea cuando:

$$\theta_n \xrightarrow{P} \theta \Leftrightarrow \lim_{n \rightarrow \infty} P[|\theta_n - \theta| > \varepsilon] = 0 \Leftrightarrow \lim_{n \rightarrow \infty} P[\theta - \varepsilon < \theta_n < \theta + \varepsilon] = 1, \quad \varepsilon > 0 \text{ fijo}$$




Figura 1. El área sombreada tiende a uno cuando n crece

Como vemos, esta propiedad de consistencia es de tipo asintótico. Será de importancia cuando se empleen *muestras grandes* para estimar a θ . No tendrá tanta importancia cuando las muestras hayan de ser necesariamente pequeñas.

El teorema de Tchebycheff da una **condición suficiente de consistencia** para estimadores contratados. Si θ_n es centrado para θ y $D^2(\theta_n)$ tiende a cero cuando n tiende a infinito entonces θ_n es consistente.

En efecto, por el teorema de Tchebycheff conocemos que:

$$P[|\theta_n - \theta| > \varepsilon] \leq \frac{D^2(\theta_n)}{\varepsilon^2}$$

Por tanto es suficiente que:

$$D^2(\theta_n) \xrightarrow{n \rightarrow \infty} 0 \quad \text{para que} \quad P[|\theta_n - \theta| > \varepsilon] \xrightarrow{n \rightarrow \infty} 0$$

Ejemplos de estimadores consistentes:

- $\bar{X}$ es un estimador consistente de μ . Pues:

$$E(\bar{X}) = \mu \quad \text{y conocemos que} \quad D^2(\bar{X}) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$$

- Sea un suceso A en una serie de pruebas de Bernoulli con $P(A) = p$. Consideremos la frecuencia relativa (es decir, la media muestral) de A en n pruebas como estimador de p :

$$E(\bar{X}) = \frac{np}{n} = p \quad y \quad D^2(\bar{X}) = \frac{D^2(X)}{n} = \frac{pq}{n} \xrightarrow{n \rightarrow \infty} 0$$

Teniendo en cuenta la condición suficiente de consistencia, es un estimador consistente.

- S^2 es consistente para σ^2 en el caso de una *población normal*. Sabemos que S^2 es centrado y hemos estudiado la distribución de S^2 que es:

$$\gamma\left(\frac{n-1}{2}, \frac{n-1}{2\sigma^2}\right)$$

por tanto:

$$D^2(S^2) = \frac{n-1}{2} \times \frac{4\sigma^4}{(n-1)^2} = \frac{2\sigma^2}{n-1} \xrightarrow{n \rightarrow \infty} 0$$

luego cumple la condición suficiente de consistencia.

4. Varianza de un estimador

Supongamos dos estimadores centrados de un mismo parámetro: $\hat{\theta}_1$ y $\hat{\theta}_2$. Esto indica que la distribución de cada estimador está centrada en el verdadero valor de θ . La Figura 2 ilustra esta situación. Puesto que $\hat{\theta}_1$ tiene una menor varianza que $\hat{\theta}_2$, el estimador $\hat{\theta}_1$ dará con mayor probabilidad una estimación más cercana al verdadero valor de θ . Evidentemente, una regla de estimación es seleccionar de varios estimadores centrados de un mismo parámetro aquél con menor varianza.




Figura 2. Distribuciones de dos estimadores centrados $\hat{\theta}_1$ y $\hat{\theta}_2$

4.1. Eficiencia de un estimador

Dados dos estimadores centrados de un mismo parámetro θ , $\hat{\theta}_1$ y $\hat{\theta}_2$, diremos que $\hat{\theta}_1$ es más eficiente que $\hat{\theta}_2$ si:

$$D^2(\hat{\theta}_1) \leq D^2(\hat{\theta}_2)$$

Evidentemente, el concepto de eficiencia es un concepto relativo. Está claro que lo ideal es un estimador que sea centrado y además tenga la menor varianza posible. A un estimador de este tipo se denomina estimador de mínima varianza o máximamente eficiente.

4.2. Acotación de la varianza de un estimador: desigualdad de Cramer-Rao

Hemos visto que para estimadores centrados se mide la eficiencia teniendo en cuenta el cociente de las varianzas. Tiene interés determinar, si es posible, una **cota inferior** para la varianza de un estimador. Si sabemos que para un estimador su varianza es igual a esta cota resultará que será de **máxima eficiencia**. Si no lo es, su diferencia respecto de esta cota nos puede dar una idea de su eficiencia. Vamos a ver que es posible determinar una cota de este tipo.

Supongamos una variable aleatoria X con función de densidad $f_x(x) = f_x(x; \theta)$ dependiente de un cierto parámetro θ . Supongamos un proceso de muestreo probabilístico (aleatorio) con muestras de tamaño n . A la muestra genérica $(X_1, X_2, \dots, X_n)$ le corresponderá una distribución de probabilidad que, en general, dependerá también del parámetro θ . A su función de densidad la vamos a denominar:

$$L(x_1, x_2, \dots, x_n; \theta) = L(\vec{x}; \theta), \quad \vec{x} = (x_1, x_2, \dots, x_n)$$

Fijémonos en la función $\ell(\vec{x}; \theta)$. Depende tanto de $\vec{x}$ como de θ . Si suponemos θ un parámetro con un determinado valor para una determinada distribución particular la función $L(\vec{x}; \theta)$ es efectivamente la función de densidad de la muestra genérica $\vec{x}$. Pero podemos considerarla también como función de θ . Entonces para un determinado valor de $\vec{x}$, dada una muestra determinada, $L(\vec{x}; \theta)$ es una función del parámetro. En este sentido la consideró Fisher y le denominó **función de verosimilitud** del parámetro. De aquí le viene la denominación con L . Se emplea la misma denominación tanto cuando se la considera en un sentido como cuando se la considera en otro, o cuando se la considera función tanto de $\vec{x}$ como de θ .

En el caso de que el muestreo sea aleatorio simple:

$$L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f_x(x_i; \theta)$$

Consideremos un estimador θ^* de θ : $\theta^* = g(X_1, X_2, \dots, X_n)$. Conocemos que

$$\int L(\vec{x}; \theta) d\vec{x} = 1$$

En general, el estimador θ^* no será centrado. Si denominamos con $b(\theta)$ el sesgo será:

$$E(\theta^*) = \int \theta^* L(\vec{x}; \theta) d\vec{x} = \theta + b(\theta)$$

Si L es una función continua y derivable respecto de θ podemos derivar respecto de θ las dos expresiones anteriores obteniendo:

$$\int \frac{\partial L}{\partial \theta} d\vec{x} = 0$$

$$\int \theta^* \frac{\partial L}{\partial \theta} d\vec{x} = 1 + b.(\theta)$$

Consideramos ahora la siguiente función a partir de L :

$$t = t(\vec{x}; \theta) = \frac{\partial \ln L}{\partial \theta} = \frac{1}{L} \frac{\partial L}{\partial \theta}$$

Vamos a ver algunas propiedades de esta función (la consideramos como función de $\vec{x}$). Se tendrá:

$$E(t) = E\left(\frac{1}{L} \frac{\partial L}{\partial \theta}\right) = \int \frac{1}{L} \frac{\partial L}{\partial \theta} \ell d\vec{x} = \int \frac{\partial L}{\partial \theta} d\vec{x} = 0$$

Entonces:

$$D^2(t) = E(t^2) = E\left(\frac{\partial \ln L}{\partial \theta}\right)^2$$

Veamos ahora el valor de $cov(\theta^*, t)$:

$$cov(\theta^*, t) = E\{[\theta^* - E(\theta^*)] \cdot t\} = E[\theta^* t - E(\theta^*) t] = E(\theta^* t) - E(\theta^*) E(t)$$

Cómo $E(t) = 0$:

$$cov(\theta^*, t) = E(\theta^* t) = \int \theta^* t L d\vec{x} = \int \theta^* \frac{1}{L} \frac{\partial L}{\partial \theta} \ell d\vec{x} = \int \theta^* \frac{\partial L}{\partial \theta} d\vec{x} = 1 + b.(\theta)$$

Además, por la acotación del coeficiente de correlación podemos poner:

$$\rho^2(\theta^*, t) = \frac{cov^2(\theta^*, t)}{D^2(\theta^*) D^2(t)} \leq 1 \quad \Rightarrow \quad D^2(\theta^*) \geq \frac{cov^2(\theta^*, t)}{D^2(t)}$$

Resultando:

$$D^2(\theta^*) \geq \frac{[1 + b.(\theta)]^2}{E\left(\frac{\partial \ln L}{\partial \theta}\right)^2}$$

Esta expresión se conoce como **acotación de Cramer-Rao**.

Cuando θ^* es centrado el numerador de anterior queda reducido a 1, y la desigualdad toma la forma:

$$D^2(\theta^*) \geq \frac{1}{E\left(\frac{\partial \ln L}{\partial \theta}\right)^2}$$

Vemos que la cota de Cramer-Rao para un estimador θ^* cualquiera de θ disminuye cuando aumenta la cantidad:

$$I = E\left(\frac{\partial \ln L}{\partial \theta}\right)^2$$

Se ve que esta cantidad está comprendida entre: $0 < I < +\infty$. Si fuese $I = +\infty$ es claro que la cota de Cramer-Rao queda reducida a cero y la distribución de θ^* sería degenerada: θ^* podría tomar un solo valor que sería el de θ . Cuando fuese $I = 0$ la cota es $+\infty$ lo que supone una distribución θ^* *absolutamente dispersa*.

Esta relación inversa entre I y $D^2(\theta^*)$ indujo a Fisher a denominar a I **cantidad de información** respecto del parámetro θ contenida en la muestra. Vemos que el *mínimo valor* que puede tomar la varianza de un estimador θ^* de θ es:

$$D^2(\theta^*) \geq \frac{[1 + b.(\theta)]^2}{I} \quad \text{si el estimador no es centrado}$$

$$D^2(\theta^*) \geq \frac{1}{I} \quad \text{si el estimador es centrado}$$

Se denomina **estimador de mínima varianza o estimador eficiente** a un estimador *centrado* y tal que su varianza es igual a la cota de Cramer-Rao:

$$D^2(\theta^*) = \frac{1}{I}$$

4.3. Determinación de la cantidad de información

Se va a deducir ahora distintas expresiones que facilitan el cálculo de la cantidad de información. Sabemos que es:

$$\int L(\vec{x}; \theta) d\vec{x} = 1$$

Como $\frac{\partial L}{\partial \theta} = \frac{\partial \ln L}{\partial \theta} L$, si derivamos respecto de θ , queda:

$$\int \frac{\partial L}{\partial \theta} d\vec{x} = 0 \quad \Rightarrow \quad \int \frac{\partial \ln L}{\partial \theta} L d\vec{x} = 0$$

Derivando aquí de nuevo

$$\int \left(\frac{\partial \ln L}{\partial \theta} \frac{\partial L}{\partial \theta} + \frac{\partial^2 \ln L}{\partial \theta^2} L \right) d\vec{x} = 0$$

De aquí:

$$\int \left[\left(\frac{\partial \ln L}{\partial \theta} \right)^2 + \frac{\partial^2 \ln L}{\partial \theta^2} \right] L d\vec{x} = 0$$

Por tanto:

$$E \left(\frac{\partial \ln L}{\partial \theta} \right)^2 + E \left(\frac{\partial^2 \ln L}{\partial \theta^2} \right) = 0 \quad \Rightarrow \quad E \left(\frac{\partial \ln L}{\partial \theta} \right)^2 = -E \left(\frac{\partial^2 \ln L}{\partial \theta^2} \right)$$

Evidentemente, cómo $f_x(x; \theta)$ es también una función de densidad, resultará:

$$E \left(\frac{\partial \ln f_x(x; \theta)}{\partial \theta} \right)^2 = -E \left(\frac{\partial^2 \ln f_x(x; \theta)}{\partial \theta^2} \right)$$

En resumen, la cantidad de información resulta ser:

$$I = E \left(\frac{\partial \ln L}{\partial \theta} \right)^2 = -E \left(\frac{\partial^2 \ln L}{\partial \theta^2} \right)$$

Nos interesa ahora obtener las fórmulas equivalentes en el caso de que el muestreo sea aleatorio simple. Se tendrá:

$$L(\vec{x}; \theta) = \prod_{i=1}^n f_x(x_i; \theta) \quad \Rightarrow \quad \ln L = \sum_{i=1}^n \ln f_x(x_i; \theta) \quad \Rightarrow \quad \frac{\partial^2 \ln L}{\partial \theta^2} = \sum_{i=1}^n \frac{\partial^2 \ln f_x(x_i; \theta)}{\partial \theta^2}$$

Entonces:

$$I = -E \left(\frac{\partial^2 \ln L}{\partial \theta^2} \right) = -E \left(\sum_{i=1}^n \frac{\partial^2 \ln f_x(x_i; \theta)}{\partial \theta^2} \right) = -nE \left(\frac{\partial^2 \ln f_x(x; \theta)}{\partial \theta^2} \right)$$

Y por lo demostrado anteriormente:

$$I = -E \left(\sum_{i=1}^n \frac{\partial^2 \ln f_x(x_i; \theta)}{\partial \theta^2} \right) = nE \left(\frac{\partial \ln f_x(x; \theta)}{\partial \theta} \right)^2$$

De esta expresión deducimos inmediatamente que la cantidad de información respecto de un parámetro contenida en una muestra aumenta, cuando aumenta el tamaño n de la muestra.

Es importante tener en cuenta que todos estos resultados son válidos tanto cuando la distribución es continua, caso que hemos supuesto, como cuando es *discreta*. Entonces $f_x(x; \theta)$ es la función de probabilidad: $f_x(x; \theta) = P(X = x; \theta)$.

Veamos algunos ejemplos de estimadores eficientes:

- Supongamos que X es $N(\mu, \sigma)$ con σ conocido y $\bar{X}$ como estimador de μ . Sabemos que:

$$E(\bar{X}) = \mu \quad D^2(\bar{X}) = \frac{\sigma^2}{n}$$

Conocemos que $I = nE\left(\frac{\partial \ln f_x(x; \theta)}{\partial \theta}\right)^2$. En este caso es:

$$f_x(x; \mu) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \Rightarrow \ln f_x(x; \mu) = -\ln(\sigma\sqrt{2\pi}) - \frac{(x-\mu)^2}{2\sigma^2}$$

$$\frac{\partial \ln f_x(x; \mu)}{\partial \mu} = \frac{x - \mu}{\sigma^2}$$

Luego,

$$I = nE\left(\frac{\partial \ln f_x(x; \mu)}{\partial \mu}\right)^2 = nE\left(\frac{x - \mu}{\sigma^2}\right)^2 = \frac{n}{\sigma^4} E(x - \mu)^2 = \frac{n}{\sigma^4} \sigma^2 = \frac{n}{\sigma^2}$$

De aquí:

$$\frac{1}{I} = \frac{\sigma^2}{n} = D^2(\bar{X})$$

Por lo tanto $\bar{X}$ es un estimador de mínima varianza de μ .

- Supongamos una serie de pruebas de Bernoulli y $\bar{X}$ como estimador de p . En este caso la distribución que muestreamos es de Bernoulli: $B(1, p)$ y $\bar{X}$ corresponde a la frecuencia relativa del número de éxitos. Para este estimador conocemos:

$$E(\bar{X}) = p \quad D^2(\bar{X}) = \frac{p(1-p)}{n} = \frac{\sigma^2}{n}$$

En este caso la distribución de X es discreta con función de probabilidad:

$$f_x(x; p) = \begin{cases} 1-p & x=0 \\ p & x=1 \end{cases} \quad \ln f_x(x; p) = \begin{cases} \ln(1-p) & x=0 \\ \ln p & x=1 \end{cases}$$

$$\frac{\partial \ln f_x(x; p)}{\partial p} = \begin{cases} -\frac{1}{1-p} & x=0 \\ \frac{1}{p} & x=1 \end{cases}$$

De aquí podemos calcular:

$$E\left(\frac{\partial \ln f_x(x; p)}{\partial p}\right)^2 = \left(-\frac{1}{1-p}\right)^2 (1-p) + \left(\frac{1}{p}\right)^2 p = \frac{1}{p} + \frac{1}{p} = \frac{p+q}{pq} = \frac{1}{pq}$$

Por tanto:

$$I = \frac{n}{pq} \Rightarrow D^2(\bar{X}) = \frac{1}{I}$$

Lo que implica que la frecuencia relativa es un estimador eficiente de p .

- Supongamos X con distribución exponencial de parámetro λ : $\gamma(1, \lambda)$. Se propone $\bar{X}$ como estimador de $1/\lambda$. Analícese la centralización y la eficiencia.

Se tendrá:

$$f_x(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}} \quad x \geq 0$$

Sabemos que es:

$$E(\bar{X}) = \mu = \frac{1}{\lambda} = \theta \quad D^2(\bar{X}) = \frac{D^2(X)}{n} = \frac{\theta^2}{n}$$

$$\ln f_x(x; \theta) = -\ln \theta - \frac{1}{\theta} x \Rightarrow \frac{\partial \ln f_x(x; \theta)}{\partial \theta} = -\frac{1}{\theta} + \frac{x}{\theta^2} = \frac{1}{\theta^2} (x - \theta)$$

$$E\left(\frac{\partial \ln f_x(x; \theta)}{\partial \theta}\right)^2 = \frac{1}{\theta^4} E(x - \theta)^2 = \frac{1}{\theta^4} D^2(X) = \frac{\theta^2}{\theta^4} = \frac{1}{\theta^2}$$

Luego:

$$I = \frac{n}{\theta^2} \Rightarrow D^2(\bar{X}) = \frac{1}{I}$$

por consiguiente $\bar{X}$ es un estimador eficiente de $1/\lambda$.

4.4. Error estándar: información sobre la calidad de la estimación por puntos

Cuando se informa sobre el valor obtenido de una estimación por puntos de un parámetro, es deseable dar una idea de la precisión de la estimación. La medida de precisión empleada suele ser el error estándar del estimador empleado.

El **error estándar** de un estimador $\hat{\theta}$ es su desviación típica $D(\hat{\theta}) = \sigma_{\hat{\theta}}$. Si el error estándar depende de parámetros desconocidos que pueden ser estimados, la substitución de estos valor en $D(\hat{\theta})$ da lugar al denominado **error estándar estimado**, denotado por $\hat{\sigma}_{\hat{\theta}}$.

Ejemplo. Se ha obtenido una muestra del peso en gramos de una determinada pieza mecánica:

40,16	39,27	37,59	38,26	41,81
41,11	37,45	40,16	37,31	41,43

Una estimación por puntos del peso medio es:

$$\bar{X} = 39.455$$

El error estándar de la muestra es $\sigma_{\bar{X}} = \sigma/\sqrt{n}$. Como σ es desconocido, lo reemplazamos por la desviación típica muestral $s = 1.7237$ con lo que obtenemos el error estándar estimado de $\bar{X}$:

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{1.7237}{\sqrt{10}} = 0.545$$

Interpretación práctica: el error estándar estimado es alrededor del 1.38% de la media muestral, lo que implica una estimación precisa del peso medio de la pieza teniendo en cuenta que la muestra es pequeña. Si los pesos están normalmente distribuidos, dos veces el error estándar estimado es $2\sigma_{\bar{X}} = 2(0.545) = 1.09$, por lo que tendremos una gran confianza de que el peso de las piezas fabricadas esté en el intervalo 39.455 ± 1.09 , es decir, entre 38.365 y 40.545 gramos.

5. Suficiencia. Criterio de Neyman-Fisher

Este concepto fue introducido por Fisher. El intuía que en una muestra había cierta información sobre un parámetro y llamó *estimador suficiente* a aquel que extraía toda la información que una muestra contiene sobre un parámetro.

θ se dice que es suficiente para θ si la distribución de una muestra $(X_1, X_2, \dots, X_n)$ dado θ no depende de θ . O sea, si la distribución de la variable aleatoria $(X_1, X_2, \dots, X_n | \theta)$ no depende de θ .

En tal caso la distribución de θ contiene toda la información que puede proporcionar la muestra aleatoria acerca de la estimación de θ . Conocido el valor particular de θ dado por la muestra no podemos conocer más, por la muestra, acerca de θ .

A continuación se enuncia el criterio de Neyman-Fisher que establece la condición necesaria y suficiente para que un estimador sea suficiente.

Para que un estimador θ de un parámetro θ sea un estimador suficiente es condición necesaria y suficiente que la función de verosimilitud admita una descomposición factorial de la forma:

$$L(x_1, x_2, \dots, x_n; \theta) = h(\theta; \theta) \cdot H(x_1, x_2, \dots, x_n) \quad \Leftrightarrow \quad L(\vec{x}; \theta) = h(\theta; \theta) \cdot H(\vec{x})$$

o sea, producto de una función de θ y θ por una función que depende de $(x_1, x_2, \dots, x_n)$ pero no de θ .

La demostración de este teorema queda fuera del alcance de este curso.

Ejemplo. Para ver cómo se aplica este teorema, consúltense los ejemplos del apartado 6.2 más adelante.

6. Métodos de obtención de estimadores

Hasta ahora hemos visto el concepto de estimador por puntos y las propiedades deseables de un buen estimador. Ahora surge la pregunta de cómo obtener estimadores de uno o varios parámetros desconocidos. Vamos a ver dos métodos: el método de los momentos y el de máxima verosimilitud.

6.1. Método de los momentos

El método de los momentos consiste en igualar momentos poblacionales con momentos muestrales. Los momentos poblacionales dependen de los parámetros de la población. Las igualdades anteriores permiten despejar y obtener los valores desconocidos de los parámetros.

Sean $X_1, X_2, \dots, X_n$ una muestra aleatoria de una población (discreta o continua) con m parámetros desconocidos $\theta_1, \theta_2, \dots, \theta_m$. Los estimadores $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ obtenidos por el método de los momentos resultan de resolver m ecuaciones consistentes en igualar los primeros m momentos poblacionales a los primeros m momentos muestrales.

Ejemplo. Estimar por el método de los momentos el parámetro λ de una distribución exponencial.

Como la distribución exponencial depende de un solo parámetro λ , tendremos que resolver una sola ecuación $E(X) = \bar{X}$. Sabemos que para una distribución exponencial es $E(X) = 1/\lambda$. Por tanto, resultará:

$$\frac{1}{\lambda} = \bar{X}$$

Por lo que el estimador obtenido por el método de los momentos es: $\hat{\lambda} = 1/\bar{X}$

Ejemplo. Estimar por el método de los momentos los parámetros de una población $N(\mu, \sigma)$.

Como hay dos parámetros, necesitamos dos ecuaciones. Para una población normal se tiene:

$$E(X) = \mu \quad E(X^2) = \mu^2 + \sigma^2$$

De aquí:

$$\mu = \bar{X} \quad \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

Resolviendo estas dos ecuaciones se obtienen los dos estimadores buscados:

$$\hat{\mu} = \bar{X} \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n X_i^2 - n \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2}{n} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

Como se puede ver, el estimador de σ^2 no es un estimador centrado.

6.2. Método de máxima verosimilitud

Es uno de los mejores métodos para obtener estimadores de un parámetro. Fue desarrollado en 1920 por R. A. Fisher. Como su propio nombre indica, el estimador obtenido por este método consiste en calcular el valor del parámetro que hace máxima la función de verosimilitud.

Dicho de manera formal. Supongamos una variable aleatoria X con función de probabilidad o de densidad $f(x; \theta)$ siendo θ un parámetro desconocido. Sean $x_1, x_2, \dots, x_n$ los valores observados de una muestra aleatoria de tamaño n . La función de verosimilitud de la muestra es:

$$L(\theta) = f(x_1; \theta) \cdot f(x_2; \theta) \cdot \dots \cdot f(x_n; \theta)$$

Nótese que la función de verosimilitud, para una muestra con valores concretos, es una función del parámetro desconocido θ . El estimador de máxima verosimilitud (EMV) de θ es el valor de θ que maximiza $L(\theta)$.

En el caso de una variable aleatoria discreta, la interpretación de la función de verosimilitud es sencilla, ya que es la probabilidad:

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

Esto es, $L(\theta)$ es la probabilidad de obtener los valores muestrales $x_1, x_2, \dots, x_n$. Por tanto, en el caso discreto, el estimador de máxima verosimilitud es un estimador que maximiza la probabilidad de ocurrencia de los valores muestrales obtenidos.

El método de máxima verosimilitud conduce a estimadores que suelen ser centrados y de mínima varianza.

Ejemplo. Se considera una serie de pruebas de Bernoulli en las que se observa la aparición de un suceso A con $P(A) = p$ en cada prueba. Determinar un estimador de máxima verosimilitud para p .

La variable aleatoria que se observa, X es tal que $P(X = 1) = p$, $P(X = 0) = q$. La muestra $x_1, x_2, \dots, x_n$ nos indica las observaciones en las que ha aparecido el suceso, según que los valores x_i sean 1 ó 0. La función de probabilidad es:

$$f_x(x; p) = \begin{cases} 1 - p & x = 0 \\ p & x = 1 \end{cases}$$

Luego:

$$L(\vec{x}; \theta) = \prod_{i=1}^n f_x(x_i; \theta) = p^r (1 - p)^{n-r}$$

Siendo r el número de 1's de la muestra: $r = 0, 1, 2, \dots, n$. Hemos de determinar p de tal forma que sea $0 \leq p \leq 1$ y haga máximo el valor de L . Determinamos:

$$\ln L = r \ln p + (n - r) \ln(1 - p)$$

$$\frac{\partial \ln L}{\partial p} = \frac{r}{p} - \frac{n - r}{1 - p} = 0 \quad \Rightarrow \quad r(1 - p) = p(n - r)$$

Ecuación que conduce a:

$$\hat{p} = \frac{r}{n} = \bar{X}$$

Se puede comprobar que este estimador es centrado y de mínima varianza.

Ejemplo. Determinar el estimador de máxima verosimilitud del parámetro λ de una distribución de Poisson a partir de una muestra de tamaño n .

$$P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda} \Rightarrow L(\vec{x}; \theta) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda}$$

$$\ln L = \sum_{i=1}^n \ln \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \sum_{i=1}^n (-\lambda + x_i \ln \lambda - \ln x_i!)$$

De aquí:

$$\frac{\partial \ln L}{\partial \lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^n x_i = 0 \Rightarrow \hat{\lambda} = \bar{X}$$

Por lo tanto el estimador de máxima verosimilitud del parámetro λ de una distribución de Poisson es la media muestral.

Ejemplo. Sea población $N(\mu_0, \sigma)$ donde μ_0 es conocido y σ desconocida. Determinar un estimador de máxima verosimilitud para de la varianza. Determinar si el estimador obtenido es o no insesgado.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu_0)^2}{2\sigma^2}} \Rightarrow L(\vec{x}; \theta) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2}$$

$$\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{\sum_{i=1}^n (x_i - \mu_0)^2}{2\sigma^2} = -\frac{n}{2} \ln(2\pi\theta) - \frac{\sum_{i=1}^n (x_i - \mu_0)^2}{2\theta}$$

$$\frac{\partial \ln L}{\partial \theta} = -\frac{n}{2\theta} + \frac{\sum_{i=1}^n (x_i - \mu_0)^2}{2\theta^2} = 0 \Rightarrow \hat{\theta} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2$$

Veamos si es centrado:

$$E(\hat{\theta}) = \frac{1}{n} E \left[\sum_{i=1}^n (x_i - \mu_0)^2 \right] = \frac{1}{n} \sum_{i=1}^n E(x_i - \mu_0)^2 = \frac{1}{n} n\sigma^2 = \sigma^2$$

Luego es centrado. Se puede comprobar que este estimador es también eficiente.

Ejemplo. Consideremos un muestreo aleatorio simple de una distribución $N(\mu, \sigma)$ siendo μ y σ desconocidos. Determinar por el método de máxima verosimilitud estimadores para μ y σ^2 . ¿Son suficientes?

Sea $\theta = \sigma^2$, entonces:

$$f(x) = \frac{1}{\sqrt{2\pi\theta}} e^{-\frac{(x-\mu)^2}{2\theta}} \Rightarrow L(\vec{x}; \mu, \theta) = \frac{1}{(2\pi\theta)^{\frac{n}{2}}} e^{-\frac{1}{2\theta} \sum_{i=1}^n (x_i - \mu)^2}$$

$$\ln L = -\frac{n}{2} \ln(2\pi\theta) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\theta}$$

$$\frac{\partial \ln L}{\partial \mu} = \frac{\sum_{i=1}^n (x_i - \mu)}{2\theta} = 0 \Rightarrow \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{X}$$

$$\frac{\partial \ln L}{\partial \theta} = -\frac{n}{2\theta} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\theta^2} = 0 \Rightarrow \hat{\theta} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2$$

Vemos que los dos estimadores se obtienen independientemente, y que el estimador de máxima verosimilitud de σ^2 es la varianza muestral que sabemos que es *sesgado*.

Veamos si son suficientes. Se tiene:

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu)^2 &= \sum_{i=1}^n [(x_i - \bar{X}) + (\bar{X} - \mu)]^2 = \sum_{i=1}^n (x_i - \bar{X})^2 + n(\bar{X} - \mu)^2 = \\ &= n[\hat{\theta} + (\hat{\mu} - \mu)^2] \end{aligned}$$

Entonces:

$$L(\vec{x}; \mu, \theta) = \underbrace{\frac{1}{(2\pi\theta)^{\frac{n}{2}}} e^{-\frac{n}{2\theta}[\hat{\theta} + (\hat{\mu} - \mu)^2]}}_{h(\hat{\mu}, \hat{\theta}; \mu, \theta)} \cdot \underbrace{1}_{H(\vec{x})}$$

Luego por el teorema de Neyman-Fisher son estimadores suficientes.

6.3. Complicaciones en el uso del método de máxima verosimilitud

Aunque el método de máxima verosimilitud es una buena técnica, algunas complicaciones surgen en su empleo. El siguiente ejemplo ilustra esta situación.

Ejemplo. Sea X una variable aleatoria con distribución uniforme en el intervalo $[0, a]$ siendo a un parámetro desconocido. Obtener un estimador de a por el método de máxima verosimilitud.

La función de verosimilitud es:

$$L(a) = \prod_{i=1}^n \frac{1}{a} = \frac{1}{a^n}$$

Y se cumplirá que: $0 \leq x_i \leq a \quad \forall i = 1, 2, \dots, n$

Se comprende que $L(a)$ no se anula nunca. La solución en este caso es encontrar el valor de a , compatible con los valores x_i , que maximiza $L(a)$. Está claro que cuando menor sea a mayor será $L(a)$ y como $x_i \leq a \quad \forall i$ resultará que la mejor estimación de a será:

$$\hat{a} = \max(x_i)$$

Tomar como estimador de a el máximo valor muestral tiene sentido en este caso.

6.4. Optimización computacional de la función de verosimilitud

En ocasiones la resolución manual para hacer máxima la función de verosimilitud resulta imposible, por lo que hay que recurrir a técnicas computacionales. Excel dispone de un complemento, denominado “Solver”, que facilita la obtención de los estimadores de máxima verosimilitud de los parámetros desconocidos dada una muestra concreta. El siguiente ejemplo muestra cómo hacerlo y además grafica la función de verosimilitud en tres dimensiones.

Ejemplo. Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución gamma de dos parámetros $\gamma(r, \lambda)$. La función de verosimilitud es:

$$L(r, \lambda) = \prod_{i=1}^n \frac{\lambda^r x_i^{r-1} e^{-\lambda x_i}}{\Gamma(r)} = \frac{\lambda^{nr} (\prod_{i=1}^n x_i^{r-1}) (e^{-\lambda \sum_{i=1}^n x_i})}{[\Gamma(r)]^n}$$

De aquí:

$$\ln L(r, \lambda) = nr \ln \lambda + (r-1) \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n x_i - n \ln[\Gamma(r)]$$

Derivando con respecto a los parámetros, obtenemos:

$$\frac{\partial L(r, \lambda)}{\partial r} = n \ln \lambda + \sum_{i=1}^n \ln x_i - n \frac{\Gamma'(r)}{\Gamma(r)}$$

$$\frac{\partial L(r, \lambda)}{\partial \lambda} = \frac{nr}{\lambda} - \sum_{i=1}^n x_i$$

Si igualamos las dos últimas ecuaciones a cero, se comprende que es imposible resolver a mano dichas ecuaciones para obtener los valores de r y λ . Sin embargo, sí que podemos encontrar estos valores conocida una muestra concreta.

Supongamos que para la población considerada obtenemos la siguiente muestra de 10 valores:

3.413	0.17	1.132	0.823	0.869	0.205	1.065	1.567	0.453	0.909
-------	------	-------	-------	-------	-------	-------	-------	-------	-------

Teniendo en cuenta estos valores resulta:

$$\ln L(r, \lambda) = 10r \ln \lambda - 2.715(r-1) - 10.606\lambda - 10 \ln[\Gamma(r)]$$

Con Excel se puede dibujar esta función. La Figura 3 muestra su gráfica para valores de $1.30 \leq r \leq 1.90$ y $1.25 \leq \lambda \leq 1.75$. Esto permite hacerse una idea de los valores de los parámetros que hacen máxima la función de verosimilitud (o, equivalentemente, de su neperiano).




Figura 3. Gráfica $\ln L(r, \lambda) = 10r \ln \lambda - 2.715(r - 1) - 10.606\lambda - 10 \ln[\Gamma(r)]$

Si utilizando el Solver de Excel para maximizar la función $\ln L(r, \lambda)$, se obtienen los valores más verosímiles de los parámetros: $\hat{r} = 1.661$ y $\hat{\lambda} = 1.566$. Pruebe a obtener estos valores.

7. Problemas

9-1. En una serie de n pruebas de Bernoulli con probabilidad de éxito p se observan r éxitos. Siendo $\hat{p} = r/n$ se quiere analizar el estadístico $\hat{p}(1 - \hat{p})$ como estimador de $p(1 - p)$. Determinar si es o no un estimador centrado. En caso negativo, determinar un estimador centrado de $p(1 - p)$.

Solución: No lo es. Un estimador centrado es $\frac{n-1}{n} \hat{p}(1 - \hat{p})$

9-2. Una variable aleatoria X tiene la siguiente función de densidad.

$$f(x) = \frac{1}{2\theta^3} x^2 e^{-x/\theta} \quad x \geq 0$$

Siendo θ un parámetro estrictamente positivo.

- a) Encontrar el estimador de máxima verosimilitud de θ
- b) Demostrar si este estimador es o no centrado.
- c) Demostrar si es o no consistente.

Se ha obtenido una muestra de 10 valores de la variable aleatoria X, de acuerdo con la siguiente tabla:

18.512	5.011	13.325	8.644	25.944
17.437	10.375	10.353	13.579	27.616

- d) ¿Cuál es la estimación más verosímil de θ ?

Solución: a) $\hat{\theta} = \frac{\bar{X}}{3}$ b) Es centrado c) Es consistente d) $\hat{\theta} = 5.02653$

9-3. Se sacan muestras de tamaño n de una población con la siguiente función de densidad:

$$f(x) = \frac{1}{\theta^2} x e^{-\frac{x}{\theta}} \quad x \geq 0$$

Determinar el estimador de máxima verosimilitud de θ . Verificar si es centrado, consistente, de mínima varianza y suficiente.

Solución: $\hat{\theta} = \bar{X}/2$. Es centrado, consistente, eficiente y suficiente.

9-4. Los diodos fabricados en una factoría tienen un tiempo de vida X con la siguiente distribución:

$$f(x) = \lambda x^{\lambda-1} \quad 0 \leq x \leq 1$$

- a) Determinar un estimador de máxima verosimilitud del parámetro λ .
- b) Verificar si el estimador obtenido es centrado y suficiente.

Solución: a) $\hat{\lambda} = -\frac{n}{\sum_{i=1}^n \ln x_i}$, b) Es centrado y suficiente.

9-5. Sea $(x_1, x_2, \dots, x_n)$ una muestra extraída de una población con distribución:

$$f(x) = 3\theta^3 x^{-4} \quad x \geq \theta \quad \theta > 0$$

- Encontrar un estimador de θ por el método de los momentos. Llámese Y a este estimador. Calcular su valor medio y su varianza.
- Determinar un estimador de máxima verosimilitud de θ . Llámese V a este estimador. Calcular su valor medio y su varianza.
- A partir de V obtener un estimador de θ que sea centrado. Llámese W a este estimador. Calcular su varianza.
- De los tres estimadores anteriores, ¿cuál seleccionaría como mejor?, ¿por qué?
- Se ha obtenido, al azar, una muestra de 20 elementos de la población, resultando los siguientes valores:

6.261	4.789	5.006	8.743	6.319	4.821	5.504	19.411	4.031	7.378
4.254	4.428	4.141	5.472	8.621	4.426	16.807	4.128	6.490	4.323

De acuerdo con la decisión del apartado d) ¿cuál sería el valor estimado para θ ?

Solución: a) $Y = \frac{2\bar{X}}{3}$, $E(Y) = \theta$, $D^2(Y) = \frac{\theta^2}{3n}$, b) $V = \text{máximo muestral}$, $E(V) = \frac{3n}{3n-1}\theta$, $D^2(V) = \frac{3n}{(3n-2)(3n-1)^2}\theta^2$, c) $W = \frac{3n-1}{3n}V$, $E(W) = \theta$, $D^2(W) = \frac{1}{3n(3n-2)}\theta^2$, d) Se desecha V por no ser centrado y se escoge W porque tiene menor varianza, e) Teniendo en cuenta W , se obtiene que la estimación de θ es 3.9638.

9-6. Sea $(y_1, y_2, \dots, y_n)$ una muestra aleatoria simple de una población Y con distribución $N(0, \sigma)$. Se define $X = Y^2$ y se desea hacer una estimación de σ^2 en base a $(x_1, x_2, \dots, x_n)$.

- Calcular la distribución de X . ¿Qué tipo de distribución es?
- Obtener un estimador de máxima verosimilitud de la varianza σ^2
- Comprobar si el estimador obtenido es o no centrado, consistente, de mínima varianza y suficiente.

Solución: a) $f_x(x) = \frac{1}{\sigma\sqrt{2\pi}}x^{-\frac{1}{2}}e^{-\frac{x}{2\sigma^2}}$ $x \geq 0$ se trata pues de una distribución gamma de dos parámetros con $r = \frac{1}{2}$, $\lambda = \frac{1}{2\sigma^2}$, b) $\bar{X}$, c) Es centrado, consistente, de mínima varianza y suficiente.

9-7. Se efectúa un proceso de muestreo aleatorio simple de una población representada por una variable aleatoria X con función de densidad:

$$f(x) = \frac{\theta}{(1+x)^{1+\theta}} \quad x \geq 0, \theta > 0$$

- Estimar por el método de los momentos un estimador de θ . Supóngase que, en este caso, es $\theta > 1$.
- Encontrar un estimador de máxima verosimilitud de $1/\theta$.
- Demuéstrese si el estimador obtenido en b) es o no suficiente.
- Calcular la cota de Cramer-Rao para todos los estimadores centrados de $1/\theta$.
- Encontrar un estimador eficiente de $1/\theta$.

Solución: a) $\hat{\theta} = \frac{1+\bar{X}}{\bar{X}}$, b) $\hat{\alpha} = \frac{1}{n} \sum_{i=1}^n \ln(1+x_i)$, c) Es suficiente, d) α^2/n siendo $\alpha = 1/\theta$, e) $\hat{\alpha}$ es centrado y eficiente.

9-8. Dada una población cuya función de densidad sea:

$$f(x) = (1 + \theta)x^\theta \quad 0 \leq x \leq 1$$

- a) Determinar por el método de los momentos un estimador del parámetro θ .
- b) Obtener por el método de máxima verosimilitud un estimador del parámetro θ .

Solución: a) $\hat{\theta} = \frac{2\bar{X}-1}{1-\bar{X}}$ b) $\hat{\theta} = -1 - \frac{n}{\sum_{i=1}^n \ln x_i}$

9-9. El resultado de una medida X realizada en un laboratorio tiene una distribución de Rayleigh cuya función de densidad es:

$$f(x) = \frac{x}{\theta} e^{-\frac{x^2}{2\theta}} \quad x \geq 0$$

Siendo $\theta > 0$.

- a) Obtenga la función de densidad de la variable $Y = X^2$. Identifique la distribución.
- b) Determine un estimador de máxima verosimilitud del parámetro θ para el caso de muestreo aleatorio simple.
- c) Demuestre si el estimador obtenido es o no centrado. Ayuda: tenga en cuenta el resultado del apartado b).
- d) Demuestre si el estimador obtenido es suficiente.

Solución: a) $f(y) = \frac{1}{\theta} e^{-\frac{y}{\theta}} \quad y \geq 0$. Se trata de una distribución exponencial $\gamma(1,1/\theta)$ b) $\hat{\theta} = \frac{T}{2n}$ c) Es centrado d) Es suficiente

9-10. Se realiza un muestreo aleatorio simple con muestras de tamaño n de una población X que tiene una distribución continua con la siguiente función de densidad:

$$f_x(x) = \frac{2(\theta - x)}{\theta^2} \quad 0 \leq x \leq \theta$$

- a) Encontrar un estimador de θ por el método de los momentos.
- b) Determinar si el estimador obtenido es centrado.
- c) Determinar si el estimador obtenido es consistente.

Solución: a) $\theta^ = 3\bar{X}$ b) Es centrado c) Es consistente*