

Capítulo 12: Regresión

(Revisión 03/2022)

1. Asociación entre variables aleatorias.....	1
2. Planteamiento e idea central de la regresión	2
3. Análisis de regresión	2
3.1. Concepto de regresión.	3
3.2. Modelos de regresión.....	6
3.3. Regresión lineal.	8
3.4. Tablas de datos para el ajuste del modelo.	9
3.5. Transformación de variables.	10
4. Regresión lineal mínimo cuadrática	14
4.1. Residuos. Definiciones.....	14
4.2. Hipótesis del modelo.....	15
4.3. Método de mínimos cuadrados.	16
4.4. Coeficiente de determinación	18
4.5. Coeficiente de determinación ajustado	20
4.6. Inferencia de los parámetros del modelo.	22
4.7. Test t para la significación de los parámetros del modelo.	24
4.8. Intervalos de confianza de los parámetros del modelo.	24
5. Problemas.....	27
ANEXO. Regresión con dos variables. Recta de regresión.....	33

Después de un estudio en profundidad de este capítulo, el estudiante deberá ser capaz de:

- Entender, conocer y proponer modelos de regresión.
- Saber ajustar modelos de regresión mediante mínimos cuadrados.
- Analizar los resultados de un modelo de regresión y testar su significación.
- Mejorar modelos de regresión.


1. Asociación entre variables aleatorias

En el estudio de numerosos fenómenos reales es preciso considerar un cierto número de variables que los caracterizan. Entre ellas pueden considerarse diversos tipos de *dependencia* que permiten obtener las leyes que las relacionan. El estudio y determinación de estas leyes es fundamental en todas las ciencias experimentales. Uno de los usos más frecuentes que pueden hacerse de este tipo de leyes es a efectos de *predicción* o pronóstico del valor que tomará una de las variables suponiendo que otras variables que entran en la descripción del fenómeno toman determinados valores. En el caso de que las variables que entran en el fenómeno sean ordinarias, es posible en muchos casos determinar una *ley* dada por una relación de la forma:

$$y = f(\vec{x}) \quad (1)$$

En el estudio de la asociación o influencia entre variables aleatorias hay dos aspectos distintos. Uno es el llamado **análisis de regresión**, mediante el cual se establece la naturaleza de la relación, es decir, la llamada relación funcional entre las variables, tratando de llegar a una función $y = f(\vec{x})$. En este caso el objetivo es estimar una variable en función de las demás. Los apartados posteriores de este capítulo versarán sobre regresión. El segundo aspecto, llamado **análisis de la correlación**, trata de determinar el grado de relación entre las variables sin buscar específicamente la relación de una en concreto con respecto a las otras.

El coeficiente de correlación ρ definido en el capítulo 7 de estos apuntes, es un ejemplo de medida del grado de asociación lineal entre variables. Según su valor sea mayor que, menor que o aproximadamente igual a 0, se tendrá una relación creciente, decreciente o no habrá relación, como se indica en la siguiente figura:



Relación *creciente* ($\rho > 0$)

Relación *decreciente* ($\rho < 0$)

No hay relación ($\rho \simeq 0$)

2. Planteamiento e idea central de la regresión

El punto de partida de la regresión es el siguiente: tenemos una variable Y y $k - 1$ variables $X_1, X_2, \dots, X_{k-1}$

Disponemos de n muestras de la distribución conjunta de estas variables (lo que se denomina tabla de datos de partida):

$$\begin{array}{cccccc} y_1 & x_{11} & x_{12} & \cdots & x_{1,k-1} \\ y_2 & x_{21} & x_{22} & \cdots & x_{2,k-1} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ y_n & x_{n1} & x_{n2} & \cdots & x_{n,k-1} \end{array}$$

Con esta información queremos ajustar una función del tipo:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_{k-1} x_{k-1}$$

que permita obtener qué valor medio debería tener la variable y a partir de un conjunto de valores de las variables $x_1, x_2, \dots, x_{k-1}$. Para las n muestras de partida tendremos:

$$\begin{aligned} \hat{y}_1 &= \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \cdots + \beta_{k-1} x_{1,k-1} \\ \hat{y}_2 &= \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \cdots + \beta_{k-1} x_{2,k-1} \\ &\vdots \\ \hat{y}_n &= \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \cdots + \beta_{k-1} x_{n,k-1} \end{aligned}$$

Las incógnitas son los coeficientes $\beta_0, \beta_1, \beta_2, \dots, \beta_{k-1}$ que calcularemos haciendo mínimo el siguiente valor, denominado suma de los cuadrados de los errores, SCE :

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Para el cálculo de los coeficientes β_i utilizaremos la función de Excel denominada “ESTIMACIÓN.LINEAL”. Se trata de una función vectorial compleja que nos calculará los valores de los coeficientes β_i así como otros valores de gran utilidad a partir de los cuales podremos contrastar si estos coeficientes son significativamente distintos de cero.

Por último, las variables $x_1, x_2, \dots, x_{k-1}$ pueden ser a su vez funciones de otras variables: esto se resuelve fácilmente mediante lo que vamos a denominar transformación de la tabla de datos de partida.

3. Análisis de regresión

El análisis de regresión lineal es una técnica estadística empleada en el estudio de la relación entre variables. Resulta de gran utilidad y se adapta a una gran variedad de situaciones: en

física se emplea para caracterizar la relación entre variables o para calibrar medidas. En ciencias de los materiales se utiliza para caracterizar la influencia de determinados elementos en las propiedades de un material. En general sirve para predecir un amplio rango de fenómenos.

Como se verá a continuación, tanto en el caso de dos variables (**regresión simple**) como el de más de dos variables (**regresión múltiple**), el análisis de regresión tiene por objetivo explorar y cuantificar la relación entre una variable llamada **dependiente**, Y , y una o más variables que denominaremos variables **independientes o predictoras**, $(X_1, X_2, \dots, X_n)$. El análisis de regresión lineal obtendrá una ecuación lineal con fines predictivos. Por otra parte, el análisis de regresión implica una serie de procedimientos de diagnóstico (análisis de los residuos) que informan sobre la estabilidad e idoneidad del análisis y que proporcionan pistas sobre cómo perfeccionarlo.

El objetivo de este capítulo es describir los fundamentos del análisis de regresión, fomentando la comprensión de cuándo y cómo utilizar el análisis de regresión lineal y cómo interpretar los resultados. También se mostrará el testeo de los supuestos del análisis de regresión y la forma de proceder cuando no se cumplen.

3.1. Concepto de regresión.

Para presentar el concepto de regresión, empezaremos por un ejemplo ilustrativo.

Ejemplo 1. En una universidad se pretende realizar un estudio previo al inicio de los exámenes finales para predecir las notas de todos los estudiantes al final de su primer curso. Para ello se desarrollará un modelo estadístico mediante el método de regresión.

Una primera forma de llevarlo a cabo es tomar una muestra representativa de estudiantes que hubieran cursado primero en el año anterior y observar su nota, que será denotada por la variable y . Se calcula la media de dicha muestra y se emplea como estimador de la nota de cada uno de los estudiantes. Las notas para un grupo de 10 estudiantes aparecen en la siguiente tabla:

Estudiante	Nota	Estudiante	Nota
Estudiante 1	8.0	Estudiante 6	7.0
Estudiante 2	7.5	Estudiante 7	4.0
Estudiante 3	3.0	Estudiante 8	9.5
Estudiante 4	5.5	Estudiante 9	7.0
Estudiante 5	2.0	Estudiante 10	6.0

En regresión, la variable y que es modelada se denomina **variable dependiente (o respuesta)**. Su valor esperado será $E(y)$, que en el ejemplo es igual a 5.95. Por ello, en este ejemplo el modelo básico que se empleará para la predicción de la nota del estudiante será:

$$y = E(y) \quad (2)$$

Sin embargo, se sabe que la nota de cada estudiante dependerá realmente de muchos otros factores: el esfuerzo realizado por el estudiante, su capacidad de aprendizaje, su conocimiento previo de la materia, su motivación, etc. Por ello el modelo anteriormente expuesto será poco preciso, ya que cada estudiante presentará una importante desviación con respecto a la media. Esta desviación se modelará como un error aleatorio ε , debido a que es un dato desconocido para las personas que llevan a cabo el estudio en el momento de hacerlo. El modelo entonces adopta la siguiente forma:

$$y = E(y) + \varepsilon \quad (3)$$

Los valores que adopta la variable ε en la muestra de estudiantes anterior serán las diferencias con respecto a la media:

Estudiante	y	$E(y)$	ε	Estudiante	y	$E(y)$	ε
Estudiante 1	8.0	5.95	2.05	Estudiante 6	7.0	5.95	1.05
Estudiante 2	7.5	5.95	1.55	Estudiante 7	4.0	5.95	-1.95
Estudiante 3	3.0	5.95	-2.95	Estudiante 8	9.5	5.95	3.55
Estudiante 4	5.5	5.95	-0.45	Estudiante 9	7.0	5.95	1.05
Estudiante 5	2.0	5.95	-3.95	Estudiante 10	6.0	5.95	0.05

Este modelo básico representa un modelo estadístico, en el que aunque no se pueda proporcionar una estimación exacta de la nota de un estudiante, sí se puede calcular la probabilidad de que su nota se encuentre en un rango de valores dados a partir de la distribución de ε .

Es obvio que, dada la gran dispersión de notas, este primer modelo presentado no permite una estimación suficientemente precisa para algunas aplicaciones. El error medio que se comete es 1,86 puntos. Una solución será emplear un modelo que recoja otras variables cuyos valores puedan ser conocidos *a priori* y que estén asociados con la nota final del alumno. Por ejemplo, en este caso, se podrían incorporar la nota de bachillerato, la asistencia a clase o la nota de los parciales realizados. Estas variables empleadas para predecir la respuesta del modelo, son las denominadas **variables independientes**. Su inclusión aportará información sobre la variable de respuesta que permitirá reducir el error cometido en la estimación.

El **análisis de regresión** es una rama de la estadística que estudia el desarrollo de modelos que permiten relacionar una **variable de respuesta**, que será denominada **variable dependiente**, con un conjunto de uno o más predictores, que serán denominados **variables independientes**.

Una pregunta que surge entonces es: dado un conjunto de variables, ¿cómo puede decidirse cuál es la variable dependiente y cuáles son las variables independientes? Para responder a esta pregunta, debe considerarse la aplicación que se le quiera dar al modelo de regresión.

Las variables independientes no han de entenderse como las *causas* de la dependiente. Aunque existen técnicas estadísticas para estudiar relaciones de causalidad, los métodos de regresión que se verán en esta asignatura no responden a la cuestión de si los valores observados de la variable dependiente son *causados* por los valores de las variables independientes. Han de entenderse exclusivamente como valores asociados, es decir, que sus valores están

relacionados de manera estadísticamente significativa. Como ejemplo ilustrativo de esta diferencia conceptual, considérese la asociación existente entre casos de cáncer y riqueza de un país. En los países con mayor PIB per cápita hay más gente que muere por cáncer, aunque la mayor riqueza no es la *causa*. La causa parece estar relacionada con la mayor longevidad de la población que se da en países ricos.

La designación como variable dependiente o independiente dependerá de la disponibilidad de sus valores en el momento en que se vaya a utilizar el modelo de regresión para una aplicación dada. Una variable se tomará como dependiente si su valor es desconocido en el momento en que vayamos a emplear el modelo y su valor es, precisamente, el que deseemos estimar o predecir para una nueva observación. Una variable será designada independiente si, en el momento en que vayamos a emplear el modelo de regresión, su valor es conocido o puede ser estimado por algún procedimiento. Por tanto, es un dato de partida para estimar o predecir la variable dependiente.

En el ejemplo 1 presentado anteriormente la variable dependiente sería la nota final, ya que se trata de la variable cuyo valor quiere ser estimado. Antes de los exámenes finales su valor es desconocido, pero mediante un modelo de regresión puede ser relacionado con un conjunto de variables que serían conocidas en ese momento: información de notas de bachillerato de los alumnos, su asistencia a clase o notas de parciales. Estas variables serán las denominadas independientes.

Se debe diferenciar la necesidad de disponer de datos en el momento de **ajuste del modelo** del momento de **utilización del modelo**. Cuando se **ajusta** el modelo, se debe disponer de una muestra de observaciones conjuntas de las variables dependientes e independientes que permitirán *ajustar* los parámetros del modelo. Cuando se **utiliza** el modelo, se debe contar con una observación conjunta de las variables independientes a partir de las cuales se *estimar*á la variable dependiente empleando los valores *ajustados* de los parámetros.

Ejemplo 2. Los modelos de regresión no son sólo utilizados para predecir observaciones futuras de un fenómeno. Existen diversas aplicaciones en que son empleados para inferir el estado de fenómenos pasados de los que no se dispone de observaciones directas. Un ejemplo es la reconstrucción del clima en épocas pasadas a partir del análisis de núcleos de hielo. A partir de muestras de capas de hielo de los casquetes polares se puede inferir la evolución de variables tales como la concentración de CO₂, la temperatura o el polvo en suspensión en la atmósfera. A medida que la nieve caída se convierte en hielo forma capas de diverso grosor, en las que quedan atrapadas inclusiones. La medida de estas variables que caracterizan las capas de hielo, ya que están relacionadas con las condiciones atmosféricas en el pasado, permite su estimación. En este caso, un modelo de regresión para estimación de la climatología pasada constaría de un conjunto de variables independientes (propiedades de las capas de hielo) y una variable dependiente (alternativamente la temperatura, polvo o concentración de CO₂ en el pasado).

3.2. Modelos de regresión.

La forma general que adoptará un **modelo de regresión** estará constituida por dos componentes: la **parte determinística** del modelo, que es la **función de regresión**, y una **parte probabilística**, formada por un modelo probabilístico de su desviación con respecto a la media.

Es decir, si estamos construyendo un modelo para la variable dependiente Y a partir de un vector de m variables independientes $\vec{x} = (x_1, x_2, \dots, x_m)$, emplearemos un modelo de la siguiente forma:

$$y = E(Y|\vec{x}) + \varepsilon \quad (4)$$

Donde ε será una variable aleatoria que representará el error que cometemos al emplear la estimación $E(Y|\vec{x})$ para predecir el valor concreto de una observación de y . ε será entonces la **parte probabilística** del **modelo de regresión**.

La **función de regresión** será una función que tendrá por argumentos las m variables independientes del modelo junto con un conjunto de k variables denominadas **parámetros del modelo**:

$$E(Y|\vec{x}) = f(x_1, x_2, \dots, x_m, \beta_0, \beta_1, \dots, \beta_{k-1}) \quad (5)$$

Según la forma que adopte la función f tendremos diversos tipos de modelos de regresión. Además, dado un tipo de función, los valores estimados de la variable dependiente dependerán también de los parámetros β .

Mediante el análisis de regresión, para una relación funcional (ecuación 5) dada, se buscará determinar los valores de los k parámetros $\beta_0, \beta_1, \dots, \beta_{k-1}$ que minimicen los errores de estimación de la variable dependiente.

Como se ha dicho anteriormente, la esperanza de la variable dependiente será el valor empleado para estimación. Para indicar que un valor de la variable dependiente es estimado y no una observación se emplea el símbolo $\hat{\cdot}$ sobre la misma. La **ecuación de predicción** será entonces:


$$\hat{y} = E(Y|\vec{x}) = f(x_1, x_2, \dots, x_m, \beta_0, \beta_1, \dots, \beta_{k-1}) \quad (6)$$

En ingeniería, los modelos de regresión son empleados con cuatro propósitos fundamentales:

- Estimación. El objetivo de la estimación es determinar el valor esperado de una variable para una combinación de valores particulares de las otras.
- Predicción. El objetivo de la predicción puede ser:
 - determinar el valor esperado de una nueva observación de una variable para una combinación de valores particulares de las otras.

- determinar la probabilidad de que futuras observaciones de la variable dependiente se encuentre en un intervalo dado.
- **Calibración.** El objetivo de la calibración es relacionar de forma cuantitativa las medidas obtenidas empleando un sistema de medida a las proporcionadas por otro sistema de medida.
- **Optimización.** Una optimización es llevada a cabo para determinar el conjunto de valores de unas variables sobre las que se puede tomar una decisión, tales que otra variable de interés presente un valor máximo o mínimo. Ejemplos típicos son la maximización del rendimiento de un proceso o la minimización del tiempo de procesamiento de un producto.


Ejemplo 3. Se ha estado estudiando el calentamiento de un gas a volumen constante con el objetivo de determinar cómo aumenta la presión del recipiente en función de la temperatura. De física se sabe que la relación entre ambas variables debe de ser de tipo lineal. Sin embargo, debido a errores en los sensores de presión (cualquier instrumento de medida tiene una precisión limitada), los datos obtenidos en un ensayo no siguen completamente una línea recta sino que presentan ciertas desviaciones como se ve en la figura.



En este caso, un modelo de regresión para la presión en función de la temperatura tendría la forma:

$$P = \beta_0 + \beta_1 \cdot T + \varepsilon \quad (7)$$

Donde $\beta_0 + \beta_1 \cdot T$ es la recta que representa la parte determinística del modelo y ε es el error aleatorio que representa la parte probabilística. Si graficamos estas dos componentes del modelo de regresión por separado nos queda:



3.3. Regresión lineal.

Se establecerá una división fundamental de los tipos de modelos de regresión entre modelos lineales y modelos no lineales.

Un modelo de regresión será **lineal** si se puede expresar como una combinación lineal de las variables independientes.

La forma general de un modelo lineal será:

$$f(x_1, x_2, \dots, x_m, \beta_0, \beta_1, \dots, \beta_{k-1}) = \beta_0 + \sum_{i=1}^m \beta_i \cdot x_i \quad (8)$$

En el modelo anterior, β_0 es el llamado **término independiente (o intercepción)** ya que no aparece multiplicado por ninguna de las variables independientes. Este término independiente representa el valor de la variable dependiente cuando todas las variables dependientes son iguales a 0.

Se distinguirán dos tipos de modelos lineales en función de que aparezca el parámetro β_0 o no.

- Modelos con término independiente. β_0 aparece en la ecuación del modelo y por tanto el número de parámetros k será: $k = m + 1$.
- Modelos sin término independiente. β_0 no aparece en la ecuación del modelo y por tanto el número de parámetros k será: $k = m$. En este caso, se asume que la respuesta correspondiente a todas las variables independientes iguales a 0 es igualmente 0.

Un modelo de regresión será **lineal en los parámetros** si se puede expresar como una combinación lineal de los parámetros. A su vez, será **no lineal en los parámetros** en caso contrario. El ajuste de modelos lineales en los parámetros se denomina **regresión lineal** ya que cualquier modelo lineal en los parámetros puede ser transformado en un **modelo lineal**.

La forma más genérica posible de un modelo lineal en los parámetros será:

$$f(x_1, x_2, \dots, x_m, \beta_0, \beta_1, \dots, \beta_{k-1}) = \beta_0 + \sum_{i=1}^{k-1} \beta_i \cdot f_i(x_1, x_2, \dots, x_m) \quad (9)$$

En este curso se estudiará únicamente regresión lineal.

Ejemplo 4. Modelos de regresión.

Modelo	Tipo de modelo
$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \varepsilon$	Modelo lineal
$y = \beta_1 \cdot x_1 + \varepsilon$	Modelo lineal sin término independiente
$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + \varepsilon$	Modelo lineal en los parámetros
$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_1 \cdot x_2 + \varepsilon$	Modelo lineal en los parámetros
$\ln(y) = \beta_0 + \beta_1 \cdot x_1^2 + \beta_2 \cdot x_2^{x_3} + \varepsilon$	Modelo lineal en los parámetros
$y = \beta_0 \cdot x_1^{\beta_1} \cdot x_2^{\beta_2} \cdot \varepsilon$	Transformable en un modelo lineal en los parámetros
$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2^{\beta_3 x_3 + \beta_4} + \varepsilon$	Modelo no lineal

El modelo $y = \beta_0 \cdot x_1^{\beta_1} \cdot x_2^{\beta_2} \cdot \varepsilon$ se puede transformar en un modelo lineal en los parámetros ya que tomando logaritmos se puede expresar como una combinación lineal de los parámetros:

$$\ln(y) = \beta'_0 + \beta_1 \cdot \ln(x_1) + \beta_2 \cdot \ln(x_2) + \ln(\varepsilon) \quad (10)$$

Dónde $\beta'_0 = \ln(\beta_0)$

3.4. Tablas de datos para el ajuste del modelo.

El proceso de ajuste de un modelo de regresión será el procedimiento por el cual se calculen los valores de los parámetros, para una función de regresión dada, que minimicen los errores de estimación para una muestra de observaciones conjuntas de las variables independientes y la dependiente. Esta muestra presentará la forma de una tabla de datos en la que cada fila es una observación conjunta de las variables y cada columna representa una variable del modelo. El número de observaciones de la muestra será n .

Observación	x_1	x_2	...	x_m	y
1	$x_{1,1}$	$x_{2,1}$		$x_{m,1}$	y_1
2	$x_{1,2}$	$x_{2,2}$		$x_{m,2}$	y_2
3	$x_{1,3}$	$x_{2,3}$		$x_{m,3}$	y_3
...	...	...		...	...
n	$x_{1,n}$	$x_{2,n}$		$x_{m,n}$	y_n

3.5. Transformación de variables.

El método de ajuste de modelos mediante mínimos cuadrados, que será explicado a continuación, es aplicable a cualquier modelo de regresión que sea lineal en los parámetros. Para ello, se realizará una transformación de las variables del modelo que permita formularlo como un modelo lineal.

La transformación consistirá en el siguiente cambio:

Modelo genérico:

$$g(y) = \beta_0 + \beta_1 \cdot f_1(x_1, \dots, x_m) + \dots + \beta_{k-1} \cdot f_{k-1}(x_1, \dots, x_m) + \varepsilon \quad (11)$$

Modelo con las variables transformadas:

$$y' = \beta_0 + \beta_1 \cdot x_1' + \dots + \beta_{k-1} \cdot x_{k-1}' + \varepsilon \quad (12)$$

Si la función de regresión se define para una función g de la variable dependiente, entonces la variable dependiente se transformará en una nueva variable cuyo valor viene dado por el resultado de dicha función: $y' = g(y)$

Definiremos una nueva variable independiente por cada parámetro del modelo de tal forma que dicha variable sea igual a la función de las variables independientes que multipliquen a dicho parámetro: $x'_j = f_j(x_1, \dots, x_m); j = 1, \dots, k - 1$

Al transformar las variables del modelo, el conjunto de datos de la muestra también deberá de ser transformado:

$$(x_{1i}, \dots, x_{mi}, y_i) \rightarrow (x'_{1i}, \dots, x'_{k-1i}, y'_i) = (f_1(x_{1i}, \dots, x_{mi}), \dots, f_{k-1}(x_{1i}, \dots, x_{mi}), g(y_i)) \quad (13)$$

Es decir, en lugar de usar la tabla de datos anterior, se usará la tabla transformada:

Observación	x_1'	x_2'	...	x_{k-1}'	y'
1	$f_1(x_{1,1}, \dots, x_{m,1})$	$f_2(x_{1,1}, \dots, x_{m,1})$		$f_{k-1}(x_{1,1}, \dots, x_{m,1})$	$g(y_1)$
2	$f_1(x_{1,2}, \dots, x_{m,2})$	$f_2(x_{1,2}, \dots, x_{m,2})$		$f_{k-1}(x_{1,2}, \dots, x_{m,2})$	$g(y_2)$
3	$f_1(x_{1,3}, \dots, x_{m,3})$	$f_2(x_{1,3}, \dots, x_{m,3})$		$f_{k-1}(x_{1,3}, \dots, x_{m,3})$	$g(y_3)$
...	...	...		...	...
n	$f_1(x_{1,n}, \dots, x_{m,n})$	$f_2(x_{1,n}, \dots, x_{m,n})$		$f_{k-1}(x_{1,n}, \dots, x_{m,n})$	$g(y_n)$

Un caso particular en la transformación de variables se da en el tratamiento de variables cualitativas en modelos de regresión, es decir, variables que no sean de tipo numérico. Este tipo de variables pueden ser igualmente incluidas en un modelo de regresión, para lo que se hace una transformación como se explicará a continuación.

Supongamos que la variable x_i del modelo de regresión es de tipo cualitativo. Es decir, no es numérica y sus valores posibles son: $\tau_0, \tau_1, \dots, \tau_{p-1}$ siendo p el número de valores posibles de la variable cualitativa. Por ejemplo, si quisiéramos usar como variable cualitativa en un modelo un atributo tal como el color (siendo sus valores posibles rojo, verde y azul), entonces tendríamos $p = 3$ y los valores posibles de la variable serían $\tau_0 = \text{rojo}$, $\tau_1 = \text{verde}$ y $\tau_2 = \text{azul}$.

Para introducir la variable cualitativa x_i en el modelo de regresión se definirán un conjunto de $p - 1$ variables auxiliares $x_{i_1}, x_{i_2}, \dots, x_{i_{p-1}}$. El valor τ_0 se tomará como valor de referencia. Cuando $x_i = \tau_0$ todas las variables auxiliares serán iguales a cero. El resto de valores posibles de x_i estará representado por cada una de las variables auxiliares de la siguiente forma:

$$x_{i_j} = \begin{cases} 1 & \text{si } x_i = \tau_j \\ 0 & \text{si } x_i \neq \tau_j \end{cases} \quad (14)$$

Entonces substituiremos la variable cualitativa del modelo por una combinación lineal de las variables auxiliares:

$$\beta_i \cdot x_i = \beta_{i_1} \cdot x_{i_1} + \beta_{i_2} \cdot x_{i_2} + \dots + \beta_{i_{p-1}} \cdot x_{i_{p-1}} \quad (15)$$

Ejemplo 5. Se está desarrollando un termómetro digital para medir temperaturas en un rango entre -10°C y 100°C en el que se emplea un sensor que proporciona un voltaje en función de la temperatura. Para la calibración de dicho sensor, se ha realizado un conjunto de pruebas en laboratorio de forma que se pueda determinar la relación entre voltaje y temperatura obteniendo la siguiente tabla de datos:

Observación	V	$T (^{\circ}\text{C})$
1	0.0	-2.014
2	0.2	6.118
3	0.4	-4.618
4	0.6	6.818
5	0.8	10.760
6	1.0	13.965
7	1.2	11.162
8	1.4	15.138
9	1.6	25.310
10	1.8	30.200
11	2.0	25.101

Se desea ajustar un modelo de regresión de la forma:

$$T = \beta_0 + \beta_1 \cdot V + \beta_2 \cdot V^2 + \varepsilon \quad (16)$$

Como se ve, este modelo no es una ecuación lineal, pero sí es lineal en los parámetros y por eso se puede transformar en un modelo de regresión lineal. Definiremos entonces las nuevas variables x_1' y x_2' que vendrán dadas por las ecuaciones:

$$x_1' = V \quad (17)$$

$$x'_2 = V^2 \quad (18)$$

Y así nos queda el modelo lineal:


$$T = \beta_0 + \beta_1 \cdot x'_1 + \beta_2 \cdot x'_2 + \varepsilon \quad (19)$$

Entonces, para ajustar este modelo deberemos de transformar la tabla de datos usando las ecuaciones anteriores. Se obtiene:

Observación	x'_1	x'_2	$T (^{\circ}C)$
1	0,0	0,00	-2,014
2	0,2	0,04	6,118
3	0,4	0,16	-4,618
4	0,6	0,36	6,818
5	0,8	0,64	10,760
6	1,0	1,00	13,965
7	1,2	1,44	11,162
8	1,4	1,96	15,138
9	1,6	2,56	25,310
10	1,8	3,24	30,200
11	2,0	4,00	25,101

Una vez ajustado (como se verá más adelante en la sección 3.3), los parámetros resultan ser $\beta_0 = -1'54$, $\beta_1 = 11'03$ y $\beta_2 = 2'18$. Por tanto, la ecuación del modelo queda (volviendo a usar las variables independientes sin transformar):

$$T = -1'54 + 11'03 \cdot V + 2'18 \cdot V^2 + \varepsilon \quad (20)$$



En la figura anterior puede verse la resolución de este ejemplo mediante Excel:

Ejemplo 6. A partir de un experimento de producción se desea ajustar un modelo que permita explicar el efecto del aprendizaje en la reducción de tiempos de ciclo (T_c) de una tarea en función de dos variables:

- El número de veces que el operario ha realizado la tarea (N).
- Una variable cualitativa que recoja el plan de entrenamiento ha recibido (X_E): plan A, plan B o Ninguno

De experiencias anteriores se sabe que un modelo adecuado para los tiempos de modelado es: $T_c = T_0 + \beta_E \cdot X_E + \beta_N \cdot e^{-N} + \varepsilon$ donde T_0 y β son parámetros. El parámetro T_0 representa el tiempo de ciclo promedio a largo plazo (cuando N tiende a infinito), β_E el efecto del entrenamiento sobre el tiempo de ciclo y β_N es una tasa de aprendizaje. Se dispone de la siguiente tabla de datos:

i	N	X_E	T_c	i	N	X_E	T_c	i	N	X_E	T_c
1	1	plan A	16.850	7	1	Plan B	21.435	13	1	Ninguno	20.820
2	2	plan A	12.285	8	2	Plan B	15.843	14	2	Ninguno	15.703
3	3	plan A	12.361	9	3	Plan B	12.365	15	3	Ninguno	11.396
4	1	plan A	16.194	10	1	Plan B	20.237	16	1	Ninguno	21.040
5	2	plan A	12.139	11	2	Plan B	14.305	17	2	Ninguno	14.572
6	3	plan A	12.951	12	3	Plan B	11.685	18	3	Ninguno	14.146

Entonces, para ajustar este modelo mediante regresión lineal, necesitaremos transformarlo primero en un modelo lineal. Para ello definiremos primero las nuevas variables x_1 , x_2 y x_3 cuyos valores serán:

$$x_1 = \begin{cases} 1 & \text{si } X_E = \text{plan A} \\ 0 & \text{si } X_E \neq \text{plan A} \end{cases}$$

$$x_2 = \begin{cases} 1 & \text{si } X_E = \text{plan B} \\ 0 & \text{si } X_E \neq \text{plan B} \end{cases}$$

$$x_3 = e^{-N}$$

El modelo entonces queda lineal:

$$T_c = T_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_N \cdot x_3 + \varepsilon$$

Para su ajuste, necesitaremos transformar la tabla de datos:

i	x_1	x_2	x_3	T_c	i	x_1	x_2	x_3	T_c	i	x_1	x_2	x_3	T_c
1	1	0	0.368	16.850	7	0	1	0.368	21.435	13	0	0	0.368	20.820
2	1	0	0.135	12.285	8	0	1	0.135	15.843	14	0	0	0.135	15.703

3	1	0	0.050	12.361	9	0	1	0.050	12.365	15	0	0	0.050	11.396
4	1	0	0.368	16.194	10	0	1	0.368	20.237	16	0	0	0.368	21.040
5	1	0	0.135	12.139	11	0	1	0.135	14.305	17	0	0	0.135	14.572
6	1	0	0.050	12.951	12	0	1	0.050	11.685	18	0	0	0.050	14.146

4. Regresión lineal mínimo cuadrática

La regresión lineal mínimo cuadrática es una técnica de optimización consistente en encontrar una función lineal, de acuerdo con un criterio de mínimo error cuadrático, que mejor se ajuste a un conjunto de datos. Para ello parte de una tabla como la anterior formada por datos de la variable dependiente y de las variables independientes.

La regresión lineal mínimo cuadrática minimiza la suma de cuadrados de las diferencias ordenadas (denominadas errores o residuos) entre los puntos generados por la función y los correspondientes a los datos.

Para que la regresión mínimo cuadrática funcione, es necesario que los errores de cada medida estén distribuidos de forma aleatoria. Como se verá más adelante, el teorema de Gauss-Markov prueba que los estimadores por mínimos cuadrados son centrados.

4.1. Residuos. Definiciones.

Como se ha indicado anteriormente, el propósito del ajuste de un modelo de regresión es obtener los valores de los parámetros que minimicen el error en la estimación del conjunto de datos disponibles.

Los errores obtenidos en el ajuste de la muestra de datos son denominados **residuos**. El residuo de la observación i , denominado ε_i , será igual a la diferencia entre el valor observado de la variable dependiente y el valor estimado por el modelo.

$$\varepsilon_i = y_i - \hat{y}_i = y_i - f(x_{1i}, \dots, x_{mi}, \beta_1, \dots, \beta_k) \quad (21)$$

Como medidas del error total obtenido en la estimación de la muestra de datos se emplean habitualmente la **suma de cuadrados de los errores (SCE)** y el **error cuadrático medio (ECM)**. Estas dos variables proporcionan una medida del grado de variabilidad presente en los residuos del modelo de regresión.

$$SCE = \sum_{i=1}^n \varepsilon_i^2 \quad (22)$$

$$ECM = \sqrt{\frac{SCE}{n-k}} \quad (23)$$

Otra medida habitualmente empleada en regresión es la **suma de cuadrados total**. Esta medida cuantifica el nivel de variabilidad presente en la variable dependiente.

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (24)$$

La **suma de cuadrados de la regresión** es la suma de cuadrados de las diferencias entre los valores estimados por el modelo y el valor medio de la variable dependiente. Esta variable proporciona una medida de la variabilidad presente en la variable y que es estimada por el modelo de regresión.

$$SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \quad (25)$$

4.2. Hipótesis del modelo.

La regresión por mínimos cuadrados se denomina así porque consiste en el ajuste de un modelo de regresión de tal manera que se minimice la suma de cuadrados de los errores en la estimación del conjunto de observaciones de una muestra de datos. Mediante mínimos cuadrados se pueden ajustar modelos de regresión lineal, y por tanto también modelos lineales en los parámetros convenientemente transformados.

Para que sea de aplicación, se asumen una serie de hipótesis sobre el término de error ε . Este término es la denominada componente probabilística del modelo de regresión y se establecerán las siguientes hipótesis sobre su distribución estadística.

- Los errores del modelo deben tener un valor esperado igual a cero: $E(\varepsilon) = 0$ para todo el rango de valores de las variables independientes.
- Los errores del modelo deben ser independientes entre distintas observaciones: $f(\varepsilon_i, \varepsilon_j) = f_i(\varepsilon_i) \cdot f_j(\varepsilon_j)$ donde f representa la distribución normal de los errores.
- Los errores del modelo deben presentar una distribución normal: $\varepsilon \sim N(0, \sigma_\varepsilon)$.
- La desviación de la distribución de errores, σ_ε , debe de ser constante y no depender del valor de ninguna variable independiente.

Si se considera el vector de n componentes, formado por los residuos de cada una de las n observaciones de la tabla de datos, es decir $\vec{\varepsilon} = [\varepsilon_1, \dots, \varepsilon_n]^T$, la matriz de covarianzas de los residuos se define como la matriz cuadrada de $n \times n$ dimensiones que contiene las covarianzas de todos los pares de componentes del vector:

$$\Sigma_{\vec{\varepsilon}} = [\sigma_{\varepsilon_i, \varepsilon_j}] = \begin{bmatrix} \sigma_{\varepsilon_1, \varepsilon_1} & \dots & \sigma_{\varepsilon_1, \varepsilon_n} \\ \dots & \dots & \dots \\ \sigma_{\varepsilon_n, \varepsilon_1} & \dots & \sigma_{\varepsilon_n, \varepsilon_n} \end{bmatrix} \quad (26)$$

Una consecuencia directa de las hipótesis anteriores es que en la matriz de covarianzas de los residuos es diagonal y todos los elementos de la diagonal son iguales a σ_ε^2 .

$$\Sigma_{\vec{\varepsilon}} = \begin{bmatrix} \sigma_{\varepsilon_1, \varepsilon_1} & \dots & \sigma_{\varepsilon_1, \varepsilon_n} \\ \dots & \dots & \dots \\ \sigma_{\varepsilon_n, \varepsilon_1} & \dots & \sigma_{\varepsilon_n, \varepsilon_n} \end{bmatrix} = \sigma_\varepsilon^2 \cdot \begin{bmatrix} 1 & \dots & 0 \\ \dots & \dots & \dots \\ 0 & \dots & 1 \end{bmatrix} = \sigma_\varepsilon^2 \cdot I_n \quad (27)$$

Aunque en caso de que estas hipótesis no se cumplan, los resultados del ajuste por mínimos cuadrados suelen ser aún buenos, es conveniente verificar que se cumplan las hipótesis para tener una mayor seguridad y confianza sobre los resultados de los test de significación del modelo ajustado que se verán posteriormente.

Con el fin de asegurar que un conjunto de datos verifica las hipótesis y por ello el método de mínimos cuadrados es aplicable, se realiza el denominado **análisis de los residuos**. Básicamente consiste en practicar una serie de pruebas sobre los residuos del modelo con el fin de determinar:

- Si su promedio es 0 para todos los puntos de la muestra.
- Si la varianza de los residuos es homogénea para todos los puntos de la muestra.
- Si los residuos de los distintos datos de la muestra son independientes entre sí.
- Si la hipótesis de normalidad es asumible.

Para ello se suele recurrir a **gráficas de residuos** que permiten una verificación visual de las hipótesis y a test estadísticos específicos que no serán tratados en este capítulo.

4.3. Método de mínimos cuadrados.

Dado un modelo de regresión lineal y un conjunto de datos, el método de mínimos cuadrados consiste en la optimización de los parámetros β de tal manera que la suma de cuadrados del error se minimice.

Es decir, se tratará de buscar la combinación de parámetros $\beta_0, \beta_1, \dots, \beta_{k-1}$ tales que se minimice:

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (28)$$

La estimación de los parámetros del modelo mediante mínimos cuadrados será, por tanto, un problema de optimización. Para resolverlo emplearemos una notación matricial consistente en definir una matriz X de $n \times k$ dimensiones que contenga unos en la primera columna y los valores de la tabla de datos en el resto de columnas, un vector $\vec{y} = [y_1, \dots, y_n]^T$ de n dimensiones con los valores de las variables dependientes de la tabla de datos, otro vector $\vec{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)$ de n dimensiones con los errores de cada observación de la tabla de datos y otro vector $\vec{\beta} = (\beta_0, \beta_1, \dots, \beta_{k-1})$ de k dimensiones con los valores estimados de los parámetros del modelo.

$$X = \begin{pmatrix} 1 & x_{1,1} & x_{2,1} & \dots & x_{k-1,1} \\ 1 & x_{1,2} & x_{2,2} & \dots & x_{k-1,2} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{1,n} & x_{2,n} & \dots & x_{k-1,n} \end{pmatrix} \quad (29)$$

Con las definiciones anteriores, es inmediato verificar que se cumple la siguiente ecuación:

$$\vec{y} = X \cdot \vec{\beta} + \vec{\varepsilon} \quad (30)$$

La suma de cuadrados del error será entonces igual al producto escalar del vector de errores consigo mismo, que despejando en función de X e $\vec{y}$ queda como:

$$SCE = \vec{\varepsilon}^T \cdot \vec{\varepsilon} = (\vec{y} - X \cdot \vec{\beta})^T \cdot (\vec{y} - X \cdot \vec{\beta}) = \vec{y}^T \cdot \vec{y} - \vec{\beta}^T \cdot X^T \cdot \vec{y} - \vec{y}^T \cdot X \cdot \vec{\beta} + \vec{\beta}^T \cdot X^T \cdot X \cdot \vec{\beta} = \vec{y}^T \cdot \vec{y} - 2 \cdot \vec{y}^T \cdot X \cdot \vec{\beta} + \vec{\beta}^T \cdot X^T \cdot X \cdot \vec{\beta} \quad (31)$$

En esta expresión, ha de notarse que $\vec{\beta}^T \cdot X^T \cdot X \cdot \vec{\beta}$ es una forma cuadrática ya que el producto de la traspuesta de una matriz por ella misma da como resultado una matriz cuadrada que, además, será simétrica ($X^T \cdot X$).

Como buscamos minimizar la suma de cuadrados de los residuos, derivaremos con respecto a $\vec{\beta}$ (usando las reglas de derivación de formas cuadráticas) e igualaremos a cero la expresión anterior. Al hacer los cálculos se tendrá presente que por ser $X^T \cdot X$ simétrica, se cumple que $X^T \cdot X = (X^T \cdot X)^T$.

$$\frac{d(SCE)}{d\vec{\beta}} = \frac{d(\vec{y}^T \cdot \vec{y})}{d\vec{\beta}} - \frac{d(2 \cdot \vec{y}^T \cdot X \cdot \vec{\beta})}{d\vec{\beta}} + \frac{d(\vec{\beta}^T \cdot X^T \cdot X \cdot \vec{\beta})}{d\vec{\beta}} = 0 - 2 \cdot X^T \cdot \vec{y} + X^T \cdot X \cdot \vec{\beta} + (X^T \cdot X)^T \cdot \vec{\beta} = -2 \cdot X^T \cdot \vec{y} + 2 \cdot X^T \cdot X \cdot \vec{\beta} = 0 \quad (32)$$

A partir de esta expresión podemos despejar el vector de parámetros $\vec{\beta}$:

$$X^T \cdot \vec{y} = X^T \cdot X \cdot \vec{\beta} \quad (33)$$

Y, por tanto:

$$\vec{\beta} = (X^T \cdot X)^{-1} \cdot X^T \cdot \vec{y} \quad (34)$$

Desde el punto de vista del cálculo numérico de los parámetros $\vec{\beta}$, la expresión anterior presenta problemas de estabilidad. Por ello no se suele emplear dicha fórmula de forma directa para la estimación de los parámetros.

Con el fin de facilitar la interpretación del resultado anterior, se pueden multiplicar los dos términos de la igualdad por la matriz X resultando:

$$X \cdot \vec{\beta} = X \cdot (X^T \cdot X)^{-1} \cdot X^T \cdot \vec{y} \quad (35)$$

Esta expresión define las denominadas **ecuaciones normales** de un modelo de regresión. Estas ecuaciones pueden ser simplificadas empleando la descomposición QR de X^1 . De esta manera se facilita notablemente el cálculo numérico del vector de parámetros mediante la resolución de un sistema de ecuaciones lineales como se ve a continuación:

¹ En álgebra lineal, la descomposición o factorización QR de una matriz es una descomposición de la misma como producto de una matriz ortogonal por una triangular superior. La descomposición QR es la base del algoritmo QR utilizado para el cálculo de los vectores y valores propios de una matriz. Consultar el enlace: http://es.wikipedia.org/wiki/Factorizaci%C3%B3n_QR

$$Q \cdot R \cdot \vec{\beta} = Q \cdot R \cdot [(Q \cdot R)^T \cdot Q \cdot R]^{-1} \cdot (Q \cdot R)^T \cdot \vec{y} \quad (36)$$

Que operando resulta:

$$Q \cdot R \cdot \vec{\beta} = Q \cdot R \cdot (R^T \cdot Q^T \cdot Q \cdot R)^{-1} \cdot (Q \cdot R)^T \cdot \vec{y} \quad (37)$$

Dado que $Q^T = Q^{-1}$, entonces:

$$Q \cdot R \cdot \vec{\beta} = Q \cdot R \cdot (R^T \cdot R)^{-1} \cdot (Q \cdot R)^T \cdot \vec{y} \quad (38)$$

Y a continuación, por las propiedades de la inversa de una matriz:

$$Q \cdot R \cdot \vec{\beta} = Q \cdot R \cdot R^{-1} \cdot R^{T^{-1}} \cdot R^T \cdot Q^T \cdot \vec{y} \quad (39)$$

Dado que los productos de las matrices R por sus inversas son iguales a la matriz identidad, queda:

$$Q \cdot R \cdot \vec{\beta} = \vec{y} \quad (40)$$

Finalmente, multiplicando por la inversa de Q resulta:

$$R \cdot \vec{\beta} = Q^T \cdot \vec{y} \quad (41)$$

Utilizando este resultado se simplifica notablemente el ajuste mediante mínimos cuadrados de un modelo de regresión.

4.4. Coeficiente de determinación

La relación existente entre la suma de cuadrados total y la suma de cuadrados de los residuos proporciona una medida del grado de ajuste del modelo de regresión a los datos de la muestra.

- Si la suma de cuadrados de los errores es muy parecida a la suma de cuadrados total, los errores de estimación del modelo serán elevados y parecidos a la variabilidad de y con respecto a su valor medio. Por tanto, no habrá una gran diferencia entre usar el modelo de regresión y usar simplemente el valor medio de y .
- Si la suma de cuadrados de los errores es baja en comparación a la suma de cuadrados total, los errores del modelo serán reducidos y por tanto el modelo de regresión permitirá realizar una estimación de y mucho más precisa que su valor medio.

Primeramente, obtendremos dos propiedades de interés sobre los residuos de un modelo de regresión ajustado mediante mínimos cuadrados. La ecuación (34) la podemos expresar como sigue:

$$X^T \cdot \vec{y} - X^T \cdot X \cdot \vec{\beta} = X^T \cdot (\vec{y} - X \cdot \vec{\beta}) = \vec{\varepsilon}^T \cdot X = \vec{0} \quad (42)$$

Dado que la primera columna de la matriz X es una columna de n unos, el producto del vector de residuos por un vector con todos sus elementos iguales a uno debe de ser igual a cero. Es decir:

$$\sum_{i=1}^n \varepsilon_i \cdot 1 = 0 \quad (43)$$

Por otro lado, multiplicando los términos de la ecuación (43) por $\vec{\beta}$ se obtiene:

$$\vec{\varepsilon}^T \cdot X \cdot \vec{\beta} = 0 \quad (44)$$

Y como $X \cdot \vec{\beta} = \vec{\hat{y}}$ donde $\vec{\hat{y}}$ es el vector de estimaciones de la variable dependiente para las observaciones de la muestra de datos dado por el modelo de regresión, se concluye que:

$$\vec{\varepsilon}^T \cdot \vec{\hat{y}} = \sum_{i=1}^n \varepsilon_i \cdot \hat{y}_i = 0 \quad (45)$$

Veremos a continuación la relación existente entre la suma de cuadrados total y la suma de cuadrados de la regresión y de los errores. Para ello desarrollaremos la suma de cuadrados total como sigue:

$$\begin{aligned} \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n ((y_i - \hat{y}_i) - (\bar{y} - \hat{y}_i))^2 \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + (\bar{y} - \hat{y}_i)^2 - 2 \cdot (y_i - \hat{y}_i) \cdot (\bar{y} - \hat{y}_i) \\ &= \sum_{i=1}^n \varepsilon_i^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \cdot \sum_{i=1}^n \varepsilon_i \cdot (\bar{y} - \hat{y}_i) \\ &= \sum_{i=1}^n \varepsilon_i^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \cdot \bar{y} \cdot \sum_{i=1}^n \varepsilon_i + 2 \cdot \sum_{i=1}^n \varepsilon_i \cdot \hat{y}_i \\ &= \sum_{i=1}^n \varepsilon_i^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \end{aligned} \quad (46)$$

La ecuación anterior implica que la suma de cuadrados total se puede expresar como la suma de cuadrados de la regresión más la suma de cuadrados de los residuos para un modelo ajustado mediante mínimos cuadrados. Esta relación se interpreta como que las desviaciones observadas de la variable dependiente con respecto a su media pueden ser expresadas como la suma de las desviaciones con respecto a la media explicadas por el modelo de regresión más las desviaciones de las observaciones con respecto a los valores predichos por el modelo de regresión. Es decir:

$$SCT = SCR + SCE \quad (47)$$

El cociente entre la suma de cuadrados de la regresión y la suma de cuadrados total es el denominado **coeficiente de determinación**. Representa el tanto por uno de las desviaciones observadas en la variable dependiente que son *explicadas* por el modelo de regresión.

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT} \quad (48)$$

Dado que el coeficiente de determinación R^2 representa la variabilidad de los datos que está siendo explicada por el modelo de regresión, en ocasiones es empleado como criterio para decidir si un modelo es adecuado para ajustar una muestra de datos. Un valor de R^2 elevado, cercano a 1, indica un buen ajuste y un R^2 reducido un mal ajuste. Sin embargo, como se verá posteriormente, esto no es necesariamente así. Un modelo con un R^2 elevado no necesariamente representa un buen ajuste y un modelo con un R^2 reducido puede ser útil. De hecho, se dan muchas situaciones en que una mejora en el R^2 , debido, por ejemplo, a incrementar el número de términos en el modelo, es causado por la inclusión de términos innecesarios en el modelo que no aportan información estadísticamente significativa. Esta cuestión será tratada posteriormente.

4.5. Coeficiente de determinación ajustado

Como se ha visto, el coeficiente de determinación R^2 cuantifica el porcentaje de variación de la variable dependiente en términos de las variables independientes. Al añadir más variables independientes este coeficiente tiende a aumentar y esto nos puede llevar a concluir de forma errónea que el modelo con más variables independientes es mejor: a este efecto se le conoce con el nombre de “sobreestimación del modelo”.

Debido a esto, la comunidad científica ha diseñado lo que se denomina coeficiente de determinación ajustado, R_a^2 :

$$R_a^2 = 1 - \frac{(n-1)(1-R^2)}{n-k-1} \quad (49)$$

Siendo n el número de observaciones de la muestra, k el número de variables independientes del modelo y R^2 el coeficiente de determinación sin ajustar.

Como se puede apreciar por la fórmula, conforme aumenta el número de variables independientes, k , el coeficiente de determinación ajustado disminuye. En consecuencia, el coeficiente de determinación ajustado está diseñado para penalizar la inclusión de más variables en el modelo.

El coeficiente de determinación ajustado permite comparar “en igualdad de condiciones” modelos con diferente número de variables independientes.

Finalmente, se debe tener en cuenta las siguientes observaciones:

- El coeficiente de determinación ajustado será siempre igual o menor que el coeficiente de determinación sin ajustar.

- Mientras que el coeficiente de determinación R^2 varía entre 0 y 1, el coeficiente de determinación ajustado R_a^2 podría ser negativo. Esto último ocurrirá cuanto más se aproxime k a n y cuando menor sea R^2 .

Ejemplo 7.

Continuando con el ejemplo 5, podemos calcular los residuos como las diferencias entre los valores observados T de la temperatura y los estimados $\hat{T}$ mediante el modelo de regresión:

$$\hat{T} = -1'54 + 11'03 \cdot V + 2'18 \cdot V^2$$

$$\varepsilon_i = T_i - \hat{T}_i = T_i - (-1'54 + 11'03 \cdot V_i + 2'18 \cdot V_i^2)$$

Los resultados aparecen en la tabla siguiente:

Observación i	V	V^2	T ($^{\circ}\text{C}$)	$\hat{T}$ ($^{\circ}\text{C}$)	ε
1	0.0	0.00	-2.014	-1.549	-0.466
2	0.2	0.04	6.118	0.746	5.372
3	0.4	0.16	-4.618	3.215	-7.833
4	0.6	0.36	6.818	5.858	0.960
5	0.8	0.64	10.760	8.675	2.084
6	1.0	1.00	13.965	11.668	2.297
7	1.2	1.44	11.162	14.834	-3.672
8	1.4	1.96	15.138	18.175	-3.038
9	1.6	2.56	25.310	21.691	3.619
10	1.8	3.24	30.200	25.381	4.820
11	2.0	4.00	25.101	29.245	-4.144

Entonces las sumas de cuadrados de los errores, de la regresión y totales resultan:

$$SCE = \sum_{i=1}^n \varepsilon_i^2 = 177'18$$

$$SCR = \sum_{i=1}^n (\hat{T}_i - \bar{T})^2 = 1049'59$$

$$SCT = \sum_{i=1}^n (T_i - \bar{T})^2 = 1226'77$$

El coeficiente de determinación resulta:

$$R^2 = \frac{1049'59}{1226'77} = 1 - \frac{177'18}{1226'77} = 0'856$$

Lo que nos dice que el modelo ajustado explica el 85.6% de la variabilidad observada de la temperatura.

4.6. Inferencia de los parámetros del modelo.

Partiremos del teorema de Gauss-Markov (cuya demostración será omitida) que nos informa sobre las características del estimador de los parámetros del modelo obtenido mediante mínimos cuadrados.

Teorema de Gauss-Markov: Asumiendo $E(\vec{\varepsilon}) = 0$, que la matriz de covarianzas del error es diagonal con todos los elementos de la diagonal iguales a la varianza del error ($\Sigma_{\vec{\varepsilon}} = \sigma_{\varepsilon}^2 \cdot I_n$) y que la parte determinística del modelo es correcta, entonces el estimador obtenido mediante el método de mínimos cuadrados $\hat{\vec{\beta}} = [\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{k-1}]^T$ constituye un **estimador insesgado** de los parámetros $\vec{\beta} = [\beta_0, \beta_1, \dots, \beta_{k-1}]^T$ del modelo y que, además, es un **estimador de varianza mínima**.

En primer lugar, consideraremos el cálculo de la varianza de los estimadores $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{k-1}$ de los parámetros del modelo. Para ello tendremos en cuenta que, de acuerdo con las hipótesis establecidas en la sección 2.2 de este capítulo, el valor esperado del error es 0 y éste presentará una distribución normal con varianza constante e igual a $\sigma_{\varepsilon}^2 \cdot I_n$ para cada uno de los datos de la muestra. Es decir:

$$\vec{\varepsilon} \sim N(\vec{0}, \sigma_{\varepsilon}^2 \cdot I_n) \quad (50)$$

Dado que $X \cdot \vec{\beta}$ es asumido como constante (por ser la parte determinística del modelo) y representa el valor esperado de la variable dependiente, el siguiente resultado es consecuencia inmediata de lo anterior:

$$\vec{y} \sim N(X \cdot \vec{\beta}, \sigma_{\varepsilon}^2 \cdot I_n) \quad (51)$$

Nos basaremos entonces en la ecuación (34), para obtener la matriz de covarianzas de los parámetros del modelo. En primer lugar, aplicaremos el operador esperanza a los dos términos para calcular el valor esperado del estimador:

$$\begin{aligned} E[\hat{\vec{\beta}}] &= E[(X^T \cdot X)^{-1} \cdot X^T \cdot \vec{y}] = E[(X^T \cdot X)^{-1} \cdot X^T \cdot (X \cdot \vec{\beta} + \vec{\varepsilon})] = \\ &= E[(X^T \cdot X)^{-1} \cdot X^T \cdot X \cdot \vec{\beta} + (X^T \cdot X)^{-1} \cdot X^T \cdot \vec{\varepsilon}] = \\ &= E[I_k \cdot \vec{\beta} + (X^T \cdot X)^{-1} \cdot X^T \cdot \vec{\varepsilon}] \end{aligned} \quad (52)$$

Dado que $(X^T \cdot X)^{-1} \cdot X^T$ es un término constante, $E[(X^T \cdot X)^{-1} \cdot X^T \cdot \vec{\varepsilon}] = (X^T \cdot X)^{-1} \cdot X^T \cdot E[\vec{\varepsilon}]$ y como se había establecido la hipótesis de que $E[\vec{\varepsilon}] = \vec{0}$ entonces queda:

$$E[\hat{\vec{\beta}}] = \vec{\beta} \quad (53)$$

Esto permite comprobar que el estimador $\hat{\vec{\beta}}$ es un estimador insesgado de $\vec{\beta}$.

A continuación, obtendremos la matriz de covarianzas del estimador $\hat{\beta}$, que será una matriz $\Sigma_{\hat{\beta}}$ cuyos elementos serán las covarianzas entre los estimadores de los parámetros del modelo $\sigma_{\hat{\beta}_i, \hat{\beta}_j}$.

$$\Sigma_{\hat{\beta}} = \begin{bmatrix} \sigma_{\hat{\beta}_0, \hat{\beta}_0} & \cdots & \sigma_{\hat{\beta}_0, \hat{\beta}_{k-1}} \\ \vdots & \ddots & \vdots \\ \sigma_{\hat{\beta}_{k-1}, \hat{\beta}_0} & \cdots & \sigma_{\hat{\beta}_{k-1}, \hat{\beta}_{k-1}} \end{bmatrix} \quad (54)$$

Para su cálculo, partiremos de la siguiente propiedad de la matriz de covarianzas $\Sigma_{\vec{z}}$ del producto de un vector $\vec{x}$ por una matriz constante A :

$$\Sigma_{\vec{z}} = \Sigma_{A \cdot \vec{x}} = A \cdot \Sigma_{\vec{x}} \cdot A^T \quad (55)$$

Donde $\Sigma_{\vec{x}}$ es la matriz de covarianzas de $\vec{x}$.

Por ello, partiendo de la ecuación (34):

$$\Sigma_{\hat{\beta}} = (X^T \cdot X)^{-1} \cdot X^T \cdot \Sigma_{\vec{y}} \cdot ((X^T \cdot X)^{-1} \cdot X^T)^T \quad (56)$$

De acuerdo con las hipótesis del modelo $\Sigma_{\vec{y}} = \sigma_e^2 \cdot I_n$. Substituyendo en la ecuación anterior y operando resulta:

$$\Sigma_{\hat{\beta}} = (X^T \cdot X)^{-1} \cdot X^T \cdot \sigma_e^2 \cdot I_n \cdot X \cdot (X^T \cdot X)^{-1} = \sigma_e^2 \cdot (X^T \cdot X)^{-1} \cdot X^T \cdot X \cdot (X^T \cdot X)^{-1} = \sigma_e^2 \cdot (X^T \cdot X)^{-1} \quad (57)$$

Por tanto, la distribución del estimador $\hat{\beta}$ será:

$$\hat{\beta} \sim N(\vec{\beta}, \sigma_e^2 \cdot (X^T \cdot X)^{-1}) \quad (58)$$

Al ajustar un modelo de regresión a un conjunto de datos, la desviación de los errores σ_e será generalmente desconocida. Es por ello que generalmente se empleará su estimador s_e dado por el error cuadrático medio de los residuos. Es decir:

$$s_e = ECM = \sqrt{\frac{SCE}{n-k}} \quad (59)$$

Donde $n - k$ son los grados de libertad de los residuos.

Entonces el **estadístico t_i para el parámetro β_i dado por la ecuación (51) presentará una distribución t de Student con $n - m$ grados de libertad**. Este resultado puede ser usado para obtener intervalos de confianza de los parámetros del modelo y para la realización de test de hipótesis de la significación de los parámetros del modelo.

$$t_i = \frac{\hat{\beta}_i}{s_{\hat{\beta}_i}} \quad (60)$$

Donde $s_{\hat{\beta}_i}$ será la desviación estándar muestral del parámetro β_i calculada como la raíz cuadrada del elemento i de la diagonal de la matriz de covarianzas de los parámetros $\Sigma_{\hat{\beta}}$.

4.7. Test t para la significación de los parámetros del modelo.

Una primera duda que surge a la hora de analizar los resultados de un análisis de regresión es si los parámetros del modelo aportan información estadísticamente significativa o no. Para responder a esta cuestión, se formula un test en el que se comparan las dos siguientes hipótesis:

- H_0 : El parámetro $\beta_i = 0$.
- H_1 : El parámetro $\beta_i \neq 0$.

En caso de cumplirse la hipótesis nula H_0 , el valor esperado del estadístico t_i debería de ser igual a 0 por la ecuación (51). Sabiendo que este estadístico presenta una distribución t de $n - k$ grados de libertad, estableceremos entonces una región de no rechazo de la hipótesis nula dada por el intervalo $(-t_{\alpha/2, n-k}, t_{\alpha/2, n-k})$ donde $(1 - \alpha) \cdot 100\%$ es el nivel de confianza establecido para el test y $t_{\alpha/2}$ es el valor del estadístico t tal que $P(T \geq t_{\alpha/2, n-k}) = \alpha/2$.

El resultado del test dependerá entonces del valor t_i observado:

- Si $t_i \in (-t_{\alpha/2, n-k}, t_{\alpha/2, n-k})$ entonces no se rechaza H_0 y por tanto, con la información disponible, no hay evidencia de que el parámetro β_i sea significativo.
- Si $t_i \notin (-t_{\alpha/2, n-k}, t_{\alpha/2, n-k})$ entonces se rechaza H_0 y por tanto se interpreta que el parámetro β_i tiene un efecto significativo en el modelo.

Además, el valor P del test podrá ser calculado como la probabilidad de que una variable T que presente una distribución de Student de $n - k$ grados de libertad. Es decir:

$$P(T \geq |t_i|) = p \quad (61)$$

4.8. Intervalos de confianza de los parámetros del modelo.

De manera análoga al test de significación de los parámetros, la distribución del estadístico t_i del parámetro β_i puede ser empleada para la obtención del intervalo de confianza de los parámetros del modelo. Para un nivel de confianza $(1 - \alpha) \cdot 100\%$ dado, el intervalo de confianza para el parámetro será:

$$\hat{\beta}_i - t_{\alpha/2, n-k} \cdot s_{\hat{\beta}_i} \leq \beta_i \leq \hat{\beta}_i + t_{\alpha/2, n-k} \cdot s_{\hat{\beta}_i} \quad (62)$$

Donde $t_{\alpha/2}$ será el valor tal que $P(T \geq t_{\alpha/2, n-k}) = \alpha/2$ donde T presenta una distribución t de Student con $n - k$ grados de libertad.

Ejemplo 8.

Continuando con el ejemplo 7, veremos a continuación cómo plantear un test estadístico para determinar la significación de los parámetros del modelo. Los valores de los parámetros presentados anteriormente fueron obtenidos mediante mínimos cuadrados. Para su cálculo se utilizó el complemento de análisis de datos de Excel. Los valores ajustados fueron: $\widehat{\beta}_0 = -1'54$, $\widehat{\beta}_1 = 11'03$ y $\widehat{\beta}_2 = 2'18$. Excel nos proporciona además los valores de las desviaciones estándar estimadas de los parámetros de manera que no es necesario calcular la matriz de covarianzas $\widehat{\Sigma}_{\widehat{\beta}}$ de forma manual.

$$\begin{array}{ll} \widehat{\beta}_0 = -1,54 & s_{\widehat{\beta}_0} = 3,58 \\ \widehat{\beta}_1 = 11,03 & s_{\widehat{\beta}_1} = 8,34 \\ \widehat{\beta}_2 = 2,18 & s_{\widehat{\beta}_2} = 4,01 \end{array}$$

La pregunta que trataremos de responder a continuación es si estos valores son estadísticamente significativos o podrían haber sido fruto del azar en el proceso de muestreo. Para ello, en primer lugar, calculamos los valores de los estadísticos t_i para cada parámetro mediante la ecuación (60).

$$\begin{array}{l} t_0 = -0,43 \\ t_1 = 1,32 \\ t_2 = 0,54 \end{array}$$

A continuación, obtendremos la región de no rechazo del test. Para un nivel de confianza del 95% ($\alpha = 0.05$) entonces, usando la distribución inversa de la t de Student con $11 - 3 = 8$ grados de libertad, resulta: $P(T \geq t_{\alpha/2}) = 0.025 \rightarrow t_{\alpha/2} = 2.306$. Por tanto el intervalo de rechazo de la hipótesis nula será $-2.306 \leq t_i \leq 2.306$. Vemos en la tabla anterior que todos los valores de los estadísticos están en la región de no rechazo. Por tanto, el resultado del test es que **no se puede rechazar la hipótesis nula**. Los valores de los parámetros ajustados no son significativamente distintos de cero.

Una manera alternativa de realizar el test es a partir del cálculo del p-valor, que nos proporciona Excel. Para ello habría que calcular la probabilidad de que la variable T con una distribución T de Student de 8 grados de libertad tuviese un valor mayor que el valor absoluto de los estadísticos t_i : $P_i = P(|T| \geq |t_i|)$. Los valores, ya calculados por Excel se muestran en la tabla:

i	t_i	P_i
0	-0.43	0.677
1	1.32	0.222
2	0.54	0.602

A partir del valor P , y dado un nivel de confianza del 95% ($\alpha = 0.05$), si $P < \alpha$ se rechaza la hipótesis nula y en caso contrario no se rechaza. En este caso como para todos los parámetros

se cumple que $P_i > 0.05$, no se puede rechazar la hipótesis nula de que los parámetros sean 0.

En este caso comprobamos que, aunque el valor de del coeficiente de determinación $R^2 = 0.85$ es elevado, ninguno de los parámetros del modelo ha sido hallado significativo y caben dudas si la información reportada es realmente útil. Para aclarar cuál es el problema, se podrían obtener más datos para la muestra (se incrementa la potencia del test) o probar a eliminar parámetros del modelo para quedarse con los más significativos.

Si ajustamos un modelo $T = \beta_0 + \beta_1 \cdot V + \varepsilon$ entonces obtenemos la tabla de resultados siguiente y un $R^2 = 0.850$:

i	$\hat{\beta}_i$	$s_{\hat{\beta}_i}$	t_i	P_i
0	-2.85	2.54	-1.12	0.291
1	15.40	2.16	7.15	0.000

Como vemos, el coeficiente de determinación R^2 apenas ha variado (de 0.856 a 0.850) con respecto al modelo anterior, por lo que ambos modelos explican una fracción de la varianza de la temperatura similar. Además, en el nuevo modelo, el parámetro β_1 es significativo ya que el valor P es muy bajo. Esto significa que podemos asumir con gran seguridad que su valor no es cero. Se ve entonces que en el modelo anterior el parámetro β_2 no aportaba información relevante y su inclusión en el modelo estaba causando que el test de significación del parámetro β_1 tuviera menos potencia y nos diera un resultado incorrecto.

Por último, si calculamos el coeficiente de determinación ajustado de cada uno de los modelos resulta un valor de 0.81947 para el modelo $T = \beta_0 + \beta_1 \cdot V + \beta_2 \cdot V^2 + \varepsilon$ y un valor de 0.83361 para el modelo $T = \beta_0 + \beta_1 \cdot V + \varepsilon$ lo que viene a reforzar las conclusiones anteriores:

Modelo	$R_a^2 = 1 - \frac{(n-1)(1-R^2)}{n-k-1}$
$T = \beta_0 + \beta_1 \cdot V + \beta_2 \cdot V^2 + \varepsilon$	$R_a^2 = 1 - \frac{(10-1)(1-0.85557)}{10-2-1} = 0.81947$
$T = \beta_0 + \beta_1 \cdot V + \varepsilon$	$R_a^2 = 1 - \frac{(10-1)(1-0.85025)}{10-1-1} = 0.83361$

Por último, podemos calcular el intervalo de confianza para los parámetros del último modelo ajustado $T = -2.85 + 15.40 \cdot V + \varepsilon$. Para ello empleamos la ecuación (62), en la que $t_{0.025} = 2.306$ para un nivel de confianza del 95%. El resultado es $\hat{\beta}_1 - t_{0.025} \cdot s_{\hat{\beta}_1} \leq \beta_1 \leq \hat{\beta}_1 + t_{0.025} \cdot s_{\hat{\beta}_1} \rightarrow 10.52 \leq \beta_1 \leq 20.27$.

5. Problemas

12-1. AENOR (Asociación Española para la Normalización y Racionalización) especifica que las emisiones electromagnéticas radiadas por dispositivos se deben medir en un sitio de prueba a campo abierto. Para que el sitio sea aceptable se debe evaluar la atenuación del sitio (es decir, la pérdida de transmisión desde la entrada de un dipolo de media onda hasta la salida de otro cuando ambos dipolos se colocan sobre el plano de tierra). Un estudio realizado en un sitio de prueba en Pontevedra produjo los siguientes datos (ver tabla) de atenuación del sitio (en decibelios, dBL) y frecuencia de transmisión (en megahercios, MHz) para dipolos a una distancia de 3 metros.

MHz	50	100	200	300	400	500	600	700	800	900	1000
dBL	11'5	15'8	18'2	22'6	26'2	27'1	29'5	30'7	31'3	32'6	34'9

Tomando como variable dependiente los decibelios:

- Efectuar un análisis de la regresión mediante Excel y determinar si los coeficientes de regresión son significativamente distintos de cero. Tómese $\alpha = 0.05$
- Obtenga, de forma gráfica, la ecuación de la recta de regresión que relaciona la atenuación del sitio (variable Y) con la frecuencia de transmisión (variable X).
- Determine el coeficiente de correlación ρ de ambas variables.
- Interprete el valor del coeficiente de correlación.

12-2. Dos variables aleatorias tienen las rectas de regresión:

$$\begin{aligned} 3x + 2y - 26 &= 0 \\ 6x + y - 31 &= 0 \end{aligned}$$

Determinar los valores medios de X e Y así como su coeficiente de correlación

12-3. Con el fin de determinar el personal necesario, la dirección de un parque acuático desea obtener un modelo de regresión que le permita predecir las visitas que recibe en un día. Para ello ha ajustado el modelo $y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_3$ donde y es el número de visitas en el día, x_1 es igual a 1 si el día es sábado, domingo o festivo, x_2 es igual a 1 si es un día nublado y 0 si es soleado y x_3 es la temperatura en $^{\circ}\text{F}$.

Cuenta con una tabla de 30 valores de los cuales se ha obtenido el siguiente ajuste por mínimos cuadrados:

i	β_i	S_{β_i}
0	105	
1	25	10
2	-100	30
3	10	4

- a) ¿Se puede afirmar que las visitas son mayores en fin de semana o festivo? Si es así, dar un intervalo de confianza bilateral para este efecto.
- b) ¿Se puede afirmar que las visitas son mayores en días soleados? Si es así, dar un intervalo de confianza bilateral para este efecto.
- c) ¿Se puede afirmar que al aumentar la temperatura aumentan linealmente las visitas?

Emplear $\alpha = 0,05$.

12.4 Una empresa de autobuses está interesada en determinar en qué medida el precio de la gasolina afecta al número de pasajeros que hacen uso de sus servicios. Se tiene una muestra de datos correspondiente a distintos meses con diferentes precios de la gasolina y dos tipos de rutas: urbanas y mixtas (urbana-extra radio). Para el estudio se va a ajustar el siguiente modelo de regresión:

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_1 \cdot x_2 + \varepsilon$$

Dónde y es el total de pasajeros por bus en 1 mes, x_1 es el precio medio del combustible en 1 mes. Finalmente, x_2 es igual a 1 si es ruta urbana y 0 si es ruta mixta.

Se dispone de la siguiente tabla de datos:

Tabla de datos		
Precio Combustible	Ruta	Total Pasajeros
1,22	Urbana	548
1,12	Urbana	538
1,30	Mixta	576
1,39	Urbana	547
1,22	Mixta	577
1,16	Urbana	541
1,09	Mixta	560
1,17	Urbana	545
1,27	Urbana	535
1,11	Urbana	535
1,39	Mixta	583
1,37	Urbana	549
1,02	Urbana	537
1,23	Mixta	575
1,22	Urbana	542
1,04	Urbana	537
1,17	Urbana	541
1,28	Urbana	544
1,14	Urbana	534
1,13	Mixta	564

Esta tabla se ha ajustado mediante regresión, proporcionando las siguientes estimaciones de los parámetros:

	β_3	β_2	β_1	β_0
$\hat{\beta}$	-42.93	22.20	74.50	481.11
$S_{\hat{\beta}}$	18.03	22.02	15.31	18.84

- Obtener el coeficiente de determinación del modelo R^2 .
- Usando $\alpha = 0,05$, ¿concluiría que el total de pasajeros aumenta con el precio del combustible en rutas mixtas?
- Usando $\alpha = 0,05$, ¿concluiría que el total de pasajeros aumenta con el precio del combustible más en las rutas urbanas que en las mixtas?

12.5 Se ha realizado un estudio de demanda de tráfico de transporte público en la ciudad de Albuquerque (Nuevo México). Concretamente, interesa determinar la tasa de viajes que hacen uso del sistema “Sun Trans”. El modelo pretende estimar la tasa de viajes “hogar-destino” que se define como el número de viajes entre el hogar y un destino dado por 1000 residentes en un área suburbana. Como predictores del modelo de regresión se usan las siguientes variables relacionadas con el nivel de servicio del sistema de transporte público:

- X1: Tiempo de viaje en vehículo hasta el destino.
- X2: Tiempo total de espera perdido en las conexiones entre líneas (incluyendo el tiempo de acceso hasta las paradas, cambios entre líneas, etc.).
- X3: Número de transferencias entre líneas necesarias para llegar hasta el destino.
- X4: Número de líneas de transporte en el sistema “Sun Trans” que atienden la zona del viaje.
- X5: 1 si el destino se encuentra en la zona cubierta por el sistema y 0 en caso contrario.

Se cuenta con una muestra de datos de 298 pasajeros a partir de la cual, mediante regresión lineal, se han obtenido los siguientes resultados:

	β_5	β_4	β_3	β_2	β_1	β_0
$\hat{\beta}$	21,689	3,095	-5,355	-0,229	-0,196	25,223
$S_{\hat{\beta}}$	1,291	0,388	0,822	0,063	0,019	2,235

$$SCR = 48098,75; SCE = 25028,02$$

Se pide:

- Escribir la ecuación del modelo de regresión que se usaría para estimar la tasa de viajes “hogar-destino”.
- Calcular el coeficiente de determinación R^2 e interpretar su significado.
- ¿La muestra aporta evidencia de que la tasa de viajes (y) se reduce cuando aumenta el tiempo de viaje dentro de vehículo (x1)? Testear la hipótesis con $\alpha = 0,01$.

- d) Calcula un intervalo de confianza del 95% para la reducción en tasa de viajes que corresponde a destinos fuera del sistema “Sun Trans”.
- e) Calcula la tasa de viajes esperada para el siguiente trayecto*:

Tramo	Tiempo (min)
Hogar - Parada	5
Espera Línea 3	6
Tránsito Línea 3	18
Cambio a línea 7	7
Tránsito en línea 7	12

* En el trayecto indicado hay 2 líneas del sistema Sun Trans que cubren la zona del viaje y el destino sí está cubierto por dicho sistema.

12.6 Se desea calibrar un sensor de ultrasonidos para medir la profundidad de los defectos en la superficie de un oleoducto. Para ello se han comparado un conjunto de pruebas realizadas mediante el sensor con mediciones precisas en laboratorio. Las pruebas han sido realizadas en tres lotes en fechas distintas por personas distintas. En total se han obtenido 124 mediciones y se ha ajustado el siguiente modelo de regresión:

$$y = \beta_0 \cdot x_1^{\beta_1} \cdot \beta_2^{x_2} \cdot \beta_3^{x_3} \cdot e^{\varepsilon}$$

Donde y es la profundidad del defecto medida en laboratorio, x_1 es la profundidad medida por el sensor y x_2 y x_3 son variables auxiliares que codifican el lote de medición:

- Lote 1. $x_2 = 0$ y $x_3 = 0$.
- Lote 2. $x_2 = 1$ y $x_3 = 0$.
- Lote 3. $x_2 = 0$ y $x_3 = 1$.

Resultados del ajuste mediante mínimos cuadrados:

	$\beta'_0 = \ln(\beta_0)$	β_1	$\beta'_2 = \ln(\beta_2)$	$\beta'_3 = \ln(\beta_3)$
$\hat{\beta}$	-0,0816	1,0516	0,0579	0,0094
$S_{\hat{\beta}}$	0,0934	0,0279	0,0411	0,0467

Además, $SCR = 49.972$ y $SCE = 3.468$.

- a) Indicar cómo se debe transformar este modelo para poder ajustar los parámetros mediante regresión lineal.
- b) Calcular el coeficiente de determinación R^2 del modelo y el error cuadrático medio ECM .
- c) Estimar un intervalo de confianza del 95% para el parámetro β_1 .
- d) Contrastar con nivel de significación $\alpha = 0.01$ si hay diferencias significativas entre las mediciones de los lotes 2 y 3 respecto al lote 1.

12.7 Se ha realizado una entrevista a 80 productores que operan en Brasil y se ha obtenido información sobre el modo de transporte usado para el transporte de la mercancía frente al tipo de mercancía (graneles o contenerizada).

		Modo			Total
		Carretera	Ferrocarril	Mar	
Mercancía	Graneles	16	8	7	31
	Contenedores	37	4	8	49
Total		53	12	15	80

Por otro lado, se ha recopilado una muestra de 60 datos de tiempos de viaje T (horas) en función del modo de transporte y la distancia en km. Se ha ajustado un modelo de regresión lineal para las variables:

- Modo de transporte:
 - Carretera: $x_1 = 0$ y $x_2 = 0$.
 - Ferrocarril: $x_1 = 1$ y $x_2 = 0$.
 - Mar: $x_1 = 0$ y $x_2 = 1$.
- Distancia x_3 .

$$T = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_3 \cdot x_3 + \beta_4 \cdot x_1 \cdot x_3 + \beta_5 \cdot x_2 \cdot x_3 + \varepsilon$$

El ajuste ha proporcionado los parámetros:

Variables $\Rightarrow$	x_1	x_2	x_3	$x_1 \cdot x_3$	$x_2 \cdot x_3$	Término independiente
Parámetro $\hat{\beta}$	12	40	0,02	0,0425	0,03	4
$s_{\hat{\beta}}$	3	10	0,005	0,006	0,006	2

AYUDA: Al asumir un modelo lineal, el tiempo de viaje T para cada modo será una función del tipo $T = \beta_c + \beta_v \cdot x_3$ donde β_c (h) es un término constante que corresponde a los tiempos para carga y descarga más demoras en terminales y β_v (h/km) es un parámetro que corresponde a la inversa de la velocidad media en tránsito (expresada en km/h).

- ¿Se puede afirmar que existe algún tipo de dependencia entre el modo elegido y el tipo de mercancía? Contrastar con nivel de significación $\alpha = 0,05$.
- ¿Se puede afirmar que las velocidades para los modos carretera y ferrocarril son más lentas que por carretera? Plantear los test de hipótesis y contrastar con $\alpha = 0,05$.
- Dar un intervalo de confianza del 95% para el tiempo que la mercancía permanece en las terminales de ferrocarril y en las terminales portuarias.

- d) Si se hace una medición de velocidades de camiones en una carretera (y asumiendo que la desviación de la velocidad para carretera es un 25% de su media), ¿cuántos camiones se deben considerar en la muestra para que el intervalo de confianza de la media sea de $\pm 5 \text{ km/h}$.

ANEXO. Regresión con dos variables. Recta de regresión

Queremos considerar el caso particular de la regresión lineal de dos variables, es decir, la variable dependiente y es función lineal de una sola variable independiente x . Por consiguiente, tratamos de determinar la recta:

$$\hat{y} = \beta_0 + \beta_1 x$$

Siguiendo la notación del capítulo, el residuo valdrá:

$$\varepsilon = y - \hat{y} = y - \beta_0 - \beta_1 x$$

Calcularemos β_0 y β_1 con la condición:

$$E(y - \hat{y})^2 = E(\varepsilon^2) = E[y - \beta_0 - \beta_1 x]^2 = \min$$

por lo que ha de verificarse:

$$\frac{\partial E(\varepsilon^2)}{\partial \beta_0} = 0 \quad \frac{\partial E(\varepsilon^2)}{\partial \beta_1} = 0$$

Ahora bien, teniendo en cuenta que con el operador E indicamos sumas o integrales y que estas son permutables con la derivación, podemos poner:

$$\frac{\partial E(\varepsilon^2)}{\partial \beta_0} = E \left[\frac{\partial \varepsilon^2}{\partial \beta_0} \right] = E[-2(y - \beta_0 - \beta_1 x)] = 0$$

Luego:

$$E(y - \beta_0 - \beta_1 x) = 0 \Rightarrow \mu_y - \beta_0 - \beta_1 \mu_x = 0 \Rightarrow \mu_y = \beta_0 + \beta_1 \mu_x$$

Esta primera ecuación nos dice que el punto (μ_x, μ_y) pertenece a la recta de regresión. La segunda ecuación es:

$$\begin{aligned} \frac{\partial E(\varepsilon^2)}{\partial \beta_1} &= E \left[\frac{\partial \varepsilon^2}{\partial \beta_1} \right] = E[-2x(y - \beta_0 - \beta_1 x)] = 0 \Rightarrow \\ \Rightarrow E(xy - \beta_0 x - \beta_1 x^2) &= 0 \Rightarrow \alpha_{11} - \beta_0 \mu_x - \beta_1 \alpha_{20} = 0 \end{aligned}$$

De lo anterior se obtiene:

$$\beta_1 = \frac{\alpha_{11} - \mu_x \mu_y}{\alpha_{20} - \mu_x^2} = \frac{\mu_{11}}{\sigma_x^2}$$

Teniendo en cuenta que la recta pasa por el punto (μ_x, μ_y) podemos poner su ecuación en la forma:

$$\hat{y} - \mu_y = \frac{\mu_{11}}{\sigma_x^2}(x - \mu_x)$$

De la ecuación anterior resulta que el parámetro β_0 resulta valer:

$$\beta_0 = \mu_y - \beta_1 \mu_x$$

Como para obtener la recta de regresión se dispone de una tabla n pares de valores (x_i, y_i) , las fórmulas de los parámetros β_0 y β_1 se reducen a las fórmulas dadas a continuación. Primero de calcula β_1 y después β_2 :

$$\begin{aligned}\beta_1 &= \frac{\alpha_{11} - \mu_x \mu_y}{\alpha_{20} - \mu_x^2} = \frac{\frac{1}{n} \sum_{i=1}^n x_i y_i - \left(\frac{1}{n} \sum_{i=1}^n x_i\right) \left(\frac{1}{n} \sum_{i=1}^n y_i\right)}{\frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i\right)^2} \\ &= \frac{n \sum_{i=1}^n x_i y_i - (\sum_{i=1}^n x_i)(\sum_{i=1}^n y_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}\end{aligned}$$

$$\beta_0 = \frac{1}{n} \left(\sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i \right) = \bar{y} - \beta_1 \bar{x}$$

Resumiendo, los parámetros de la recta de regresión son:

$$\beta_1 = \frac{n \sum_{i=1}^n x_i y_i - (\sum_{i=1}^n x_i)(\sum_{i=1}^n y_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} \quad \beta_0 = \frac{1}{n} \left(\sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i \right) = \bar{y} - \beta_1 \bar{x}$$

Error de ajuste o varianza residual

Hemos determinado la recta de regresión con la condición de que sea $E(\varepsilon^2) = \text{mínimo}$. Denominamos error de ajuste o varianza residual a este valor $E(\varepsilon^2)$. Determinemos su valor:

$$\begin{aligned}E(\varepsilon^2) &= E(y - \beta_0 - \beta_1 x)^2 = E[y - (\mu_y - \beta_1 \mu_x) - \beta_1 x]^2 = E[(y - \mu_y) - \beta_1 (x - \mu_x)]^2 = \\ &= E\left[(y - \mu_y)^2 - 2\beta_1 (x - \mu_x)(y - \mu_y) + \beta_1^2 (x - \mu_x)^2\right] = \sigma_y^2 - 2\beta_1 \mu_{11} + \beta_1^2 \sigma_x^2\end{aligned}$$

Sustituimos ahora el valor β_1 y queda:

$$E(\varepsilon^2) = \sigma_y^2 - 2 \frac{\mu_{11}}{\sigma_x^2} \mu_{11} + \frac{\mu_{11}^2}{\sigma_x^4} \sigma_x^2 = \sigma_y^2 - \frac{\mu_{11}^2}{\sigma_x^2}$$

Esto nos indica que es $E(\varepsilon^2) \leq \sigma_y^2$. Sólo es $E(\varepsilon^2) = \sigma_y^2$ cuando $\mu_{11} = 0$. Si tenemos en cuenta que $\mu_{11} = \rho \sigma_x \sigma_y$ podemos poner la anterior ecuación en la forma siguiente:

$$E(\varepsilon^2) = \sigma_y^2 - \frac{\rho\sigma_x^2\sigma_y^2}{\sigma_x^2} = \sigma_y^2(1 - \rho^2)$$

Esta expresión da un significado muy claro acerca de ρ como medida de la *dependencia lineal* de y respecto de x . En primer lugar, obtenemos una acotación para ρ . Como el valor de $E(\varepsilon^2)$ tiene que ser no negativo, se tendrá:

$$0 \leq 1 - \rho^2 \leq 1 \Rightarrow 0 \leq \rho^2 \leq 1 \Rightarrow -1 \leq \rho \leq 1$$

$E(\varepsilon^2)$ disminuye cuando ρ se aproxima a uno de sus valores extremos ± 1 . Cuando $\rho = \pm 1$ entonces hay una dependencia lineal entre las dos variables. Por el contrario cuando ρ vale 0 las variables son incorrelacionadas. Podemos considerar que las variables aleatorias tienen una dependencia más o menos lineal según que ρ se aproxime más o menos a uno de sus valores extremos. Un valor $\rho > 0$ supone una *correlación positiva* lo que implica $\beta_1 > 0$. Análogamente $\rho < 0$ implica $\beta_1 < 0$ y la correlación es negativa.




Figura 2. Correlación positiva y negativa.

El coeficiente de determinación R^2 desempeña, en regresión lineal múltiple, el mismo papel que el coeficiente de correlación ρ^2 cuando el número de variables se reduce a dos: la dependiente y la independiente.

Cuando consideramos la regresión lineal de y sobre x el error o residuo es:

$$\varepsilon = y - \beta_0 - \beta_1 x$$

β_0 y β_1 son los valores que hemos calculado. Vamos a estudiar algunas propiedades de esta variable aleatoria ε . Su valor medio, teniendo en cuenta lo anterior, es:

$$E(\varepsilon) = \mu_y - \beta_0 - \beta_1 \mu_x = 0$$

Por consiguiente, tendremos:

$$VAR(\varepsilon) = E(\varepsilon^2) = \sigma_y^2(1 - \rho^2)$$

Esta es la razón por la que a $E(\varepsilon^2)$ se la denomina *varianza residual*: es la parte de la varianza que queda sin explicar por la recta de regresión o, lo que es lo mismo, es la varianza del residuo ε .

La covarianza de x con esta variable residual ε es:

$$\begin{aligned} COV(x, \varepsilon) &= E[(x - \mu_x)\varepsilon] = E[(x - \mu_x)(y - \mu_y + \beta_1\mu_x)] = \\ &= E\{(x - \mu_x)[(y - \mu_y) - \beta_1(x - \mu_x)]\} = E[(X - \mu_x)(y - \mu_y) - \beta_1(x - \mu_x)^2] = \\ &= \mu_{11} - \beta_1\sigma_x^2 = \mu_{11} - \frac{\mu_{11}}{\sigma_x^2}\sigma_x^2 = \mu_{11} - \mu_{11} = 0 \end{aligned}$$

Así pues, la variable residual ε está incorrelada con x . Por tanto, la posible correlación que puede existir entre las variables aleatorias x e y queda *completamente caracterizada por la recta de regresión*, en el sentido de que si en vez de la variable aleatoria y consideramos diferencias respecto de la recta de regresión es $COV(x, \varepsilon) = 0$.