

Capítulo 2

Análisis exploratorio de datos

(Revisión 01/2012)

1. Estadística descriptiva	1
2. Tabulación de una muestra con datos repetitivos: tabla de frecuencias.	2
3. Histograma. Diagrama acumulativo	4
4. Tabulación de una muestra con datos no repetitivos: tabla de frecuencias.	5
5. Medidas de tendencia central.....	8
6. Medidas de dispersión.	9
7. Otras medidas de dispersión.....	11
8. Medidas de forma.	12
9. Diagrama de cajas y bigotes.	14
10. Análisis de la estabilidad de las frecuencias relativas.....	16
11. Problemas.....	17

Después de un estudio en profundidad de este capítulo, el estudiante deberá ser capaz de:

- Calcular e interpretar la media, la varianza, la desviación típica, la mediana y el rango de una muestra.
- Construir gráficos a partir de los datos. Dibujar histogramas y diagramas de cajas y bigotes.

1. Estadística descriptiva

En primer lugar conviene introducir una serie de definiciones:

- **Unidad elemental o dato estadístico.** Es una unidad observada con su correspondiente valor de la característica examinada. Los datos estadísticos pueden ser:

- a) *cualitativos: éxito o fracaso, varón o hembra, pieza defectuosa o buena. También se llaman atributos.*
- cuantitativos: números discretos o continuos. También se llaman variables.*
- b) *De una o varias dimensiones.*

- **Población.** Es el conjunto de valores observados al examinar, en todos los elementos del colectivo, una característica medible X . Puede ser finita o infinita.

Ejemplos: las longitudes del diámetro exterior de las piezas que salen de una fabricación, el porcentaje de piezas defectuosas en los lotes de un proceso de fabricación, las resistencias de un determinado tipo de cables, etc.

- **Universo o colectivo.** Es el conjunto de elementos, unidades u objetos sobre los que se realiza el estudio.

Ejemplos: los individuos de un hospital, los coches fabricados por una determinada marca, los clientes de una casa comercial, etc.

- **Muestra.** Es una población parcial. Es un conjunto parcial de datos estadísticos obtenidos al considerar una parte del universo o colectivo y al examinar sobre cada uno de ellos la característica medible X considerada. Ejemplos:

- si en la producción en serie de tornillos se escogen los producidos en una hora y al examinar el peso de cada uno de ellos se obtiene una muestra $(x_1, x_2, \dots, x_n)$.
- si en un lote de N artículos se extraen n de ellos ($n \leq N$) examinando si son o no defectuosos se obtiene la muestra $(x_1, x_2, \dots, x_n)$ con $x_i = 1$ si la pieza es defectuosa y $x_i = 0$ si no lo es.

• **Serie estadística.** Conjunto de *datos ordenados*. Una serie estadística puede ser:

- Continua: los datos difieren de unos a otros en una cantidad tan pequeña como se quiera. Por ejemplo el peso, la altura de un conjunto de personas, ...
- Discreta: los datos son números discretos. Por ejemplo el número de piezas fabricadas, el número personas encuestadas, etc.

• **Variable aleatoria.** A veces interesa más que el resultado completo de un experimento aleatorio una cierta función de dicho resultado. Por ejemplo, al lanzar dos monedas al aire pueden ocurrir los siguientes sucesos.

CC, CF, FC, FF C = cara, F = cruz.

Se puede definir la variable aleatoria X como el número de caras que resultan en el experimento. Entonces:

$$X(CC) = 2, X(CF) = 1, X(FC) = 1, X(FF) = 0$$

Definición: Se llama variable aleatoria a una función cuyos valores dependen del resultado de un experimento aleatorio. Las variables aleatorias pueden ser:

- **discretas:** si la característica examinada en las unidades del colectivo toman valores numéricos discretos. Ejemplos: las notas de un grupo de alumnos, el número de artículos defectuosos en un lote
- **continuas:** si la característica examinada en las unidades del colectivo puede tomar valores numéricos correspondientes a un intervalo de números reales. Ejemplos: los pesos de los ejes producidos para la construcción de un determinado modelo de automóvil, la estatura de los ciudadanos de un país, la resistencia de un determinado tipo de cables.

2. Tabulación de una muestra con datos repetitivos: tabla de frecuencias.

Supóngase que el conjunto de observaciones $x_1, x_2, \dots, x_n$ corresponde a un fenómeno de carácter discreto:

- tiradas de un dado
- números de hijos de una familia
- número de unidades defectuosas de un lote de piezas

Entre todas las observaciones habrá un conjunto de valores distintos, que podemos denominar $x_{(1)}, x_{(2)}, \dots, x_{(r)}$. En el caso del dado es $r = 6$. En el segundo caso se puede poner $r = 20$. En el tercer caso la cota de r será el tamaño del lote aunque es de esperar que sea mucho más pequeña. En cualquiera de estos casos es de esperar que sea r mucho menor que n y será necesario agrupar los datos en la tabla de frecuencias. Ésta puede darse en la forma que se indicará a continuación y a partir de ella pueden hacerse representaciones o

determinar características del conjunto de datos. Para concretar ideas, supóngase el siguiente ejemplo.

Ejemplo 1. Se desea estudiar los resultados de una clase de cien alumnos en una asignatura. Los datos numéricos fueron:

4	4	4	4	4	5	5	4	4	4	6	2	4	5	7	4	4	4	6	5
5	4	5	6	4	5	6	6	3	7	1	7	5	6	5	3	7	3	4	6
4	4	4	6	6	6	3	4	8	1	7	3	3	6	3	4	4	6	5	5
2	5	4	4	6	5	5	5	5	4	3	5	3	2	2	5	6	3	3	2
5	6	4	6	2	5	7	5	4	3	2	4	6	4	6	3	6	5	3	6

A la vista de este conjunto de datos es difícil sacar conclusiones. Se hace necesario organizarlos.

Valores de la variable	Frecuencias absolutas	Frecuencias absolutas acumuladas	Frecuencias relativas	Frecuencias relativas acumuladas
0.0	0	0	0.00	0.00
1.0	2	2	0.02	0.02
2.0	7	9	0.07	0.09
3.0	14	23	0.14	0.23
4.0	28	51	0.28	0.51
5.0	22	73	0.22	0.73
6.0	20	93	0.20	0.93
7.0	6	99	0.06	0.99
8.0	1	100	0.01	1.00

En general se tiene:

Valores de la variable $x_{(i)}$	Frecuencia absoluta n_i	Frecuencias absoluta acumulada N_i	Frecuencia relativa f_i	Frecuencias relativa acumulada F_i
$x_{(1)}$	n_1	$N_1 = n_1$	$f_1 = \frac{n_1}{n}$	$F_1 = f_1$
$x_{(2)}$	n_2	$N_2 = n_1 + n_2$	$f_2 = \frac{n_2}{n}$	$F_2 = f_1 + f_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$x_{(r)}$	n_r	$N_r = n_1 + n_2 + \cdots n_r$	$f_r = \frac{n_r}{n}$	$F_r = f_1 + f_2 + \cdots f_r$
	$\Sigma n_i = n$	$N_r = n$	$\Sigma f_i = 1$	$F_r = 1$

Se define la **función de frecuencias** de la muestra de la siguiente forma:

$$f(x) = \begin{cases} f_i & \text{cuando } X = x_i \\ 0 & \text{cuando } X \neq x_i \end{cases}$$

La función de frecuencias nos hace ver cómo están distribuidos los valores de la muestra. Sus propiedades son:

$$0 \leq f_i \leq 1$$

$$\sum_{i=1}^r f_i = 1$$

Se define la **función de distribución** de la muestra por:

$$F(x) = \sum_{\forall x_{(i)} \leq x} f_i$$

$F(x)$ es la suma de las frecuencias relativas de todos los valores de la muestra que son menores o iguales que x . Se comprende que $F(x)$ es una función escalonada (función constante por intervalos) que tiene saltos en los puntos en que la frecuencia relativa no es nula.

3. Histograma. Diagrama acumulativo

El *histograma* consiste en levantar en la abscisa x_i una barra de longitud proporcional a su frecuencia relativa. Así para los datos del ejemplo 1 se tiene el histograma de la Figura 1.




Figura 1. Histograma de frecuencias (Ejemplo 1)

El *diagrama acumulativo* corresponde a la función de distribución de la muestra (función de frecuencias relativas acumuladas de la muestra). Para los datos del Ejemplo 1 se tiene la Figura 2.




Figura 2. Diagrama acumulativo (Ejemplo 1)

4. Tabulación de una muestra con datos no repetitivos: tabla de frecuencias.

Supóngase ahora que el conjunto de observaciones $x_1, x_2, \dots, x_n$ corresponde a un fenómeno de tipo continuo como puede ser las horas de vida de un tipo de lámpara o las estaturas de los individuos de una comunidad

Si estas medidas se hacen con suficiente precisión es posible que haya muy pocas que se repitan, aunque algunas difieran entre sí muy poco. Incluso es posible que sean todas diferentes. En este caso en la tabla de frecuencias sería $r \cong n$ e incluso $r = n$, en cuyo caso para todo valor i se cumpliría: $n_i = 1/n$.

Esta es la razón principal de que si se quiere hacer una representación *similar* a la hecha en con valores repetitivos, sea preciso introducir en el recorrido de los valores un conjunto de intervalos que comprendan varias observaciones. Si los intervalos son de la misma longitud el número de observaciones correspondientes nos dará una medida de la densidad de observaciones en el intervalo. A estos intervalos se les llama *intervalos de clase*. A los valores entre los cuales se encuentra comprendido el intervalo de clase se les denomina *límites de clase*.

Marcas de clase son los puntos medios de los intervalos: se designan por $x_{(1)}, x_{(2)}, \dots, x_{(r)}$.

Se denomina *frecuencia absoluta* de una clase al número de valores de la muestra que pertenecen al intervalo de dicha clase. La *frecuencia relativa* de la clase es su frecuencia absoluta dividida por el tamaño de la muestra.

Esta frecuencia relativa, considerada como función de las marcas de clase, se denomina función frecuencias de la muestra y se denota por $f(x)$ al igual que en el caso de datos no repetitivos. La función de frecuencias acumuladas de la muestra se denotará por $F(x)$ y se define como:

$$F(x) = \sum_{t \leq x} f(t)$$

La tabla de frecuencias relativas y acumuladas para una muestra tiene la siguiente forma:

Intervalo $a_i - a_{i+1}$	Marca de clase $x_{(i)}$	Frecuencia absoluta n_i	Frecuencia absoluta acumulada N_i	Frecuencia relativa f_i	Frecuencia relativa acumulada F_i
$a_1 - a_2$	$x_{(1)}$	n_1	$N_1 = n_1$	$f_1 = \frac{n_1}{n}$	$F_1 = f_1$
$a_2 - a_3$	$x_{(2)}$	n_2	$N_2 = n_1 + n_2$	$f_2 = \frac{n_2}{n}$	$F_2 = f_1 + f_2$
.	.	.	.	.	.
.	.	.	.	.	.
.	.	.	.	.	.
$a_r - a_{r+1}$	$x_{(r)}$	n_r	$N_r = n_1 + n_2 + \dots n_r$	$f_r = \frac{n_r}{n}$	$F_r = f_1 + f_2 + \dots f_r$
		$\Sigma n_i = n$	$N_r = n$	$\Sigma f_i = 1$	$F_r = 1$

Para la elaboración de esta tabla se adoptarán las siguientes directrices:

- Se elegirá la amplitud al intervalo de clase de forma que el error cometido al sustituir todos los valores de un intervalo por una marca de clase sea despreciable.
- Se redondeará el recorrido de la muestra para que resulte múltiplo de la amplitud elegida para el intervalo.
- Por comodidad los intervalos de clase se escogerán de manera que las marcas de clase correspondan a números sencillos.
- Es conveniente que los extremos de los intervalos tengan una cifra decimal más que las medidas de la muestra para que éstas no coincidan con ningún extremo.

En cuanto al número de intervalos no existe una regla general válida para todos los casos. Un número de clases aproximado puede obtenerse mediante la **regla de Sturges**:

$$k = 1 + 3.3 \log n$$

Donde k es el número de clases, n el número de observaciones y $\log$ es logaritmo decimal. Por ejemplo si se hacen 100 observaciones el número de clases $1 + 3.3 \times 2 = 7.6$ que puede redondearse a 8 clases. El número definitivo debería estar de acuerdo con el estudio que

se esté realizando, de forma que su número no sea muy pequeño (perderían significado los datos, y se acumularían errores) ni muy grande (pues nos dificultaría extraer conclusiones).

La utilización de intervalos de clase es útil para obtener representaciones gráficas más sencillas para fenómenos aleatorios de tipo continuo y además aclaran sus propiedades esenciales así como simplifican muchos datos, pero tiene el inconveniente de pérdida de información y, en consecuencia, si la inferencia estadística se basa en los datos no repetitivos, se pueden crear problemas de variedad de grados de exactitud que dependerán de los métodos de inferencia empleados. Se comete el llamado *error de agrupamiento*.

Ejemplo 2. Se ha conseguido una muestra de las estaturas de 50 trabajadores de una empresa. Los datos obtenidos, en centímetros, son:

173	163	169	168	163	167	171	170	174	172
172	178	165	171	170	167	172	168	171	164
171	173	167	168	170	170	169	173	166	179
171	168	169	164	156	168	173	175	178	179
167	170	166	173	172	159	168	165	160	178

Teniendo en cuenta lo anterior, elaboramos la siguiente tabla:

Intervalo $a_i - a_{i+1}$	Marca de clase $x_{(i)}$	Frecuencia absoluta n_i	Frecuencia absoluta acumulada N_i	Frecuencia relativa f_i	Frecuencia relativa acumulada F_i
153.5 – 157.5	155.5	1	1	0.02	0.02
157.5 – 161.5	159.5	2	3	0.04	0.06
161.5 – 165.5	163.5	6	9	0.12	0.18
165.5 – 169.5	167.5	15	24	0.30	0.48
169.5 – 173.5	171.5	19	43	0.38	0.86
173.5 – 177.5	175.5	2	45	0.04	0.90
177.5 – 181.5	179.5	5	50	0.10	1.00

De aquí se obtienen el siguiente histograma de la Figura 3.




Figura 3. Histograma (Ejemplo 2)

Y el diagrama acumulativo se da en la Figura 4.




Figura 4. Diagrama acumulativo (Ejemplo 2)

5. Medidas de tendencia central.

Las medidas de tendencia central más frecuentes son la media, la mediana y la moda. Veamos sus definiciones y fórmulas de cálculo.

Media (o valor medio) de una muestra: Dada una muestra $(x_1, x_2, \dots, x_n)$ de tamaño n , se define la media muestral $\bar{X}$ por:

$$\bar{X} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

La media es la principal medida de posición de los datos o tendencia central de la muestra.

La **mediana M** es el número tal que ordenados los datos de manera creciente, la mitad son inferiores a dicho número y la otra mitad son superiores.

Si el número total de datos, n , es impar, existe un único valor de la variable en el centro de la distribución, y éste es la mediana. En el caso de que n sea par, la mediana se define como la media aritmética de los dos valores centrales.

En consecuencia, si la muestra es $(x_1, x_2, \dots, x_n)$ y llamamos $x_{(i)}$ al i -ésimo valor de la muestra cuando la ordenamos de menor a mayor, entonces:

$$M = \begin{cases} x_{\left[\frac{(n+1)}{2}\right]} & \text{si } n \text{ es impar} \\ \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} & \text{si } n \text{ es par} \end{cases}$$

La **moda m** es el valor más frecuente.

Así, para el siguiente conjunto de datos:

$$(3, 7, 1, 8, 5, 9, 4, 2, 0, 2)$$

Obtenemos el conjunto de datos ordenados:

$$(0, 1, 2, 2, 3, 4, 5, 7, 8, 9)$$

Como el número de datos $n = 10$ es par, resulta que la mediana es:

$$M = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} = \frac{x_{(5)} + x_{(6)}}{2} = \frac{3 + 4}{2} = 3.5$$

Fácilmente se comprueba que la media es: $\bar{X} = 4.1$ y la moda $m = 2$.

6. Medidas de dispersión.

Las medidas de dispersión más frecuentes son la varianza (o, en su caso, su raíz cuadrada positiva, denominada desviación típica), el rango y la desviación absoluta media, DAM.

El rango se define como la diferencia entre los valores mayor y menor de una muestra.

Ahora vamos a introducir una *medida de dispersión* o variación de los valores de la muestra con respecto a la media. Considérense las dos muestras siguientes:

$$(20, 30, 40) \text{ y } (25, 30, 35)$$

Ambas tienen tamaño 3 y media 30. Sin embargo existe una diferencia esencial entre ellas porque los valores de la primera se encuentran más separados unos de otros (y, por lo tanto, también del valor medio) que los valores de la segunda muestra. Esto nos conduce a la necesidad de introducir una medida a la variabilidad que distinga a dos muestras que sean como las anteriores. La importancia de esta medida es obvia: una pequeña variabilidad en el proceso de producción de un cierto producto puede indicar una alta calidad.

Considérese el problema general. Sea una muestra $(x_1, x_2, \dots, x_n)$. En principio se podría usar como medida de variación con respecto a la media, la suma de las diferencias con respecto a la media, pero resulta que:

$$(x_1 - \bar{X}) + (x_2 - \bar{X}) + \dots + (x_n - \bar{X}) = 0$$

Como se puede comprobar fácilmente. Los valores de la muestra menores que la media dan lugar a diferencias negativas que se compensan exactamente con las diferencias positivas originadas por los valores de la muestra mayores que la media. Cabe entonces optar por dos soluciones:

- Considerar los cuadrados $(x_i - \bar{X})^2$
- Tener en cuenta los valores absolutos $|x_i - \bar{X}|$

El primer procedimiento necesita más cálculos pero los métodos estadísticos basados en él son mucho más sencillos. Por tanto se emplea un concepto que mide la variabilidad en función de los cuadrados de las diferencias con respecto a la media.

Dada la muestra $(x_1, x_2, \dots, x_n)$ se define la **varianza** de esta muestra, S^2 , como:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$$

A la raíz cuadrada positiva de la varianza se la denomina **desviación estándar** o **desviación típica** de la muestra, S :

$$S = +\sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2}$$

A la expresión:

$$DAM = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{X}|$$

se le llama **desviación absoluta media**. Esta expresión apenas se usa debido a las ventajas de cálculo de la varianza.

7. Otras medidas de dispersión.

En este apartado definiremos lo que se entiende por percentiles, cuartiles, rango intercuartílico y coeficiente de variación.

Definición de **percentiles** Q_p y Q_{1-p} :

Q_p es el primer valor tal que por debajo de él se tiene el $p\%$ de las observaciones

Q_{1-p} es el primer valor tal que por debajo de él se tiene el $(1-p)\%$ de las observaciones

Por consiguiente, los percentiles Q_p y Q_{1-p} son los primeros valores para los que:

$$F(Q_p) \geq p \quad F(Q_{1-p}) \geq 1 - p$$

Para el caso particular de $p = 25\%$ se tienen los **cuartiles** $Q_{0.25}$ y $Q_{0.75}$. Se comprende que el valor $Q_{0.50}$ es la mediana. Algunos libros de texto llaman denotan estos cuartiles por Q_1 y Q_3 . Nosotros seguiremos la notación correspondiente a los percentiles para unificar criterio.

Se define el **rango intercuartílico**, RIC, como la diferencia $RIC = Q_{0.75} - Q_{0.25}$

Evidentemente, para calcular los percentiles (y también el caso particular de los cuartiles), los datos de la muestra se han de ordenar de mayor a menor.

Así, para el siguiente conjunto de datos:

$$(3, 7, 1, 8, 5, 9, 4, 2, 0, 2)$$

Obtenemos el conjunto de datos ordenados:

$$(0, 1, 2, 2, 3, 4, 5, 7, 8, 9)$$

Resultando que los cuartiles son:

$$Q_{0.25} = 2, \quad Q_{0.75} = 7$$

El **coeficiente de variación**¹ es una medida de dispersión que se utiliza para comparar la dispersión de variables que utilizan las mismas unidades de medida o emplean escalas diferentes (es invariante a los cambios de escala). Lo denotaremos por la letra V y se calcula mediante:

¹ El coeficiente de variación fue introducido por Karl Pearson, matemático y estadístico inglés (1857-1936), fundador de la revista *Biométrie*. Hizo numerosas aportaciones a la Estadística.

$$V = \frac{S}{\bar{X}}$$

Este coeficiente no tiene dimensiones pues es el cociente de dos valores con la misma magnitud. A veces se expresa como un porcentaje:

$$V = \frac{S}{\bar{X}} \times 100\%$$

Sirve para comparar variables que están a distintas escalas pero que están correlacionadas estadísticamente y sustantivamente con un factor en común. Es decir, ambas variables tienen una relación causal con ese factor.

Este coeficiente es variable ante cambios de origen. Por ello es importante que todos los valores sean positivos. A mayor valor de V mayor heterogeneidad de los valores de la variable; y a menor V , mayor homogeneidad en los valores de la variable.

8. Medidas de forma.

En ocasiones interesa caracterizar la forma de la distribución de una serie de datos. Por ejemplo, si un histograma es o no simétrico. También si es más plano o más apuntado. De esta forma aparecen dos nuevas medidas que son los coeficientes de *asimetría* y *aplataamiento* (también denominado *curtosis*).

El **coeficiente de asimetría**, g_1 , se calcula mediante la siguiente fórmula:

$$g_1 = \frac{1}{S^3} \times \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^3$$

Este coeficiente, debido a Fisher², es tal que si vale cero, la distribución es simétrica respecto a la media (Figura 5). Si es positivo, la distribución está sesgada a la derecha (cola a la derecha) y si es negativo está sesgada a la izquierda (cola a la izquierda): véase Figura 6.




Figura 5. Distribución simétrica ($g_1 = 0$)

² Ronal Aylmer Fisher fue un matemático y estadístico inglés (1890-1962). Está reconocido como uno de los fundadores de la Estadística moderna por sus numerosas contribuciones.




Figura 6. Distribución sesgada a la derecha ($g_1 > 0$) y a la izquierda ($g_1 < 0$)

La curtosis es una medida de la forma o apuntamiento de las distribuciones. Mide la mayor o menor concentración de frecuencias alrededor de la media y en la zona central de la distribución.

El **coeficiente de apuntamiento**, g_2 , se calcula por la siguiente fórmula:

$$g_2 = \frac{1}{S^4} \times \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^4 - 3$$

Si para valores próximos a la moda la frecuencias son altas, la distribución se dice que es leptocúrtica ($g_2 > 0$). Si la distribución de frecuencias es muy aplanada diremos que es platocúrtica ($g_2 < 0$). Finalmente las distribuciones que no presentan un apuntamiento ni son muy planas diremos que son mesocúrticas ($g_2 = 0$). Véase Figura 7.




Figura 7. Distribuciones con diferentes coeficientes de apuntamiento (g_2)

9. Diagrama de cajas y bigotes.

El diagrama de cajas y bigotes (en inglés *Box and Whisker plot*) es un gráfico que sirve para visualizar un conjunto de datos y algunas medidas de centralización y dispersión. Está basado en los cuartiles.

Para dibujarlo se necesitan realizar los siguientes cálculos:

- Calcular los cuartiles: $Q_{0.25}$ y $Q_{0.75}$.
- Calcular el rango intercuartílico: $RIC = Q_{0.75} - Q_{0.25}$
- Calcular la media y la mediana
- Calcular el valor mínimo, MIN, y el máximo, MAX de los datos de partida.

Seguidamente se construye un rectángulo con los valores $Q_{0.25}$ y $Q_{0.75}$ como extremos. El rectángulo se divide por una línea a la altura del valor dado por la mediana.

Para dibujar los bigotes se han de calcular los límites inferior, L_i , y superior, L_s , que identifican los valores denominados atípicos. Los valores de estos límites son:

$$L_i = \max(MIN, Q_{0.25} - 1.5 \times RIC)$$

$$L_s = \min(MAX, Q_{0.75} + 1.5 \times RIC)$$

Estos valores sirven para dibujar las líneas horizontales que forman los bigotes. Los valores que caen fuera de estos límites son considerados atípicos y se representan en el gráfico.

Se consideran *atípicos extremos* aquellos valores que exceden los siguientes límites siguientes:

$$Q_{0.25} - 3 \times RIC$$

$$Q_{0.75} + 3 \times RIC$$

Todo lo anterior se muestra en la Figura 8.





Figura 8. Diagrama de cajas y bigotes

Este gráfico es de utilidad porque sirve para visualizar la distribución de los datos. Si la mediana no está en el centro la distribución no es simétrica.

Para los datos del Ejemplo 2 se obtiene el siguiente diagrama de cajas y bigotes (y debajo, una estadística de resumen).



<i>Resumen de una variable</i>	<i>Ejemplo 2</i>
Media	169.460
Varianza	24.049
Desviación estándar	4.904
Mediana	170.000
Mínimo	156.000
Máximo	179.000
Rango	23.000
Cuenta	50
1er cuartil	167.000
3er cuartil	172.000
Rango intercuartílico	5.000

De aquí, resulta para este ejemplo que:

$$L_i = \max(156.00, 167 - 1.5 \times 5) = \max(156.00, 159.50) = 159.5$$

$$L_s = \min(179.00, 172 + 1.5 \times 5) = \min(179.00, 179.55) = 179.5$$

Para ver los valores atípicos extremos calculamos:

$$Q_{0.25} - 3 \times RIC = 167 - 3 \times 5 = 152$$

$$Q_{0.75} + 3 \times RIC = 172 + 3 \times 5 = 187$$

Cómo se puede ver, hay dos valores atípicos moderados (correspondientes a los valores 156 y 159) y ningún valor atípico extremo.

10. Análisis de la estabilidad de las frecuencias relativas

Aunque ya se habló de esto en el capítulo de introducción, se vuelve a insistir debido a su importancia.

Sea A un suceso cualquiera asociado a la realización de un fenómeno aleatorio. Llamamos $n(A)$ a su frecuencia absoluta en n observaciones y $f(A) = n(A)/n$ a su frecuencia relativa. La estabilidad de las frecuencias relativas consiste en que se observa que $f(A)$ cuando n crece va oscilando cada vez con menos amplitud alrededor de cierto valor. Si se representan los sucesivos valores de $f(A)$ en función de n se obtiene la gráfica de la Figura 9.




Figura 9. Convergencia de la frecuencia relativa a la probabilidad

Se observa que las oscilaciones son cada vez de menor amplitud. Es claro que esto induce a tratar de *definir* esta característica como un límite. Esta característica se la denomina **probabilidad** del suceso A : $P(A)$. La probabilidad del suceso A , $P(A)$, no se puede definir como el siguiente límite:

$$P(A) \neq \lim_{n \rightarrow \infty} \frac{n(A)}{n}$$

Esto se debe a que la sucesión $n(A)/n$ no está definida matemáticamente, de tal forma que se pueda conocer el valor de $n(A)$ en función de n de alguna forma (ley de recurrencia, etc.). Esto impide definir el límite anterior en la forma que se hace en el Análisis Matemático. Será

necesario introducir un nuevo concepto de *convergencia*, la *convergencia en probabilidad* para poder expresar de una forma adecuada este hecho experimental de la estabilidad de las frecuencias.

11. Problemas.

2-1. Determinar la media y la desviación típica de la siguiente muestra de 50 edades de ejecutivos:

38	50	35	46	63	69	54	62	68	40
48	44	55	43	42	59	54	57	47	46
42	60	43	64	49	36	59	42	60	38
61	56	51	50	66	63	57	51	38	45
62	37	50	44	48	69	64	56	53	52

Obtener la tabla de frecuencias relativas y acumuladas. Dibujar el histograma de frecuencias y el diagrama acumulativo.

2-2. En una empresa se ha obtenido la siguiente tabla de salarios para cien trabajadores no cualificados:

Salario semanal (Ptas.)	Número de trabajadores
14000-16000	7
16000-18000	20
18000-20000	33
20000-22000	25
22000-24000	11
24000-26000	4
Total	100

- Dibujar el histograma de frecuencias.
- Determinar la función de distribución y dibujarla.
- Calcular el salario medio y la varianza de los salarios.

2-3. Un grupo de catadores de vino probaron la cosecha de 2006 de vino Albariño, dando cada uno una puntuación de 0 a 100. Las puntuaciones fueron las siguientes:

95	93	90	91	90	89	85	91	90	94
90	94	88	90	91	94	90	96	92	94

- Calcular la media, la mediana, la varianza, los valores mínimo y máximo, los cuartiles.
- Dibujar el diagrama de cajas y bigotes. ¿Hay algún valor atípico?